



第4章 线性判别函数

- 线性判别函数基本概念
- Fisher线性判别
- 感知准则函数
- 最小平方误差准则函数
- 多类问题简介



4.1 引言

- 问题的提出

$\because P(\omega_i)$ 和 $p(x | \omega_i)$ 估计困难

\therefore 考虑直接方法，利用样本直接设计分类器

线性决策面是较简单的，易于实现，因此
本章主要讨论线性分类器。



4.1 引言

- 判别函数形式

$$g(x) = \omega^T x + \omega_0$$

$$g_i(x) = \omega_i^T x + \omega_{i0} \quad i = 1, 2, \dots, c$$

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} \quad \omega = \begin{bmatrix} \omega_1 \\ \omega_2 \\ \vdots \\ \omega_d \end{bmatrix}$$


$$g_j(x) = \max g_i(x), i = 1, \dots, c \quad x \in \omega_j$$

4.1 引言

■ 两类情况

$$g(x) = g_1(x) - g_2(x)$$

$$\begin{cases} g(x) > 0 & x \in \omega_1 \\ g(x) < 0 & x \in \omega_2 \\ g(x) = 0 & \text{任意分至某一类或拒绝} \end{cases}$$



决定分类界面的方向, w_0 决定分类界面的位置



4.1 引言

■ 线性分类器的设计步骤

(1) 有一已知类别的样本集 H

(2) 确定一准则函数 J

$\left\{ \begin{array}{l} J \text{ 是 } H, \omega, \omega_0 \text{ 的函数} \\ \text{极值解对应最好的“决策”} — \omega^*, \omega_0^* \end{array} \right.$

(3) 利用最优化技术求出准则函数极值解 ω^*, ω_0^*



4.1 引言

■ 与最优分类器的关系

贝叶斯分类器是在错误率或风险下为最优的分类器。线性分类器针对错误率或风险是“次优”的。但对于所采用的准则函数 $J(\omega)$ 则是最优的。

■ 线性可分性

已知一样本集，如果有一个线性分类器能把每个样本正确分类，则称这组样本集为线性可分的，否则称为线性不可分的。反之，如果样本集是线性可分的，则必然存在一个线性分类器能把每个样本正确分类。

4.2 Fisher线性判别



由1936年的经典论文开始最早研究线性判别函数，发明了最大似然估计方法。

其著作有

《研究者用的统计方法》

《统计方法和科学推理》

《近交的理论》

《试验设计》

《自然选择的遗传理论》

《根据孟德尔遗传方式的亲属间的相关》

R. A. Fisher爵士, 1890.2.17-1962.7.29, 英国

现代统计学与现代演化论的奠基者之一


4.2 Fisher线性判别 (两类)

■ 问题的提出

在低维空间中行得通的方法在高维空间里往往失效，因此需要降低空间维数。

■ 基本原理

将高维空间数据向某一直线上投影，如何确定该直线在特征空间中的最佳方向？



Fisher法即寻找最佳的投影方向 ω ，使投影后样本最佳可分


4.2 Fisher线性判别（两类）

■ 投影的表示

$$y = \omega^T x$$

$$y = \omega_1 x_1 + \omega_2 x_2 + \cdots + \omega_d x_d$$

$$\omega = \begin{bmatrix} \omega_1 \\ \omega_2 \\ \vdots \\ \omega_d \end{bmatrix} \quad x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$



投影示意图



4.2 Fisher线性判别（两类）

■ 基本参量定义（ d 维 x 空间）

(1) 各类样本均值向量

$$m_i = \frac{1}{N_i} \sum_{x \in \omega_i} x \quad i = 1, 2$$

(2) 样本类内离散度矩阵 S_i 和总类内离散度矩阵 S_ω

$$S_i = \sum_{x \in \omega_i} (x - m_i)(x - m_i)^T \quad i = 1, 2$$

$$S_\omega = S_1 + S_2$$

对称半正定阵，当 $N > d$ 时通常非奇异

(3) 样本类间离散度矩阵

$$S_b = (m_1 - m_2)(m_1 - m_2)^T$$

对称半正定阵



4.2 Fisher线性判别（两类）

■ 补充定义——正定二次型

设有实二次型 $f = X^T A X$ ，若对任意向量 X 都有 $f > 0$ ，则称矩阵 A 为正定矩阵；若 $f < 0$ ，则称 A 为负定矩阵；若 $f \geq 0$ ，则称 A 为半正定矩阵。

■ 补充定义——非奇异阵

当 $|A|=0$ 时，方阵 A 为奇异阵； $|A| \neq 0$ 时，方阵 A 为非奇异阵。方阵 A 可逆的充要条件是 $|A| \neq 0$ 。

可逆阵亦称非退化阵或非奇异阵或满秩阵

不可逆的方阵也称退化阵或奇异阵或降秩阵



4.2 Fisher线性判别（两类）

- 基本参量定义（一维 y 空间）

(1) 各类样本均值向量

$$\tilde{m}_i = \frac{1}{N_i} \sum_{y \in \omega_i} y \quad i=1,2$$

(2) 样本类内离散度矩阵 \tilde{S}_i^2 和总类内离散度矩阵 \tilde{S}_ω

$$\tilde{S}_i^2 = \sum_{y \in \omega_i} (y - \tilde{m}_i)^2 \quad i=1,2$$

$$\tilde{S}_\omega = \tilde{S}_1^2 + \tilde{S}_2^2$$



4.2 Fisher线性判别（两类）

- 定义Fisher准则函数

$$J_F(\omega) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2} \quad \frac{\text{越大越好}}{\text{越小越好}}$$

原则：各类样本尽可能分开，类内样本尽量密集，需求令准则函数极大的 ω^* 。



4.2 Fisher线性判别（两类）

■ 准则函数的显式化

$$(\tilde{m}_1 - \tilde{m}_2)^2 = (\omega^T m_1 - \omega^T m_2)^2 = \omega^T (m_1 - m_2)(m_1 - m_2)^T \omega = \omega^T S_b \omega$$

$$\because \tilde{S}_i^2 = \sum_{x \in \omega_i} (y - \tilde{m}_i)^2 = \sum_{x \in \omega_i} (\omega^T x - \omega^T m_i)^2 = \omega^T \left[\sum_{x \in \omega_i} (x - m_i)(x - m_i)^T \right] \omega = \omega^T S_i \omega$$

$$\therefore \tilde{S}_1^2 + \tilde{S}_2^2 = \omega^T (S_1 + S_2) \omega = \omega^T S_\omega \omega$$

$$\therefore J_F(\omega) = \frac{\omega^T S_b \omega}{\omega^T S_\omega \omega}$$

求令准则函数极大的 ω^*

4.2 Fisher线性判别（两类）

利用Lagrange乘子法

假设 $\omega^T S_\omega \omega = C \neq 0$

求令准则函数极大的 ω^*

$$L(\omega, \lambda) = \omega^T S_b \omega - \lambda(\omega^T S_\omega \omega - C)$$

$$\frac{\partial L(\omega, \lambda)}{\partial \omega} = S_b \omega - \lambda S_\omega \omega = 0 \quad \text{二次型对向量求导}$$

$$S_b \omega^* = \lambda S_\omega \omega^*$$

$\because S_\omega$ 非奇异

$$\therefore S_\omega^{-1} S_b \omega^* = \lambda \omega^*$$

$$\because S_b = (m_1 - m_2)(m_1 - m_2)^T$$

$$\therefore \lambda \omega^* = S_\omega^{-1} (m_1 - m_2) (m_1 - m_2)^T \omega^* \quad \text{内积为常量，以R替代}$$

$$\therefore \omega^* = \frac{R}{\lambda} S_\omega^{-1} (m_1 - m_2) \quad \text{要求的是方向，常量系数可去除}$$

4.2 Fisher线性判别（两类）

■ 概念补充——二次型对向量求导

$$x^T A x = [x_1 \quad \cdots \quad x_d] \begin{bmatrix} a_{11} & \cdots & a_{1d} \\ \vdots & \ddots & \vdots \\ a_{d1} & \cdots & a_{dd} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix} = \begin{bmatrix} \sum_{\alpha=1}^d a_{\alpha 1} x_1 & \cdots & \sum_{\alpha=1}^d a_{\alpha d} x_d \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix}$$

$$= \sum_{\beta=1}^d \sum_{\alpha=1}^d a_{\alpha\beta} x_{\alpha} x_{\beta}$$

$$\frac{\partial}{\partial x_i} [x^T A x] = \frac{\partial}{\partial x_i} \left| \sum_{\beta=1}^d \sum_{\alpha=1}^d a_{\alpha\beta} x_{\alpha} x_{\beta} \right| = 2a_{ii}x_i + \sum_{j \neq i} (a_{ij} + a_{ji})x_j$$

$$\therefore \frac{\partial}{\partial x} [x^T A x] = (A + A^T)x \quad \text{当 } A = A^T, \frac{\partial}{\partial x} [x^T A x] = 2Ax$$



4.2 Fisher线性判别（两类）

- 投影过程 $y = \omega^{*T} x$
- 一维阈值的选取

(1) 当维数与样本数都很大时，可用贝叶斯分类器

(2) 依据先验知识选择

$$y_0^{(1)} = \frac{\tilde{m}_1 + \tilde{m}_2}{2}$$

$$y_0^{(2)} = \frac{N_1 \tilde{m}_1 + N_2 \tilde{m}_2}{N_1 + N_2}$$

$$y_0^{(3)} = \frac{\tilde{m}_1 + \tilde{m}_2}{2} + \frac{\ln[P(\omega_1)/P(\omega_2)]}{N_1 + N_2 - 2}$$

$$y \begin{matrix} > \\ < \end{matrix} y_0 \rightarrow x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$