认知科学与类脑计算

第三章 学习与记忆模型

山东大学 吴强 副教授

本章要点

01 学习和记忆的定义、意义及简史

02 学习和记忆的分类及其细胞和分子基础

03 基于Hebb学习律的数学模型

04 基于Hebb的主分量分析

05 长短期记忆神经网络

学习和记忆的定义、意义及简史

人们对学习和记忆能力，目前了解得不够透彻。一百多年来，诺贝尔生理医学奖中，授予直接研究学习和记忆的研究的人只有两位，一位是1904 年诺贝尔生理与医学奖获得者Pavlov，他创立了条件反射实验方法，研究神经系统学习的功能。相隔近一百年后，2000 年诺贝尔奖获得者Kandel用海兔的缩鳃反射研究学习和记忆的最基本形式的细胞和分子基础。

一般认为学习是个体生活经历引起的行为上的适应性改变，而记忆是以往经验的存储和回忆。

阿尔兹海默症

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

学习和记忆的定义、意义及简史

人脑	计算机
分布式	集中
按内容记忆	与内容无关
可联想	不可联想
只有一小部分可回忆	全部可回忆
选择性记忆	越多越好
感情兴趣起作用	越精确越好
重组、精炼、故事、情节化	无深层次加工

表3-1-1 人脑记忆与计算机存贮的比较

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

学习和记忆的定义、意义及简史

近代科学发展史中，德国Ebbinghaus的记忆曲线可称为第一个定量结果，他用人作为实验者，发现记忆量是一条按指数衰减的曲线，如图3-1-1

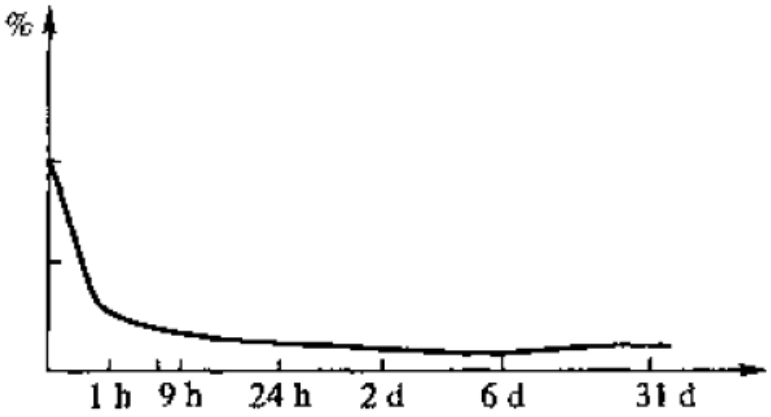

图3-1-1 Ebbinghaus的记忆曲线
横坐标是时间（开始时间以小时为单位，后来时间单位是天），纵坐标是记忆比率

在动物实验方面，值得一提的是巴甫洛夫的条件反射实验和Skinner的操作式(operant)条件实验。

20世纪50-60年代，学习和记忆的心理学研究进入“信息加工学派”为主导的时代，这一学派多以人作为实验对象，研究一些比较复杂的学习记忆行为。

功能定位

例如，一位26 岁女性患者，开颅后刺激额叶的不同部位(图8-2-1)，引起梦样感觉(dream states) 或幻觉重现(flash-back)。

- 刺激图8 -2-1 部位11时她说“我听到某种声音，但我不知道是什么。“
- 当电极刺激部位12 时，她说“是的，我听到河边上两种声音，一个男人的声音和一个女人的声音，他们在叫喊什么。。。我看到了这条河。。。

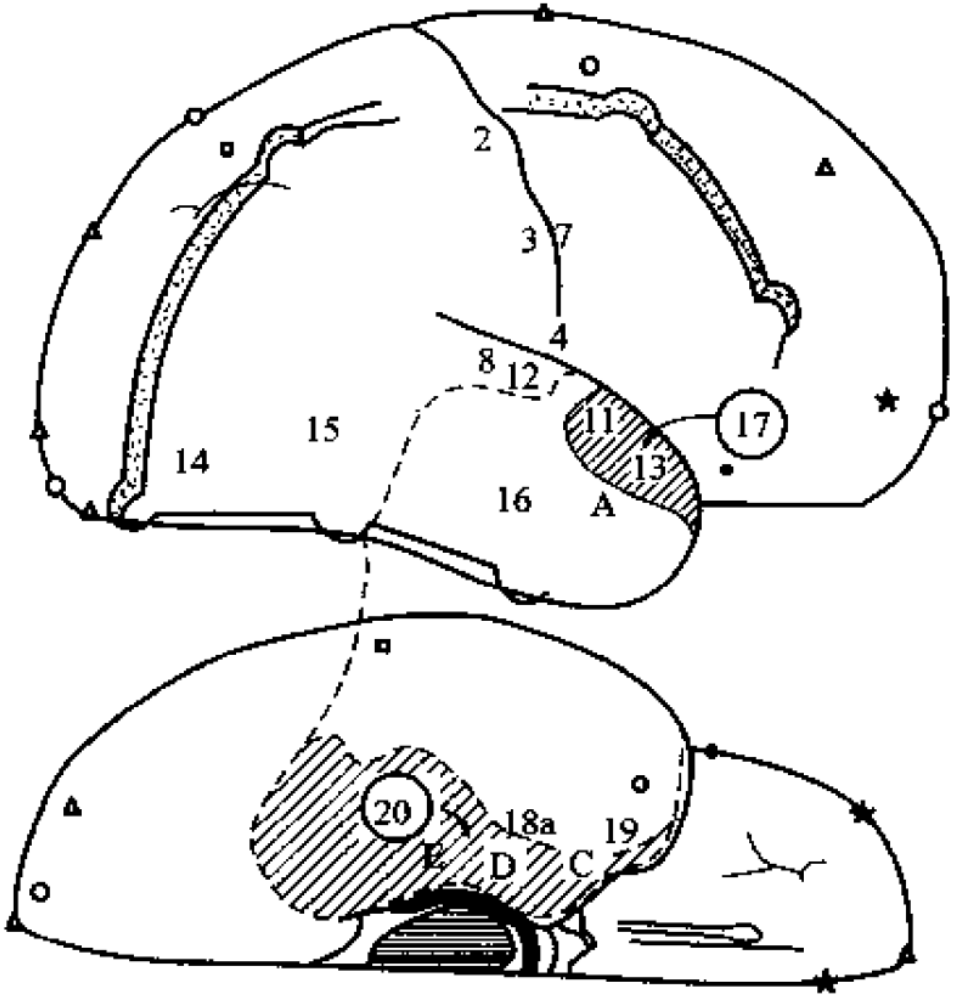

图 8－2－1　人大脑的侧视图

学习和记忆的分类有关脑结构

记忆的分类

按照记忆的内容和性质，分成两大类。**一种是事件、知识的记忆，或称陈述式记忆**，它记忆的东西是事物名称、人名、概念、场景等这些常可用语言表达的东西。因此，也称显性记忆。**另一种是技巧性记忆，或称过程式记忆。**这类记忆常与躯体运动相联系，包括弹琴、骑自行车、游泳等技巧，表示“如何去做”的问题。整个过程难以用语言表达清楚，所以，也称隐性记忆。第二种记忆发展要比较早些，而且一旦学会，终身难忘。这两类记忆的异同如表3-2-1

学习和记忆的分类有关脑结构

记忆的分类

表3-2-1 两种不同的记忆类型

名称	技巧性记忆 Memory for skill Procedure memory Implicit memory	事件性记忆 Memory for events(knowledge) Declarative memory Explicit memory
内容	动作、技巧（如弹琴、游泳、骑车、打字、……）How to do	语义记忆、物、名、概念、情景，What
部位	小脑、皮质运动区	海马、感官、杏仁核、中颞叶、新皮质、联络区
特点	早期发育 不易遗忘 学习进展开始变慢，突然有个飞跃。 每个动作都短于决策时间	2~3岁才发展起来 健忘症，最先遗忘

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

学习和记忆的分类有关脑结构

记忆的分类

心理学实验表明，人的记忆过程按时程来说可分为**瞬时(感觉)记忆**，**短时记忆**和**长时记忆。**“首位效应”实验很能说明问题，如图3-2-1，这几种记忆的容量、发生部位和生理机制都不相同，如表3-2-2

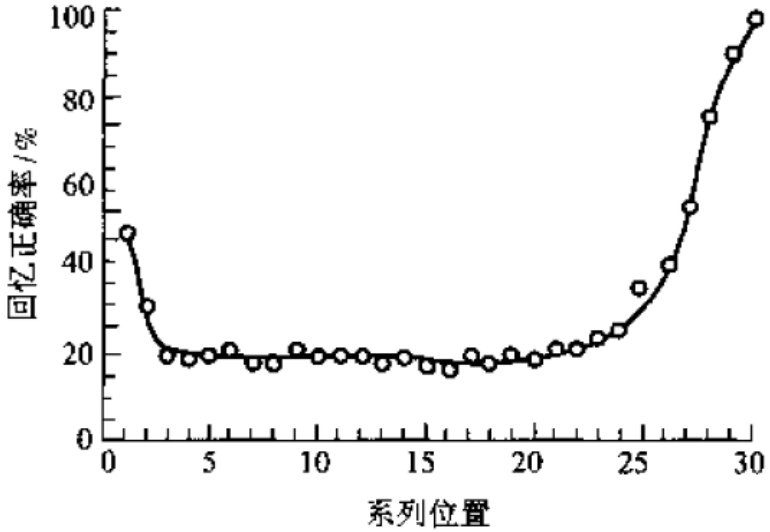

图3-2-1 记忆的“首位效应”
横坐标是言词的出现次序，这是一个由30个词呈现的实验；纵坐标是会议的正确率

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

学习和记忆的分类有关脑结构

记忆的分类

心理学实验表明，人的记忆过程按时程来说可分为**瞬时(感觉)记忆**，**短时记忆**和**长时记忆。**“首位效应”实验很能说明问题，如图3-2-1，这几种记忆的容量、发生部位和生理机制都不相同，如表3-2-2

表3-2-2 记忆时程上的差别

	记忆容量	记忆时间	记忆部位
瞬时记忆	9～20(图像项目) 5(声像)	250～300 ms(图像) 4 s(声像)	感觉系统
短时记忆	7±2 组块	15～30 s	
长时记忆	无限		海马、皮质等

学习和记忆的分类有关脑结构

记忆的分类

瞬时记忆发生在感觉道路中，衰减很快，感觉记忆又可分为图像记忆和声象记忆。视觉感觉记忆表现为视觉残留，是现代电影电视的基本原理。

短时记忆未进入长时记忆前，也能保存一段时间，类似于一个工作平台，本身空间容量较少，随时处理，因此，也称工作记忆。

多次重复刺激，启动神经细胞的分子机制，进入**长时记忆**，可保存相当时日，其中还有一个遗忘过程，现在一般认为这三种记忆之间的关系如图3-2-2所示

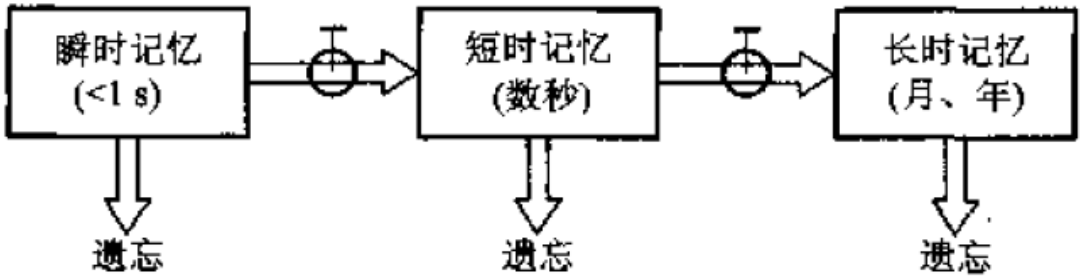

图3-2-2 记忆过程的流程图

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

学习和记忆的分类有关脑结构

记忆的分类

在上述记忆流程图基础上，有的研究者提出“记忆水平论”，该学说认为外界刺激要经过一系列不同水平的分析，从较浅的感觉分析开始到较深、较复杂抽象的语义分析。

也有研究者把长期记忆分成两类，一类称为**情景记忆**，记录个体生活中经历，与时间空间，场景有关，另一类**语义记忆**，记录物、名、符号概念、规则等等。

头部受到强烈撞击以后，例如车祸突发后，伤者逐渐恢复过程中，最先能回忆起来的事情是早年的记忆，然后一点点向近期发展，而事故发生前数分钟的事情，是永远也想不起来的，这是Ribot发现的规律，称为**Ribot定律**。

学习和记忆的分类有关脑结构

学习的分类

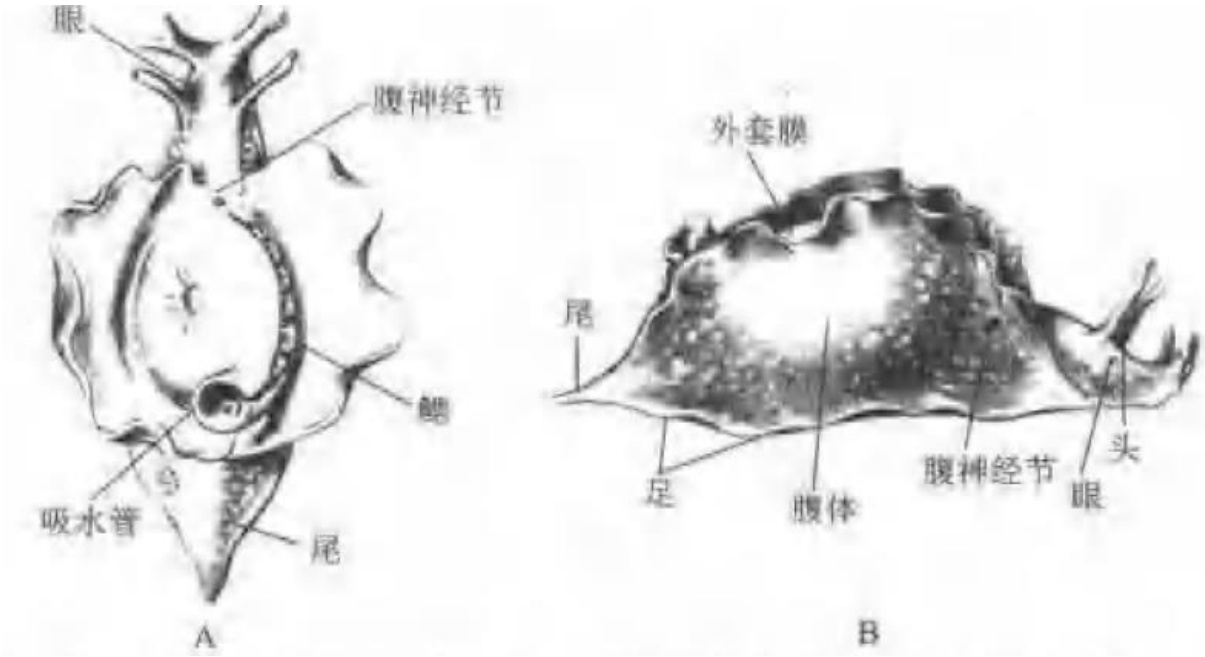

图3-2-3 用于学习和记忆实验的海兔的顶视图(A)和侧视图(B)

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

学习和记忆的分类有关脑结构

学习的分类

(1)非联合性学习

这类学习包括习惯化和敏感化两小类，此时刺激类型比较单一，行为反应是鳃的收缩程度

习惯化

如果用一个较弱的刺激重复性地刺激吸水管，开始时鳃的收缩比较强烈，但随着刺激次数的增加，收缩程度逐渐降低，称为习惯化。控制习惯化的神经回路如图3-2-4

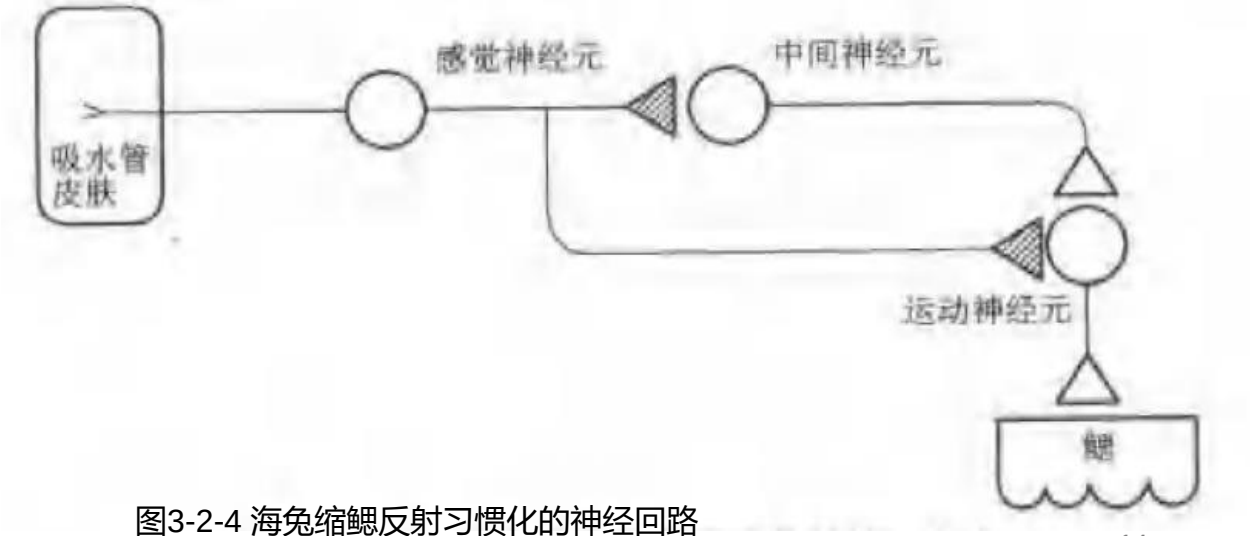

图3-2-4 海兔缩鳃反射习惯化的神经回路
吸水管部分有24个感觉神经元，控制鳃运动的神经元有6个

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

学习和记忆的分类有关脑结构

学习的分类

(1)非联合性学习

敏感化

如果对海兔的头部或尾部给予伤害性刺激，缩鳃反射就会增加，称为敏感化，它的神经回路如图3-2-5所示

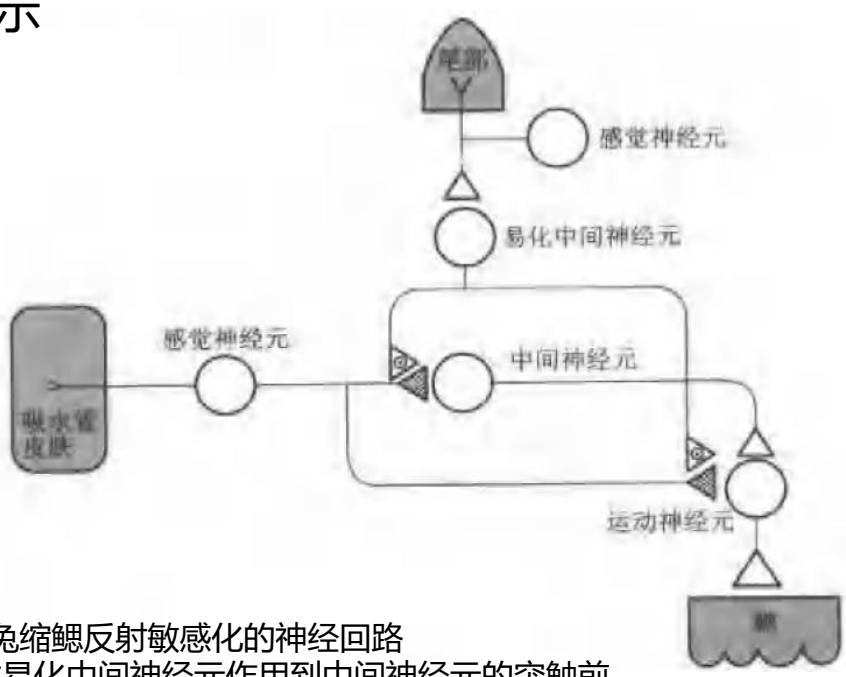

图3-2-5 海兔缩鳃反射敏感化的神经回路

来自尾部感觉神经元，通过易化中间神经元作用到中间神经元的突触前和运动神经元的突触前，所以刺激尾部会增强中间神经元和运动神经元的递质释放，从而使缩鳃反射敏感化

学习和记忆的分类有关脑结构

学习的分类

(2)联合型学习

此时刺激有两个，一个是弱的非条件刺激，如在吸水管的弱刺激引起习惯化，同时在头部或尾部给予强的电击，这种非条件刺激，引起强烈的收缩反射，于是，以后仅仅在吸水管上给予微弱刺激，也能引起强烈的缩鳃反射。这一行为的神经回路如图3-2-6所示

学习和记忆的分类有关脑结构

学习的分类

(2)联合型学习

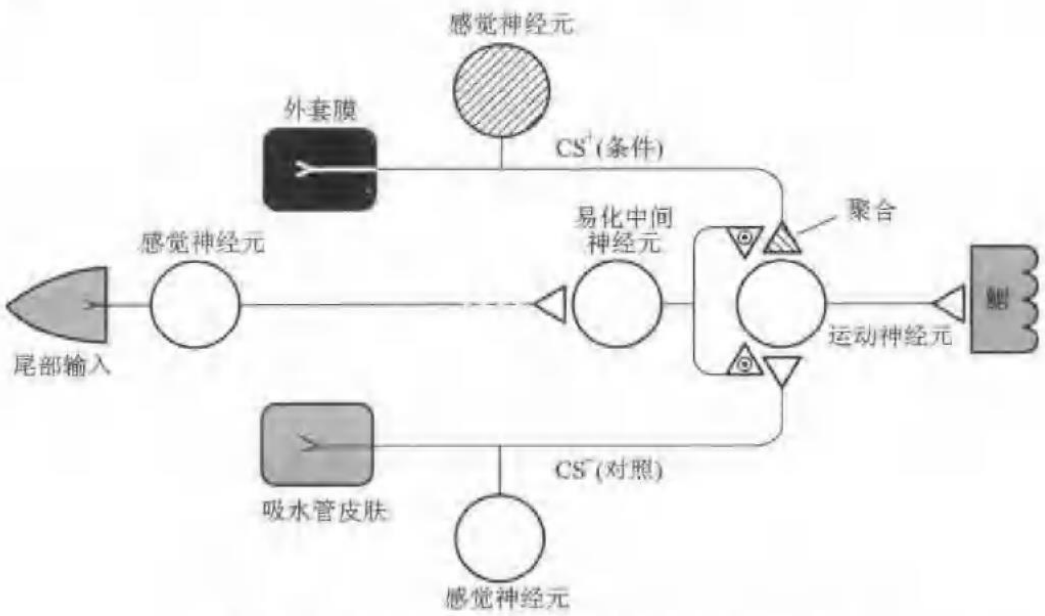

图3-2-6 海兔缩鳃反射过程中联合型学习的神经回路
在条件刺激(CS，外套膜部分)后立刻加以无条件刺激(US，尾部)，可以建立起联合型学习。这两种刺激会聚到运动神经元的突触前，在吸水管(CS)和尾部(US)之间也可以建立联合型学习，但是这个图式中吸水管上的刺激时间斥候尾部刺激，时间上不配对，所以标以CS^-(对照)字样

学习和记忆的分类有关脑结构

学习的分类

(2)联合型学习

人的学习记忆机制远较海兔的复杂，例如，人的视觉陈述性学习记忆过程，牵涉到视皮质(V1)和更高级的视皮质(V2,V3,V4区)，信号又传送到颞叶，继而与边缘系统(海马、杏仁核、内嗅、外嗅和旁海马)发生作用，然后传送内侧颞叶，内侧丘脑，腹内侧额叶，整个神经回路如图3-2-7

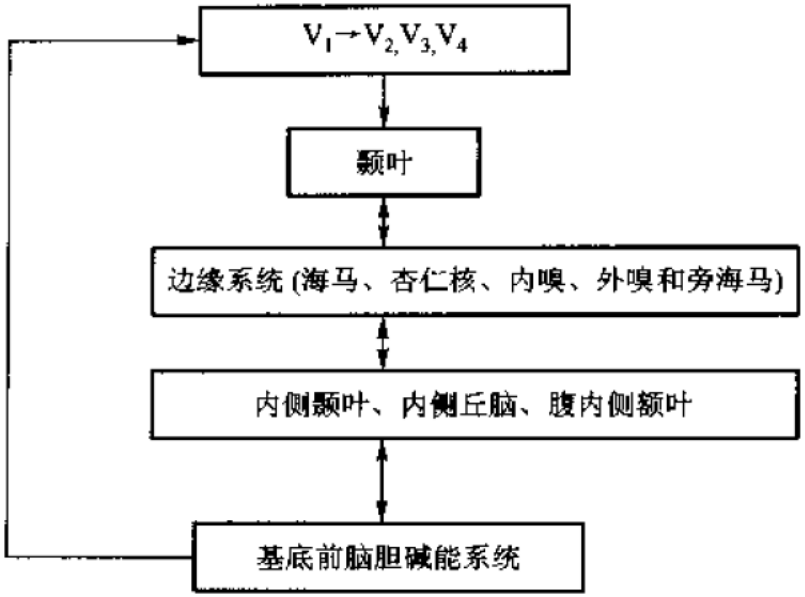

图3-2-7 视觉陈述性记忆的神经回路示意图
图中V代表皮质视区；V_1代表初级视区

学习和记忆的分类有关脑结构

学习的分类

(2)联合型学习

人的技巧性学习记忆的神经调控，也牵涉到许多脑的部位和结构，如图3-2-8所示

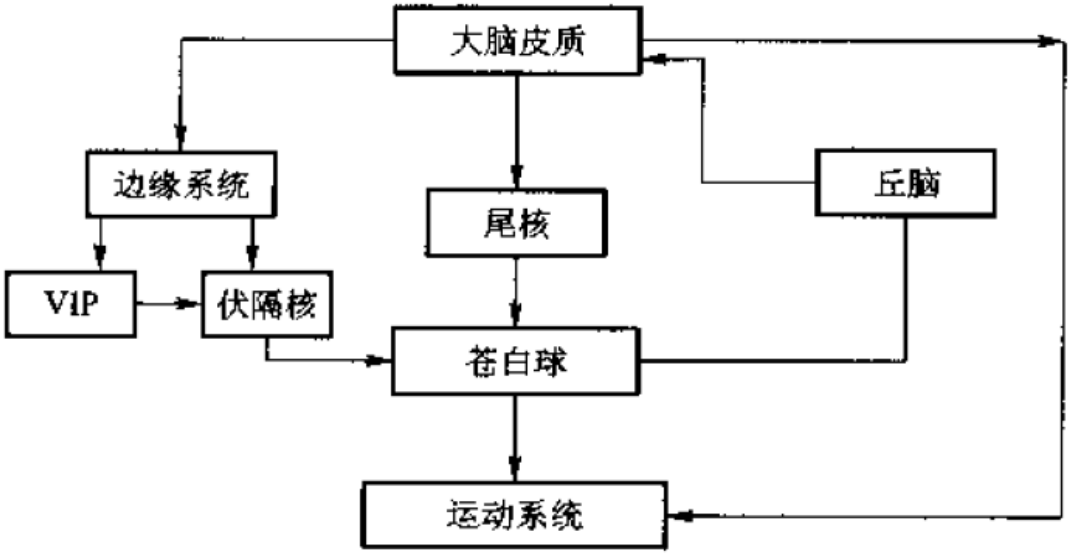

图3-2-8 习得性行为的神经调控的框图
VIP-腹侧顶叶内区

学习和记忆的分类有关脑结构

学习的分类

(2)联合型学习

综合了脑外伤和脑病患者的功能缺失和损伤部位以及一些心理学研究，把两类学习功能及有关解剖部位结合成一张图，如图3-2-9所示

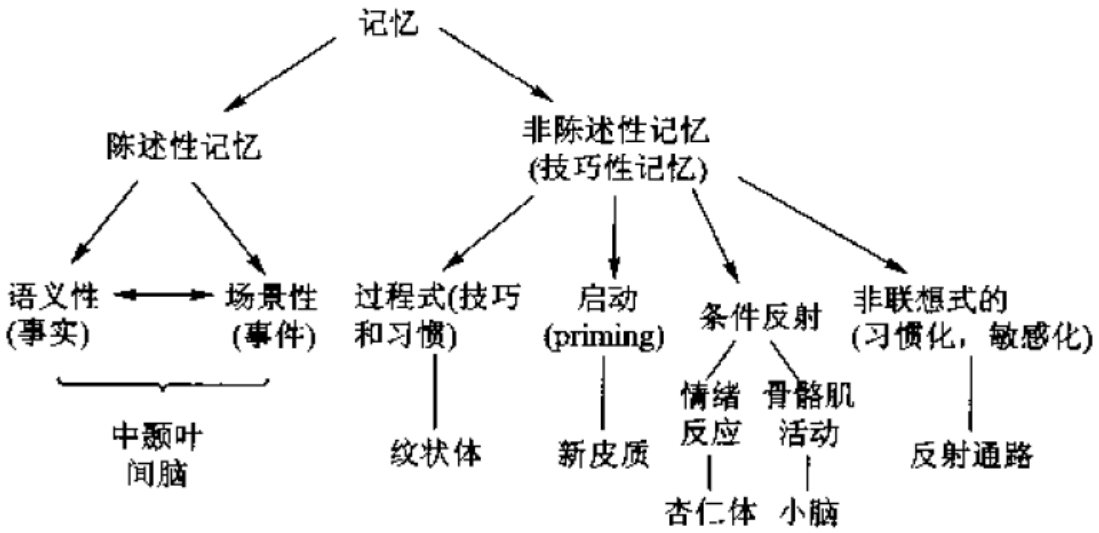

图3-2-9 两类记忆功能及相关解剖部位

学习和记忆的分类及其细胞和分子基础

分子基础

- 早期的一些实验，如训练涡虫走简单迷宫，其学会后，把它喂养别的涡虫，据说可以提高学习效率；
- Unger的恐暗素实验；
- 阿格拉诺夫对金鱼的实验都表明，长期记忆的形成需要蛋白质。

学习和记忆的分类及其细胞和分子基础

分子基础

- Bliss在麻醉的家兔海马上发现长时程增强效应；Douglas对大白鼠海马进行实验；McNaughton发现兔海马CA1区的突触有联合型性质；Nicoll等给出联合型LTP(长时程突触增强)的良好示例；之后发现与LTP相反，突触后电位也能产生长时程压抑(LTD)。

- Kandel以海兔的缩鳃反射实验作为样本，给出了一个单突触成分中短期和长期敏感化中的参与的分子图式，并把基因与突触之前关系画成一张简图，给出神经递质活动的四个过程。

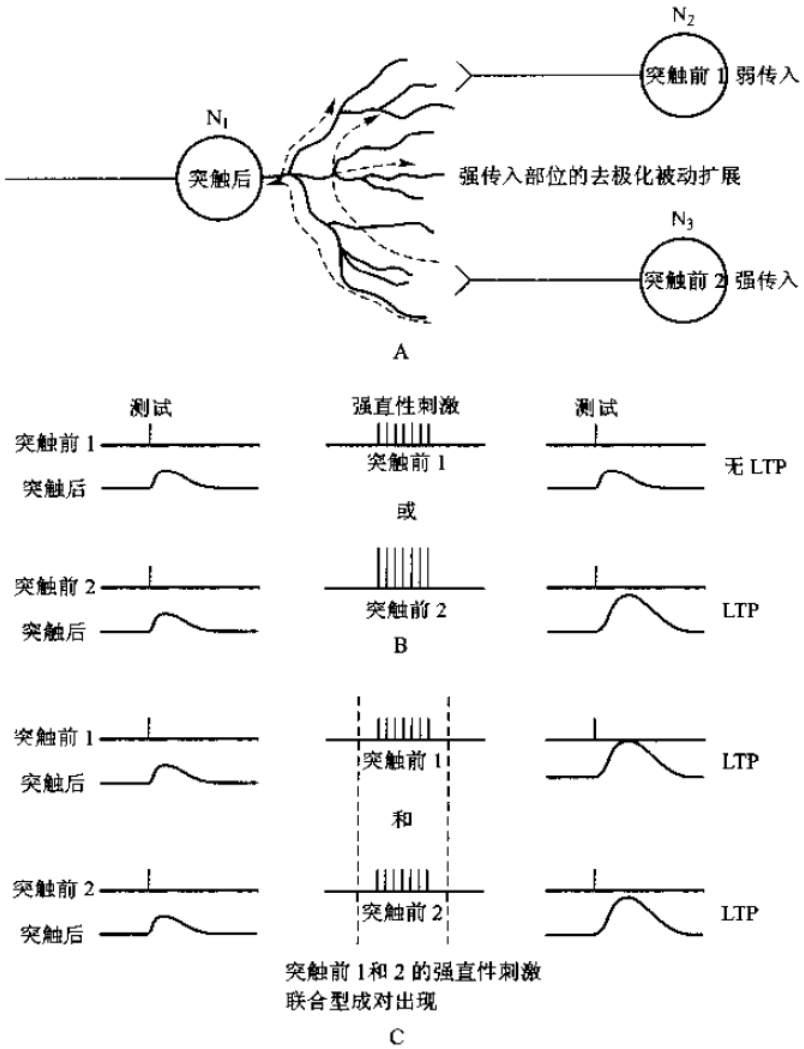

图 8－4－1　联合型长时程突触增强效应(LTP)的例子

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

Hebb学习律的一般数学描述和分类

Hebb律原文：当细胞A的轴突足够靠近细胞B，或重复或持续地参与B的发放，那么某种生长过程或者代谢变化发生在二个或一个细胞上，使得A作用于B的效率有所增加。

对Hebb学习律可以扩展成两个规则：
1.如果两个神经元(即细胞)中的一个突触连接是同时激活的(即同步的)，则突触的强度会选择性地增强。
2.如果两个神经元中的一个突触时异步激活的，则突触会选择性的减弱或消除

基于Hebb学习律的数学模型

Hebb学习律的一般数学描述和分类

假设细胞A和细胞B的发放为V_A和V_B，它的突触联系为W_{AB}，由于细胞A的和细胞B的发放，引起它们之间突触联系有一个增量ΔW_{AB}，一般情况下可表达为下式：

$$\Delta W_{AB} = f(V_A, V_B)$$

其中f表示某种函数关系。

Hebb的突触学习律并没有直接说明函数f的形式为何。

基于Hebb学习律的数学模型

Hebb学习律的一般数学描述和分类

设神经元N_j与神经元N_i之间有突触联系w_{ij}(图3-3-1)，神经元N_j输出为x_j，神经元N_i输出为y_i，这两个神经元之间的联系系数为w_{ij}。R为学习信号，作用于突触w_{ij}上。学习信号R的含义随学习的方式而变，可以是教师信号，也可以是神经元N_j输出有关的量。其中教师信号是人为加入的参与学习过程的因素，它按自己的要求增加或减少(奖或罚)突触联系w_{ij}的值。

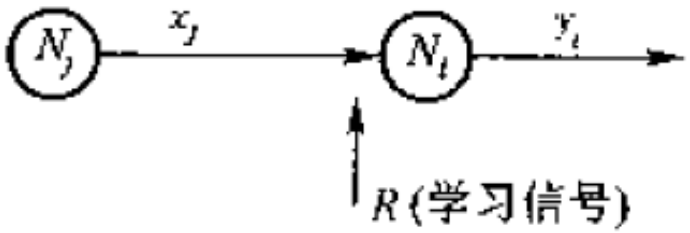

图3-3-1 Hebb学习律的一种图形表示
神经元N_j输出为x_j，它与神经元N_i之间形成突触联系，联系系数用w_{ij}表示，学习信号R作用到w_{ij}

基于Hebb学习律的数学模型

Hebb学习律的一般数学描述和分类

按照图3-3-1的方式，可以写出一般的Hebb学习律的数学表达式。突触联系系数w_{ij}按神经元N_j的输出x_j与学习信号R的乘积而变化，如果长久没有变化，则按指数衰减，Hebb学习律的一般数学描述：

$$\frac{dw_{ij}}{dt} = -Tw_{ij} + CRx_j \qquad (3\text{-}3\text{-}1\text{-}1)$$

其中T为衰减常数，C为常数。$R(d,y)$学习信号，是教师信号d和输出y_i的某个函数。

基于Hebb学习律的数学模型

Hebb学习律的一般数学描述和分类

对于神经元N_i来说，有n个输入神经元，相应的有n个突触相连，(3-3-1-1)式可以写为向量方程：

$$\frac{dW}{dt} = -TW + CRX \qquad (3\text{-}3\text{-}1\text{-}2)$$

其中W表示n个突触的联系系数，$W = (w_1, w_2, \dots, w_n)$，$X$为输入向量，$X = (x_1, x_2, \dots, x_n)$

Hebb学习律的一般数学描述中，按教师信号的有无，可分为有监督学习和无监督学习。

基于Hebb学习律的数学模型

Hebb学习律的一般数学描述和分类

学习信号R起关键作用：

如果学习信号R等于输出信号Y，那么(3-3-1-2)式描述的就是最基本的Hebb学习律，此时，(3-3-1-2)式简化为：

$$\frac{dW}{dt} = -TW + CYX \qquad (3\text{-}3\text{-}1\text{-}3)$$

如果学习信号R是输出信号Y与教师信号D之差，即：$R = Y - D$，此时突触修正方程为：

$$\frac{dW}{dt} = -TW + C(Y - D)X \qquad (3\text{-}3\text{-}1\text{-}4)$$

上式描述的突触修正方程就是感知机中使用的学习方法。

基于Hebb学习律的数学模型

Hebb学习律的一般数学描述和分类

如果学习信号R 等于教师信号，即$R = D$ ，则式(3-3-1-2)变为：

$$\frac{dW}{dt} = -TW + CDX \qquad (3\text{-}3\text{-}1\text{-}5)$$

上式称为相关学习律

如果学习信号R等于教师信号与输入信号和突触系数W乘积之差，即$R = D - W \cdot X$，则式(3-3-1-2)变为：

$$\frac{dW}{dt} = -T \cdot W + C \cdot (D - W \cdot X) \cdot X \qquad (3\text{-}3\text{-}1\text{-}6)$$

上式称为正交学习律

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

无监督学习即无教师学习，也就是外界不干预系统的学习过程，系统按其本身的固有的特性运行。对于一系列输入系统依照固定的联系方式及动力学性质作出反应。系统根据突触可塑性的规则以及训练期内提供的输入性质，对系统进行自组织进化。

基于Hebb学习律的数学模型

无监督学习

1. 基本Hebb学习律

这种学习律是Hebb关于突触可塑性的最简单最直接的表达，它的数学描述如下：

$$\tau \frac{dW}{dt} = YX \qquad (3\text{-}3\text{-}2\text{-}1a)$$

其中W代表突触联系系数，为一向量，τ是常数，Y是突触后神经元的输出，X是突触前神经元的输出也是突触后神经元的输入。(3-3-2-1a)式表明，突触前后同时发放，则引起该突触系数有一个增加，其描述的突触修正过程与神经元本身的电过程比较起来，是相对较慢的，应该把它放在不同的时间尺度上来考虑。学习过程中输入X是在某个集合中不同样本上取值，把不同样本称为输入模式。在一系列输入模式作用下，突触联系系数(权值) W累计它的变化，最后收敛到一个稳定值。在具体计算时，常把(3-3-2-1a)式改写为迭代方程：

$$W \rightarrow W + \Delta W = W + CYX \quad (3\text{-}3\text{-}2\text{-}1b)$$

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

2. 举例

设一神经元u有4个输入(x_1, x_2, x_3, x_4)，分别与4个突触相连(w_1, w_2, w_3, w_4)，该神经元是进行输入综合并取正负为输出，即：

$$\mathrm{sgn}(x) = \begin{cases} 1, & 当x > 0 \\ -1, & 当x \le 0 \end{cases}$$

对于这样一个系统，输入训练集设有三个：

$$X_1 = (1, -2, 1.5, 0)$$
$$X_2 = (1, -0.5, -2, -1.5)$$
$$X_3 = (0, 1, -1, 1.5)$$

又设突触联系系数初始值为：

$$W_0 = (1, -1, 0, 0.5)$$

又设τ =1

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

2. 举例

用模式X_1作为输入，神经元u的纯输入为net_1：

$$net_1 = W_0 X_1^T = (1,-1,0,0.5)\begin{pmatrix}1\\-2\\1.5\\0\end{pmatrix} = 3$$

神经元输出为：$Y_1 = \mathrm{sgn}(net_1) = 1$

更新权重：

$$\begin{aligned} W_1 &= W_0 + \Delta W_0 = W_0 + Y_1 \cdot X_1^T \\ &= (1,-1,0,0.5) + (1,-2,1.5,0) \\ &= (2,-3,1.5,0.5) \end{aligned}$$

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

2. 举例

用模式X_2作为输入，神经元u的纯输入为：

$$net_2 = W_1 X_2^T = (2, -3, 1.5, 0.5)\begin{pmatrix} 1 \\ -0.5 \\ -2 \\ -1.5 \end{pmatrix} = -0.25$$

神经元的输入Y_2为：

$$Y_2 = \mathrm{sgn}(net_2) = -1$$

更新权重：

$$\begin{aligned} W_2 &= W_1 + \Delta W_1 = W_1 + Y_2 \cdot X_2^T \\ &= W_1 - X_2 = (1, -2.5, 3.5, 2) \end{aligned}$$

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

2. 举例

再用模式X_3作为输入，神经元u的纯输入为：

$$net_3 = W_2 X_3^T = (1, -2.5, 3.5, 2)\begin{pmatrix} 0 \\ 1 \\ -1 \\ 1.5 \end{pmatrix} = -3$$

神经元的输入Y_3为：

$$Y_3 = \mathrm{sgn}(net_3) = -1$$

更新权重：

$$W_3 = W_2 + \Delta W_2 = W_2 - X_3 = (1, -3.5, 4.5, 0.5)$$

不断地重复地把训练集输入这个神经元，可以不断地修正突触联系系数

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

3. 相关学习律

如果神经元u的动态方程用第一章$C\frac{du}{dt}=-\frac{1}{R}u+\sum_j^n T_j f[u_j]+I_i \quad (j=1,2,\dots,n)$表达式，即最简单的线性总和方式：

$$\tau\frac{du}{dt}=-u+W\cdot X \qquad (3\text{-}3\text{-}2\text{-}2)$$

此处X为输入，W为突触联系系数，它的静态解为：$\tau\frac{du}{dt}=0=-u+W\cdot X$

$$u=W\cdot X \qquad (3\text{-}3\text{-}2\text{-}3)$$

上面规定神经元的输出为Y，如果神经元的输出函数就是它本身，则：

$$Y=u \qquad (3\text{-}3\text{-}2\text{-}4)$$

上式带入(3-3-2-1)，得：

$$\tau\frac{dW}{dt}=W\cdot X\cdot X \qquad (3\text{-}3\text{-}2\text{-}5)$$

用Q表示输入的相关矩阵，$Q=X\cdot X$那么上式：

$$\tau\frac{dW}{dt}=W\cdot Q \qquad (3\text{-}3\text{-}2\text{-}6)$$

上式即为基于输入相关性的突触可塑性学习律，简称相关学习律

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

3. 相关学习律

上面提到的基本Hebb学习律是不稳定的，设突触联系系数向量W的长度平方为$|W|^2 = W \cdot W = \sum_i w_i^2$，对其微分：

$$\frac{d|W|^2}{dt} = 2W \cdot \frac{dW}{dt} = 2W \cdot W \cdot X \cdot X = 2Y^2 \qquad (3\text{-}3\text{-}2\text{-}7)$$

(3-3-2-7)式表明突触联系系数的绝对值的变化时一个常正值，所以它会连续增长而不稳定

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

4. 协方差律

Hebb假设的原意是突触联系系数(权重)的改变依赖于突触前神经元的兴奋X和突触后神经元的兴奋Y，之后的生理学发现的长时程突触增强效应(LTP)说明符合Hebb的原意，但是，随后长时程突触压抑效应(LTD)的发现，表明如果突触前的活动伴随的是突触后的细胞的低水平活动，它会降低突触效益，因此有一种负的作用。于是将基本Hebb学习律(3-3-2-1)式表达的规律改为：

$$\tau \frac{dW}{dt} = (Y - \theta_1)X \qquad (3\text{-}3\text{-}2\text{-}8)$$

其中θ_1为阈值，它表明突触后兴奋性高于此值时用LTP(为正数)，低于此值时用LTD(为负值)

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

4. 协方差律

对于突触前兴奋性也有一个阈值θ_2，决定LTP还是LTD启动，因此类似于(3-3-2-8)式有：

$$\tau \frac{dW}{dt} = Y(X - \theta_2) \qquad (3\text{-}3\text{-}2\text{-}9)$$

阈值θ_1和θ_2的取得一般按平均值进行，也就是用多种输入模式来训练它，得到一个平均值兴奋性，把它作为阈值

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

4. 协方差律

按照(3-3-2-6)式写法，(3-3-2-8)式和(3-3-2-9)式可合并为一个表达式：

$$\tau \frac{dW}{dt} = C \cdot W \qquad (3\text{-}3\text{-}2\text{-}10)$$

上式中C为协方差矩阵

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

5. BCM律

Bienenstock，Cooper&Munro(1982)提出另一种学习律，也是无监督的，有实验证据表明，突触前和突触后活动都能影响突触联系系数的改变，他们将这种新的学习律称为BCM学习律，表达式：

$$\tau \frac{dW}{dt} = YX(Y - \theta_1) \qquad (3\text{-}3\text{-}2\text{-}11)$$

θ_1是突触后活动的阈值，由它决定突触联系系数是增加还是减少。如果θ_1是可调节的，情况就会不一样。BCM学习律中假定θ_1可变，而且比输出值Y还快，则BCM学习律会稳定。

基于Hebb学习律的数学模型

无监督学习

6. 突触联系系数的正规化(normalization)

上面介绍的几种学习律，在具体执行时往往会发生突触联系系数无限增大，从而使系统不稳定，BCM学习律中采用可调阈值的办法来防止这种情况发生。还有一些其他的办法可做到这一点，可以施加某种全局性约束达到这一目标。如突触联系系数为非负，可令它们的总和小于或等于某个值，即$\sum_i w_i \leq K$，其中K为一常数。或者，突触联系系数w_i可取正值或负值，也可使它们的平方之和小于等于某个常数K，即$\sum_i w_i^2 \leq K$。

不同的正规化可使学习过程的速度以及结果不同

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

无监督学习

6. 突触联系系数的正规化(normalization)

Oja(1982)提出一种非监督学习律，表达式如下：

$$\tau\frac{dW}{dt} = YX - \alpha Y^2 W \qquad (3\text{-}3\text{-}2\text{-}12)$$

其中W, X, Y符号的含义同上，α为一常数。在Oja学习律中，正规化方法称为“乘法性的”。因为上式右边第二项表达的突触修正量正比于W值，Oja学习律中的突触联系系数的稳定性容易证明。用W点乘(3-3-2-12)式两边得：

$$\begin{aligned}\tau\frac{d|W|^2}{dt} &= 2\tau W\frac{dW}{dt} = 2\tau W(YX - \alpha Y^2 W)\\ &= 2\tau YWX - 2\tau\alpha Y^2|W|^2\\ &= 2Y^2(1-\alpha|W|^2) \qquad (3\text{-}3\text{-}2\text{-}13)\end{aligned}$$

$|W|^2$会逐渐收敛到$1/\alpha$，而不会达到无界值。这也保证W的各分量之间可以互相竞争，有的突触联系系数增加，必然引起有的突触联系系数减少。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

有监督学习

1. 感知机学习

   感知机学习过程中，事先有一个期望值，而训练开始时，用不同模式作为输入时，往往达不到预计要求，因此有一个差距(误差)，用这个误差来调正突触联系系数，经过多次训练后，可达到预期要求。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

有监督学习

1. 感知机学习

感知机学习过程中，事先有一个期望值，而训练开始时，用不同模式作为输入时，往往达不到预计要求，因此有一个差距(误差)，用这个误差来调正突触联系系数，经过多次训练后，可达到预期要求。

设系统的实际输出为Y，而期望的反应为Z，它们之间有一个差距，把这个差距作为学习信号$R = Z - Y$，如果神经元的输出函数为符号函数：

$$\mathrm{sgn}(x) = \begin{cases} 1, & \text{当} x > 0 \\ -1, & \text{当} x \le 0 \end{cases}$$

系统的输出$Y = \mathrm{sgn}(YX)$，用预值与实际输出之差乘以输入值，作为突触修正量，来更新突触联系系数：

$$\begin{aligned} W \to W + \Delta W &= W + CRX = W + C(Z - Y)X \\ &= W + C(Z - \mathrm{sgn}(W \cdot X))X \qquad (3\text{-}3\text{-}3\text{-}1) \end{aligned}$$

而突触修正量ΔW为：

$$\Delta W = C(Z - \mathrm{sgn}(W \cdot X))X \qquad (3\text{-}3\text{-}3\text{-}2)$$

其中C为常数

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

有监督学习

2. 举例

设输入模式为向量，有三个：

$$X_1 = (1, -2, 0, -1)$$
$$X_2 = (0, 1.5, -0.5, -1)$$
$$X_3 = (-1, 1, 0.5, -1)$$

期望把这三个模式分为两类，即Z_1(对应X_1)与Z_2(对应X_2)归为一类，期望值为-1，而Z_3(对应X_3)的期望值为1，为另一类。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

有监督学习

2. 举例

设突触联系系数为$W_0 = (1,-1,0,0.5)$，$C = 0.1$，把模式X_1作为输入，计算实际输出：

$$net_1 = W_0 X_1^T = (1,-1,0,0.5)\begin{pmatrix} 1 \\ -2 \\ 0 \\ -1 \end{pmatrix} = 2.5$$

$$Y_1 = \mathrm{sgn}(net_1) = 1$$

更新突触联系系数：

$$W_1 = W_0 + C \cdot (Z_1 - \mathrm{sgn}(W_0 X_1))X_1 = W_0 + 0.1 \cdot \big((-1) - 1\big) \cdot X_1$$
$$= (1,-1,0,0.5) - 0.2 \cdot (1,-2,0,-1) = (0.8,-0.6,0,-0.7)$$

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

有监督学习

2. 举例

再把第二个模式X_2作为输入，计算神经元纯输入：

$$net_2 = W_1 X_2^T = (0.8, -0.6, 0, 0.7)\begin{pmatrix} 0 \\ 1.5 \\ -0.5 \\ -1 \end{pmatrix} = -1.6$$

神经元实际输出：

$$Y_2 = \mathrm{sgn}(net_2) = -1$$

与期望值Z_2相同，突触联系系数不必调整，即$W_2 = W_1$。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

有监督学习

2. 举例

把第三个模式X_3作为输入，计算神经元纯输入：

$$net_3 = W_2 X_3^T = (0.8, -0.6, 0, 0.7)\begin{pmatrix} -1 \\ 1 \\ 0.5 \\ -1 \end{pmatrix} = -2.1$$

实际输出Y_3：

$$Y_3 = \mathrm{sgn}(net_3) = \mathrm{sgn}(-2.1) = -1$$

与期望输出$Z_3 = 1$不符，更新联系系数：

$$W_3 = W_2 + C \cdot (Z_3 - \mathrm{sgn}(W_2 X_3))X_3 = W_2 + 0.1 \cdot (1+1) \cdot X_3$$
$$= (0.6, -0.4, 0.1, 0.5)$$

重复使用上述算法，可以调正突触联系系数W，使得当X_1和X_2为输入，反应均为-1，而X_3为输入时输出为1。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

有监督学习

3. δ学习律

δ学习律(DLR)的学习信号为期望值与实际输出之差，再乘以实际输出的微分值。神经元的实际输出为$f(u)$，其中$u=\sum_i w_i x_i$表示神经元的膜电位u是输入的线性总和，而输出函数f是一非线性函数。

DLR算法中，学习信号R为：

$$R=[Z-f(W\cdot X)]\cdot f'(W\cdot X) \qquad (3\text{-}3\text{-}3\text{-}3)$$

基于Hebb学习律的数学模型

有监督学习

3. δ学习律

这一学习律可用图3-3-2表示：

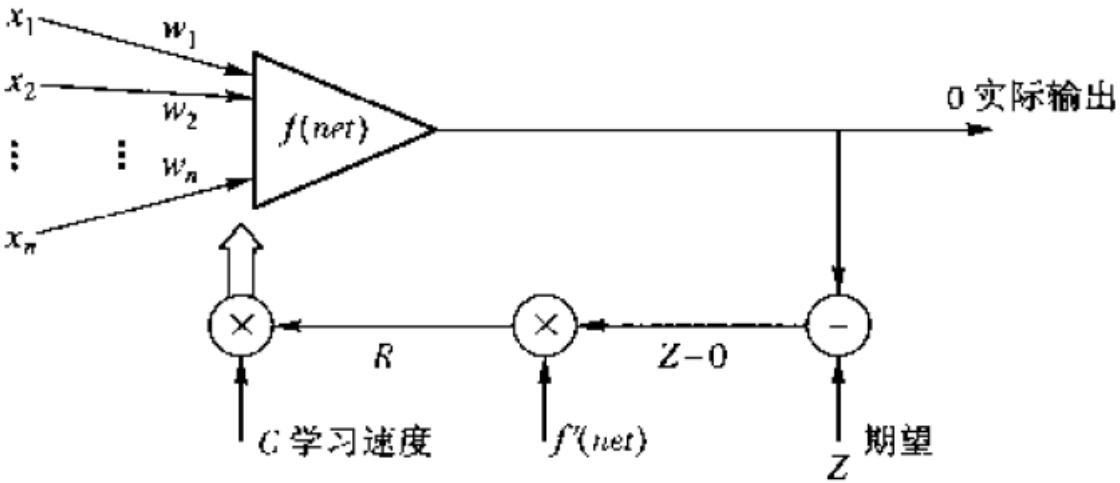

图3-3-2 δ学习律的图式化表示

输入X与突触联系系数相乘得net，经非线性函数f得实际输出值0。期望Z与实际输出值0之差，再乘f'作为学习信号R，用R信号乘以学习速度常数C来修正突触联系系数

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

有监督学习

3. δ学习律

δ学习律是一种收敛的学习算法。设这一学习过程的势函数E为均方差，即期望值与实际值之间差值的平法：

$$E = \frac{1}{2}(Z - Y)^2 \qquad (3\text{-}3\text{-}3\text{-}4)$$

或者

$$E = \frac{1}{2}[Z - f(W \cdot X)]^2 \qquad (3\text{-}3\text{-}3\text{-}5)$$

该均方差的变化方向，由它的微分决定，

$$\nabla E = -[Z - Y] \cdot f'(W \cdot X) \cdot X \qquad (3\text{-}3\text{-}3\text{-}6)$$

其中W为突触矩阵。某个分量w_i而言，对(3-3-3-6)式微分：

$$\frac{\partial E}{\partial w_i} = -[Z - Y] \cdot f'(W \cdot X) \cdot x_i \,, i = 1,2,\ldots,n \qquad (3\text{-}3\text{-}3\text{-}7)$$

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

有监督学习

3. δ学习律

在学习工程中，突触联系系数要收敛到一个稳定值，表示势函数的梯度为负值，即：

$$\Delta w_i = -\eta \nabla E \qquad (3\text{-}3\text{-}3\text{-}8)$$

其中η为正值，把(3-3-3-6)式代入(3-3-3-8)式，得：

$$\Delta w_i = \eta \cdot [Z - Y] \cdot f'(W \cdot X) \cdot X \qquad (3\text{-}3\text{-}3\text{-}9)$$

也就是Δw取(3-3-3-9)，即可保证势函数(期望值与实际值的均方差)的梯度沿负值方向运动，趋向于一个稳定值，因而此学习算法是收敛的。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

学习算法小结

关于神经系统学习和记忆的机理，Hebb提出一个笼统的突触修正假设，发展出各种各样的学习算法，这种理论上的发展，产生两方面的重大影响，一方面根据这种理论假设，建立数学模型，然后与神经科学中的现象进行比较，考虑它能否解释这些现象的产生。第二方面的影响来自各种学习律在技术方面的应用。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

学习算法小结

表3-3-1 几种学习算法的比较

学习律	突触修正量	初始值	有无监督	神经元性质	单个神经元或层
Hebb律	$co_i x_j$	0	无	任何	单个
感知机	$c[d_i - \mathrm{sgn}(w_i X)]x_j$	任何	有	二值	单个
δ学习律	$c(d_i - o_i)f'(net_i)x_j$	任何	有	连续	单个
W-H学习律	$c(d_i - w_i x)x_j$	任何	有	任何	单个
相关律	$cd_i x_j$	0	有	任何	单个
胜者为王	$\Delta w_{mj} = \alpha(x_j - w_{mj})$	随机正则	无	连续	神经元层
Outstar	$\beta(d_i - w_{ij})$	0	有	连续	神经元层

注：c：学习速度常数；o_i：实际输出；x_j：输入；d_i：期望输出

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

脉冲时间依赖的突触可塑性与数学描述

突触前后脉冲发放的时间次序和间隔是决定性关键，其中最典型的实验结果表明，突触前脉冲发放在前，突触后发放在后，则造成突触修正有一个正的变化，若突触前发放在后，突触后发放在前，则造成一个负的变化。突触前后脉冲发放的时序产生的效果是相反的，形成某种反对称的效应。突触修正的不同时间特性反映了神经系统中突触机制的多样性，可以在神经系统的不同部位和不同阶段的信息加工起特殊的作用。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

脉冲

脉冲)P)
现象 为
时间

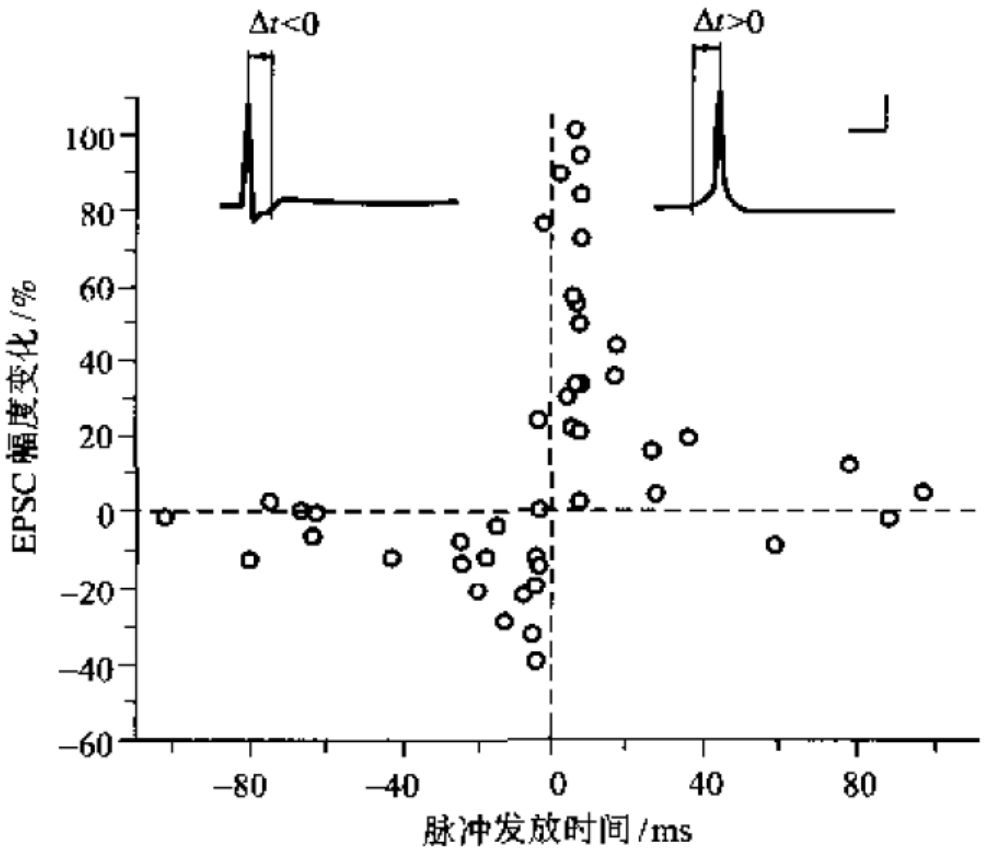

图 10－5－1　突触前后脉冲发放的先后与 EPSC(excitatory postsynaptic current)的增减关系

横坐标是突触前后脉冲发放的相对时间，0 点在中央，右侧表示突触前脉冲发放在先，左侧表示突触前脉冲发放在后，单位是 ms。纵坐标是 EPSC 幅度的变化，整个变化呈现十分明显的反对称形状。（引自 Bi & Poo，1998）

基于Hebb学习律的数学模型

脉冲时间依赖的突触可塑性与数学描述

脉冲时间以来的突触可塑性（spike-timing dependent plasticity，STDP）的发现及其理论的过程可能对现有的学习算法产生重大影响。STDP的突触修正规律，发生在数十毫秒之内，是一种快速的变化，可能对学习效果产生影响，同时，不同类型的时间窗可能对学习的结果有关键性作用。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

脉冲时间依赖的突触可塑性与数学描述

对于典型的反对称时间突触修正有如下形式表达。设突触联系系数W的变化量为ΔW，最大值为W_{max}，联系系数的当前值为W，用Δt表示突触前后脉冲发放的时间间隔。那么反对称时间窗可用等式表达：

$$\Delta W = \begin{cases} f_+(w)\exp(-\Delta t/\tau_+), & \text{当}\Delta t > 0 \\ f_-(w)\exp(-|\Delta t|/\tau_-), & \text{当}\Delta t < 0 \end{cases} \quad (3\text{-}3\text{-}5\text{-}1)$$

其中$f_+(w)$为突触前后脉冲发放为正值时引起突触修正的最大值，$f_-(w)$为突触前后脉冲发放为负值时突触修正的最小值。 τ_+和τ_-为时间常数。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb学习律的数学模型

脉冲时间依赖的突触可塑性与数学描述

设$H(\tau)$是时间函数，可以采用式(3-3-5-1)形式(反对称时间窗)，也可以采用其他时间窗形式，总的突触修正量是多次突触前后发放的时间差τ之和。设突触前发放为$V(t)$，突触后发放的$\boldsymbol{u}(t)$，那么突触修正的变化率为：

$$\tau_W \frac{dW}{dt} = \int_0^{\infty} d\tau [H(\tau)V(\tau)\boldsymbol{u}(t-\tau) + H(-\tau)V(t-\tau)\boldsymbol{u}(t)] \qquad (3\text{-}3\text{-}5\text{-}2)$$

其中τ_W为常数， $H(\tau)$为时间窗函数。上始终积分不需要∞，因为时间窗的有效范围一般都不长，在一定误差范围内设为T，则上式可写为：

$$\tau_W \frac{dW}{dt} = \int_0^{T} d\tau [H(\tau)V(\tau)\boldsymbol{u}(t-\tau) + H(-\tau)V(t-\tau)\boldsymbol{u}(t)] \qquad (3\text{-}3\text{-}5\text{-}3)$$

上式仅是形式上描述了STDP的可塑性。

神经信息学—神经系统的理论和模型
汪云九等著
高等教育出版社，2006.06

基于Hebb的主分量分析

自组织原则

无监督学习可以从两个不同的方面考虑：
(1)自组织学习，其从神经生物的角度考虑。特别的，半监督学习算法伴随着一系列局部行为规则，要求使用这些规则计算带有预期性质的输入输出映射。这里的局部是指对于神经网络中每个神经元突触权值的调整收到神经元局部邻居的限制。在此环境下，用于自组织学习的神经网络模型区域神经生物学结构，使得网络组织与人脑相似。

(2)统计机器学习理论，这是传统机器学习的方法。在神经网络中强调的局部学习的概念在机器学习中起到次要作用。相反，在统计机器学习中，更强调数学工具

基于Hebb的主分量分析

自组织原则

原则1 自增强

自组织第一个原则是：神经元突触权值的修正随着Hebb条件学习自增强，这使得突触可塑性有了可能。

原则2 竞争原则

第二个自组织原则：可用资源的局限性，以一种或另一种的形式，导致单个或一群神经元的突触之间的竞争。这个结果使得最强健增长的突触或神经元是以其他神经元作为代价的。

原则3 协作

自组织的第三个原则：在神经网络和网络的神经元级别中，对突触权值的修改趋于互相合作。

原则4 结构化信息

自组织的最后一条原则：在一个输入信号中存在的潜在次序和结构代表了冗余的信息，其通过一个自组织系统以知识的形式获得。

基于Hebb的主分量分析

主分量分析

在统计模式识别中，一个常见的问题是特征选择或特征提取。特征选择是指将数据空间变换到特征空间的过程，在理论上与原始数据空间具有相同的维数。然而，我们希望设计一种变换使得数据集由维数较少的“有效”特征来表述，而不减少原始数据所包含的内在信息内容；换句话说，数据集进行了维数压缩。具体来说，假设一个m维的向量$\boldsymbol{x}$，希望压缩到l维，其中$l < m$，如果简单截断$\boldsymbol{x}$，所带来的均方误差等于舍掉的各分量的方差之和。希望找一个可逆的线性变换$\mathbf{T}$，使得对$\mathbf{T}\boldsymbol{x}$的截断在均方误差意义下最优。要求变换$\mathbf{T}$的某些分量具有较低的方差。主分量分析能最大限度地减少方差，并因而是正确的选择。

基于Hebb的主分量分析

主分量分析

令$\mathbf{X}$为表示环境的m维随机向量。假设$\mathbf{X}$均值为0，即：

$$\mathbb{E}[\mathbf{X}] = \mathbf{0}$$

如果$\mathbf{X}$均值不为0，在执行分析前先减去其均值。

令$\mathbf{q}$表示m维单位向量， $\mathbf{X}$在其上投影。这个投影被定义为向量$\mathbf{X}$和$\mathbf{q}$的内积，表示为：

$$A = \mathbf{X}^T\mathbf{q} = \mathbf{q}^T\mathbf{X} \quad (3\text{-}4\text{-}1\text{-}1)$$

满足约束条件：

$$||\mathbf{q}|| = (\mathbf{q}^T\mathbf{q})^{1/2} = 1 \qquad (3\text{-}4\text{-}1\text{-}2)$$

投影A也是随机变量，其均值和方差与$\mathbf{X}$的统计有关。由假设$\mathbf{X}$的均值为0，推知A的均值也为0：

$$\mathbb{E}[A] = \mathbf{q}^T\mathbb{E}[\mathbf{X}] = 0$$

方差与其均方值相同：

$$\sigma^2 = \mathbb{E}[A^2] = \mathbb{E}[(\mathbf{q}^T\mathbf{X})(\mathbf{X}^T\mathbf{q})] = \mathbf{q}^T\mathbb{E}[\mathbf{X}\mathbf{X}^T]\mathbf{q} = \mathbf{q}^T\mathbf{R}\mathbf{q} \quad (3\text{-}4\text{-}1\text{-}3)$$

基于Hebb的主分量分析

主分量分析

$m \times m$矩阵$\mathbf{R}$是随机向量$\mathbf{X}$和它自己的外积的期望，表示为：

$$\mathbf{R} = \mathbb{E}[\mathbf{X}\mathbf{X}^T] \qquad (3\text{-}4\text{-}1\text{-}4)$$

相关矩阵$\mathbf{R}$是对称的，即：

$$\mathbf{R}^T = \mathbf{R}$$

由这个性质知，如果$\mathbf{a}$和$\mathbf{b}$为任意$m \times 1$向量，那么

$$\mathbf{a}^T\mathbf{R}\mathbf{b} = \mathbf{b}^T\mathbf{R}\mathbf{a} \qquad (3\text{-}4\text{-}1\text{-}5)$$

由式(3-4-1-3)看出，投影A的方差σ^2是单位向量$\mathbf{q}$的函数，可以写为：

$$\psi(\mathbf{q}) = \sigma^2 = \mathbf{q}^T\mathbf{R}\mathbf{q} \qquad (3\text{-}4\text{-}1\text{-}6)$$

基于此认为$\psi(\mathbf{q})$为方差探针。

基于Hebb的主分量分析

主分量分析的特征结构

在欧几里得范数的约束条件下，找出单位向量$\mathbf{q}$沿$\psi(\mathbf{q})$所具有的极值或稳定值。如果$\mathbf{q}$为单位向量使得方差探针$\psi(\mathbf{q})$具有极值，那么对单位向量$\mathbf{q}$任意小的扰动$\delta\mathbf{q}$， $\delta\mathbf{q}$的一阶项有：

$$\psi(\mathbf{q}+\delta\mathbf{q})=\psi(\mathbf{q})$$

从式(3-4-1-6)给出方差探针定义，有：

$$\psi(\mathbf{q}+\delta\mathbf{q})=\mathbf{q}^T\mathbf{R}\mathbf{q}+2(\delta\mathbf{q})^T\mathbf{R}\mathbf{q}=\psi(\mathbf{q})+2(\delta\mathbf{q})^T\mathbf{R}\mathbf{q} \qquad (3\text{-}4\text{-}1\text{-}7)$$

$\psi(\mathbf{q}+\delta\mathbf{q})$是$\psi(\mathbf{q})$的一阶近似；因此有：

$$(\delta\mathbf{q})^T\mathbf{R}\mathbf{q}=0 \qquad (3\text{-}4\text{-}1\text{-}8)$$

对$\mathbf{q}$而言，任意扰动$\delta\mathbf{q}$是不允许的；相反对扰动进行限制，仅使$\mathbf{q}+\delta\mathbf{q}$的欧几里得范数为1的扰动是允许的，即：

$$\left||\mathbf{q}+\delta\mathbf{q}|\right|=1$$

或等价地：

$$(\mathbf{q}+\delta\mathbf{q})^T(\mathbf{q}+\delta\mathbf{q})=1$$

根据式(3-4-1-2)，要求对$\delta\mathbf{q}$的一阶项有：

$$(\delta\mathbf{q})^T\mathbf{q}=0 \qquad (3\text{-}4\text{-}1\text{-}9)$$

这意味着，扰动$\delta\mathbf{q}$必须与$\mathbf{q}$正交，因此仅$\mathbf{q}$的垂直方向上变化时允许的。

基于Hebb的主分量分析

主分量分析的特征结构

通常单位向量$\mathbf{q}$在物理意义上是无量纲的。从而如果结合式(3-4-1-8)和式(3-4-1-9)，那么必须在式(3-4-1-9)中引入一个比例因子λ使得它和相关矩阵$\mathbf{R}$中的元素有相同的量纲：

$$(\delta\mathbf{q})^T\mathbf{R}\mathbf{q} - \lambda(\delta\mathbf{q})^T\mathbf{q} = 0$$

或等价于：

$$(\delta\mathbf{q})^T(\mathbf{R}\mathbf{q} - \lambda\mathbf{q}) = 0 \qquad (3\text{-}4\text{-}1\text{-}10)$$

式(3-4-1-10)成立的充要条件为：

$$\mathbf{R}\mathbf{q} = \lambda\mathbf{q} \qquad (3\text{-}4\text{-}1\text{-}11)$$

这个方程控制单位向量$\mathbf{q}$使得方差探测值$\psi(\mathbf{q})$有极值

基于Hebb的主分量分析

主分量分析的特征结构

式(3-4-1-11)被认为是特征值问题，仅对特殊的λ值问题有非平凡解(即$\mathbf{q} \neq \mathbf{0}$)，$\lambda$被称为相关矩阵$\mathbf{R}$的特征值，对应的$\mathbf{q}$被称为特征向量。相关矩阵的特征值必须为非负数。假设它的特征值互不相同，则对应的特征向量是唯一的。令$m \times m$矩阵$\mathbf{R}$的特征值为$\lambda_1, \lambda_2, \dots, \lambda_m$，对应的特征向量分别是$\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_m$：

$$\mathbf{R}\mathbf{q}_j = \lambda_j \mathbf{q}_j \text{，} j = 1,2, \dots, m \qquad (3\text{-}4\text{-}1\text{-}12)$$

令相应的特征值按降序排列，即：

$$\lambda_1 > \lambda_2 > \cdots > \lambda_j > \cdots > \lambda_m \qquad (3\text{-}4\text{-}1\text{-}13)$$

这样$\lambda_1 = \lambda_{\max}$。令对应的特征向量用于构成一个$m \times m$矩阵：

$$\mathbf{Q} = [\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_j, \dots, \mathbf{q}_m] \qquad (3\text{-}4\text{-}1\text{-}14)$$

结合式(3-4-1-12)中的m个方程为一个方程组：

$$\mathbf{R}\mathbf{Q} = \mathbf{Q}\boldsymbol{\Lambda} \qquad (3\text{-}4\text{-}1\text{-}15)$$

其中$\boldsymbol{\Lambda}$为$\mathbf{R}$的特征值构成的对角矩阵，即：

$$\boldsymbol{\Lambda} = [\lambda_1, \lambda_2, \dots, \lambda_j, \dots, \lambda_m] \qquad (3\text{-}4\text{-}1\text{-}16)$$

基于Hebb的主分量分析

主分量分析的特征结构

矩阵**Q**是正交(酉)矩阵，意味着它的列向量(即**R**的特征向量)满足正交条件：

$$\mathbf{q}_i^T\mathbf{q}_j = \begin{cases} 1, & j = i \\ 0, & j \neq i \end{cases} \qquad (3\text{-}4\text{-}1\text{-}17)$$

式 (3-4-1-17)要求不同的特征值。等价地，可写成：

$$\mathbf{Q}^T\mathbf{Q} = \mathbf{I}$$

由此可以推导出矩阵**Q**的逆矩阵与它的转置矩阵相同，表示为：

$$\mathbf{Q}^T = \mathbf{Q}^{-1} \qquad (3\text{-}4\text{-}1\text{-}18)$$

这意味着可以重写(3-4-1-15)为众所周知的正交相似变换形式：

$$\mathbf{Q}^T\mathbf{R}\mathbf{Q} = \mathbf{\Lambda} \qquad (3\text{-}4\text{-}1\text{-}19)$$

或展开为：

$$\mathbf{q}_j^T\mathbf{R}\mathbf{q}_k = \begin{cases} \lambda_j, & k = j \\ 0, & k \neq j \end{cases} \qquad (3\text{-}4\text{-}1\text{-}20)$$

基于Hebb的主分量分析

主分量分析的特征结构

式(3-4-1-19)的正交相似(酉)变换将相关矩阵$\mathbf{R}$变成特征值对角阵。相关矩阵$\mathbf{R}$可以用特征值和特征向量表示为：

$$\mathbf{R} = \sum_{i=1}^{m} \lambda_i \, \mathbf{q}_i \mathbf{q}_i^T = \mathbf{Q}\boldsymbol{\Lambda}\mathbf{Q}^{\boldsymbol{T}} \quad (3\text{-}4\text{-}1\text{-}21)$$

这称为谱定理，对所有i，外积$\mathbf{q}_i \mathbf{q}_i^T$的秩为1。式(3-4-1-19)和式(3-4-1-21)是相关矩阵$\mathbf{R}$的特征分解的两个等价表示。

主分量分析和矩阵$\mathbf{R}$的特征分解从根本上来说是一致的，只是从不同的角度观察问题。从式(3-4-1-6)和式(3-4-1-20)可以看出方差探针和特征值的确相等，表示为：

$$\psi(\mathbf{q}_j) = \lambda_j, \ j = 1,2,\ldots,m \quad (3\text{-}4\text{-}1\text{-}22)$$

从主分量分析的特征结构中有两个重要发现：

- 零均值的随机向量$\mathbf{X}$的相关矩阵$\mathbf{R}$的特征向量定义为单位向量$\mathbf{q}_j$，代表主方向，沿着它们的方差探针$\psi(\mathbf{q}_j)$取得极值。
- 相应的特征值定义方差探针$\psi(\mathbf{q}_j)$的极值

基于Hebb的主分量分析

广义Hebb算法(Generalized Hebbian algorithm，GHA)

考虑如图3-4-1所示的前馈网络，假设具有下面两个结构属性：
1.网络输出层的每个神经元是线性的
2.网络有m个输入和l个输出，它们都是指定的。另外，网络输出少于输入(即$l < m$)。

网络接受训练的仅有突触权值集$\{w_{ji}\}$，它们将输入层的源节点i和输出层计算节点j连接起来，其中$i = 1,2,\dots,m$和$j = 1,2,\dots,l$。

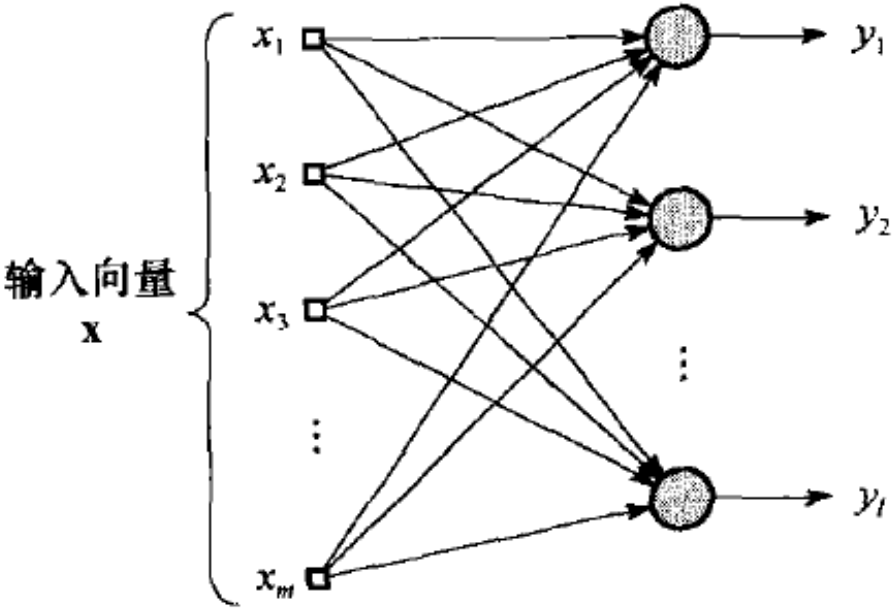

图3-4-1 仅有单层计算节点的前向反馈网络

基于Hebb的主分量分析

广义Hebb算法(Generalized Hebbian algorithm，GHA)

在时刻n神经元j对输入集$\{x_i(n)|i=1,2,\dots,m\}$的响应所产生的输出$y_i(n)$由下式给出(参看图3-4-2a)：

$$y_i(n)=\sum_{i=1}^{m} w_{ji}(n)x_i(n)\text{，}\ j=1,2,\dots,l \qquad (3\text{-}4\text{-}2\text{-}1)$$

根据Hebb学习的广义形式，修改突触权值$w_{ji}(n)$采用下式：

$$\Delta w_{ji}(n)=\eta\left(y_j(n)x_i(n)-y_j(n)\sum_{k=1}^{j} w_{ki}(n)y_k(n)\right), i=1,2,..,m; j=1,2,..,l \quad (3\text{-}4\text{-}2\text{-}2)$$

其中$\Delta w_{ji}(n)$是在时刻n对$w_{ji}(n)$的修改， η是学习率。

基于Hebb的主分量分析

广义Hebb算法(Generalized Hebbian algorithm，GHA)

将式(3-4-2-2)重新写成以下形式：

$$\Delta w_{ji}(n) = \eta\left(x_i'(n) - w_{ji}(n)y_j(n)\right), i = 1,2,..,m; j = 1,2,..,l \qquad (3\text{-}4\text{-}2\text{-}3)$$

其中$x_i'(n)$为输入向量$\mathbf{x}(n)$的第i个分量的修改形式；它是下标j的函数，表示为：

$$x_i'(n) = x_i(n) - \sum_{k=1}^{j-1} w_{ki}(n)y_k(n) \qquad (3\text{-}4\text{-}2\text{-}4)$$

将公式(3-4-2-3)重新写成Hebb的学习假设对应的形式，表示为：

$$\Delta w_{ji}(n) = \eta y_j(n)x_i''(n) \qquad (3\text{-}4\text{-}2\text{-}5)$$

其中

$$x_i''(n) = x_i' - w_{ji}(n)y_i(n) \qquad (3\text{-}4\text{-}2\text{-}6)$$

因此，注意到

$$w_{ji}(n+1) = w_{ji}(n) + \Delta w_{ji}(n) \qquad (3\text{-}4\text{-}2\text{-}7)$$

和

$$w_{ji}(n) = z^{-1}[w_{ji}(n+1)] \qquad (3\text{-}4\text{-}2\text{-}8)$$

z^{-1}是单位延迟操作符

基于Hebb的主分量分析

广义Hebb算法(Generalized Hebbian algorithm，GHA)

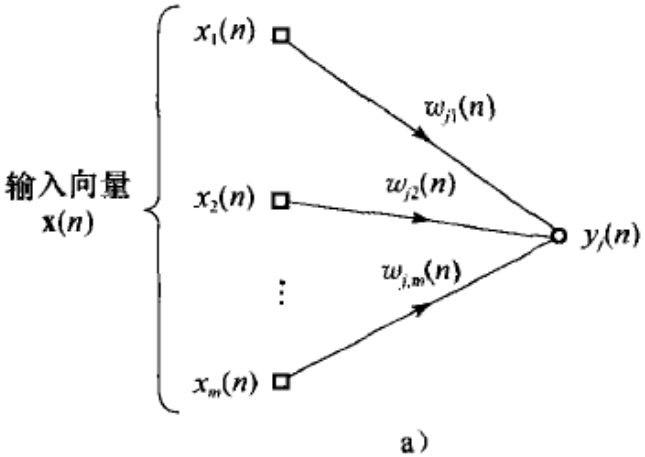

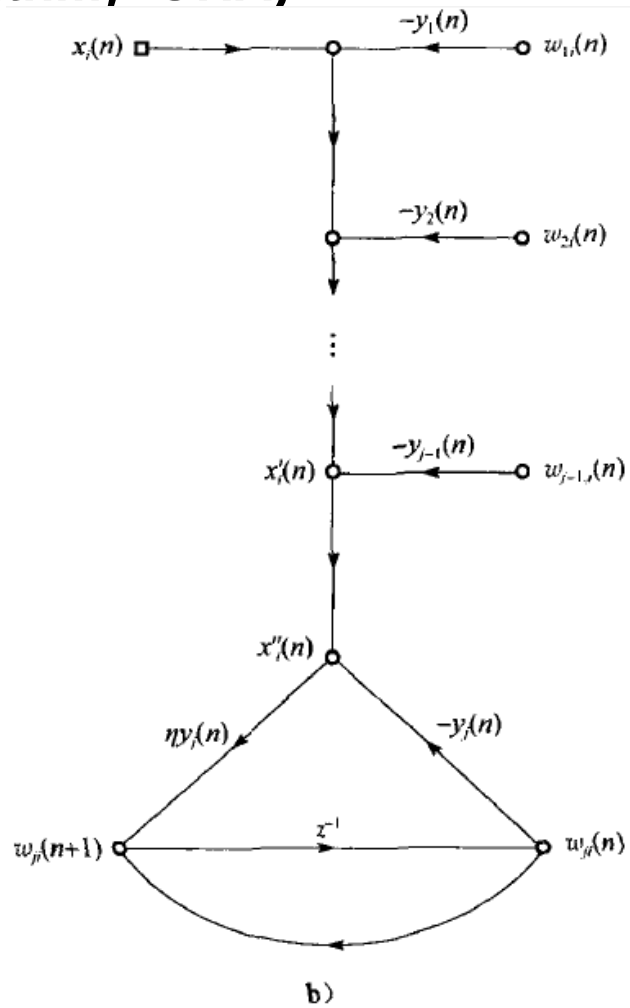

图3-4-2 广义Hebb算法的信号流图表示：a)式(3-4-2-1)的图；b)式(3-4-2-2)到式(3-4-2-3)的图，其中$x_i'(n)$和$x_i''(n)$由式(3-4-2-4)和式(3-4-2-6)定义

基于Hebb的主分量分析

广义Hebb算法(Generalized Hebbian algorithm，GHA)

利用矩阵形式重写式(3-4-2-3)定义的算法：

$$\Delta w_j(n) = \eta y_j(n)\mathbf{x}'(n) - \eta y_j^2(n)\mathbf{w}_j(n)，\ j = 1,2,\dots,l \qquad (3\text{-}4\text{-}2\text{-}9)$$

其中$\mathbf{w}_j(n)$是神经元j的突触权值向量，且：

$$\mathbf{x}'(n) = \mathbf{x}(n) - \sum_{k=1}^{j-1} \mathbf{w}_k(n)\, y_k(n) \qquad (3\text{-}4\text{-}2\text{-}10)$$

向量$\mathbf{x}'(n)$为输入向量$\mathbf{x}(n)$的修正形式，基于式(3-4-2-9)，有以下观察结果

基于Hebb的主分量分析

广义Hebb算法(Generalized Hebbian algorithm，GHA)

1.对于图3-4-1的前馈网络中的第一个神经元，有：

$$j=1:\ \mathbf{x}'(n)=\mathbf{x}(n)$$

在这种情况下，这个神经元将发现输入向量的第一个主分量。

2.对于图3-4-1的第2个神经元，有：

$$j=2:\ \mathbf{x}'(n)=\mathbf{x}(n)-\mathbf{w}_1(n)y_1(n)$$

如果第一个神经元已经收敛于第一个主分量，则第二个神经元看到第一个输入向量$\mathbf{x}'(n)$，从其中已经去掉相关矩阵$\mathbf{R}$的第一个特征向量，因此第二个神经元抽取的是$\mathbf{x}'(n)$第一个主分量，相当于原来输入向量$\mathbf{x}(n)$的第二个主分量。

3.对于第3个神经元，写出：

$$j=3:\ \mathbf{x}'(n)=\mathbf{x}(n)-\mathbf{w}_1(n)y_1(n)-\mathbf{w}_2(n)y_2(n)$$

假设前两个神经元已经分别收敛于第一个和第二个主分量，如前面两步的解释一样。第三个神经元的输入向量为$\mathbf{x}'(n)$，从其中已经去掉相关矩阵$\mathbf{R}$的前两个特征向量，因此第三个神经元抽取的是$\mathbf{x}'(n)$的第二个主分量，相当于原来输入向量$\mathbf{x}(n)$的第三个主分量。

长短期记忆神经网络

循环神经网络(Recurrent Neural Network, RNN)

循环神经网络(Recurrent Neural Network，RNN)是深度学习中一类非常重要且特殊的网络结构，它不仅考虑前一时刻的输入，而且网络还会对前面的状态进行“记忆”，因此，对于当前的输出，不仅与前一时刻的输出有关，还跟前一时刻所“记忆”的状态有关。RNN是在自然语言处理领域中最先被用起来的，比如，RNN可以为语言模型来建模。

https://zybuluo.com/hanbingtao/note/541458
零基础入门深度学习(5)—循环神经网络

长短期记忆神经网络

循环神经网络(Recurrent Neural Network, RNN)

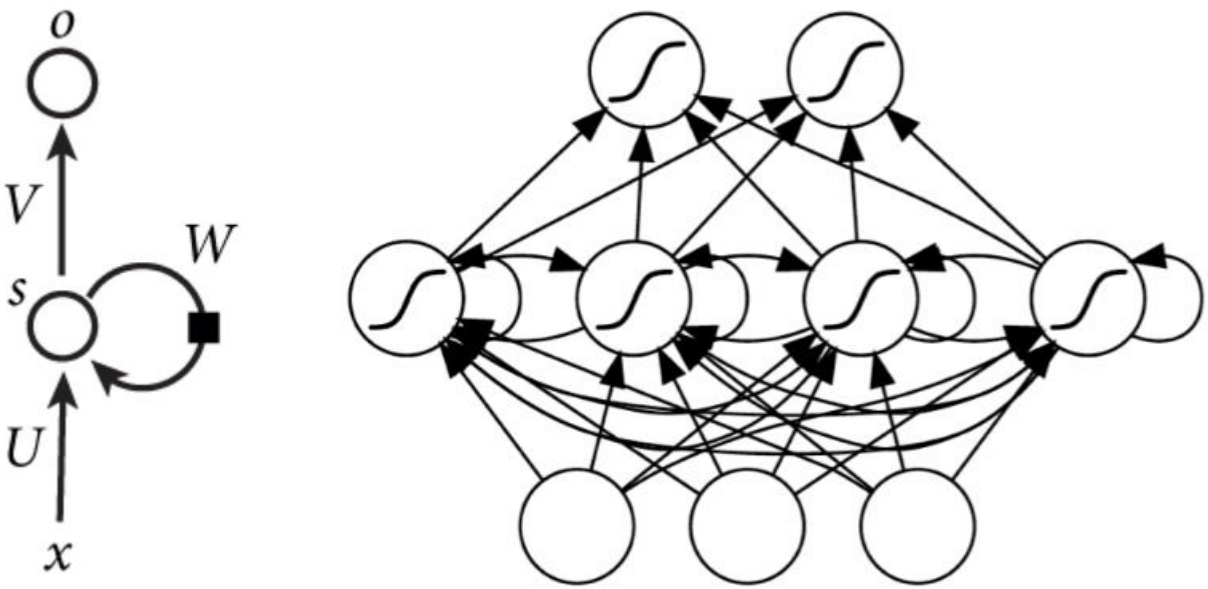

https://blog.csdn.net/qq_32241189/article/details/80461635
深度学习值RNN(循环神经网络)

长短期记忆神经网络

循环神经网络(Recurrent Neural Network, RNN)

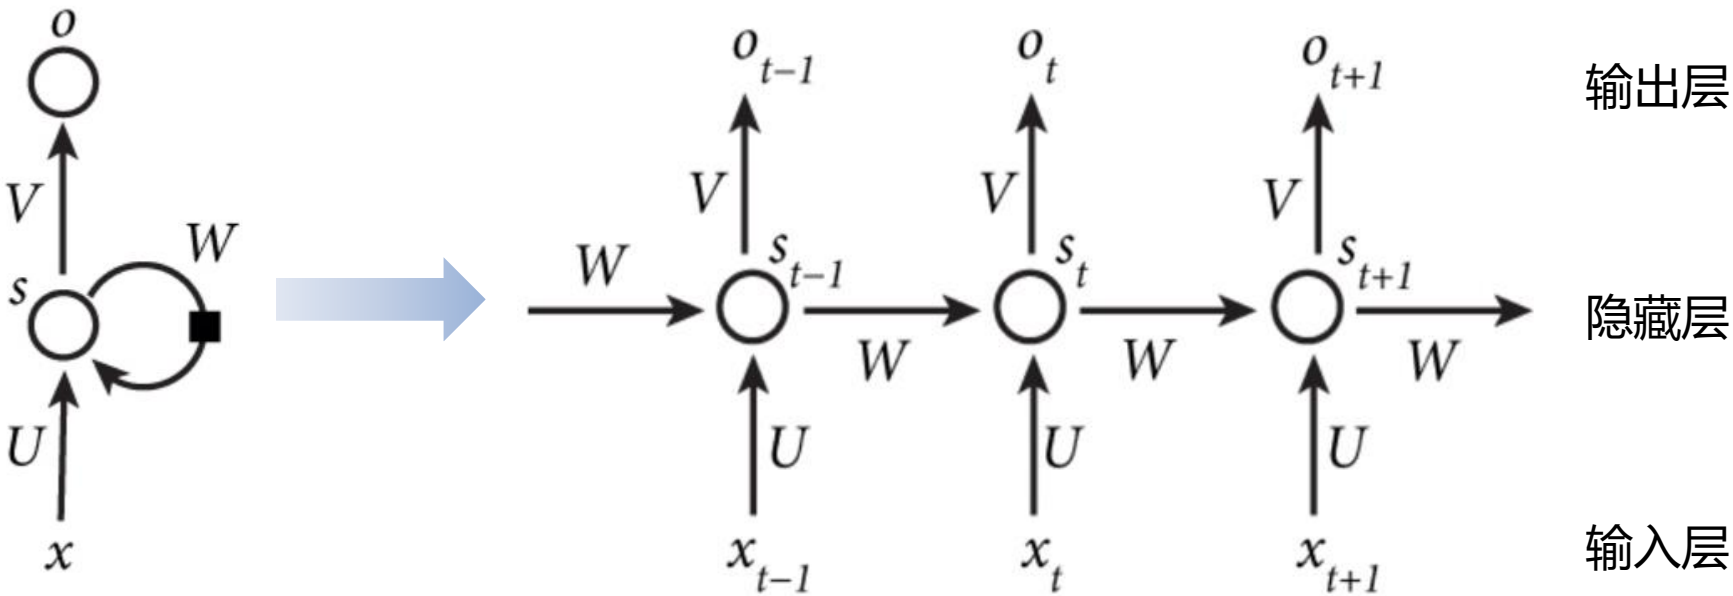

U是输入层到隐藏层的权重矩阵，V是隐藏层到输出层的权重矩阵， W是上一时刻隐藏层对此时刻的权重矩阵

https://zybuluo.com/hanbingtao/note/541458
零基础入门深度学习(5)—循环神经网络

长短期记忆神经网络

循环神经网络(Recurrent Neural Network, RNN)

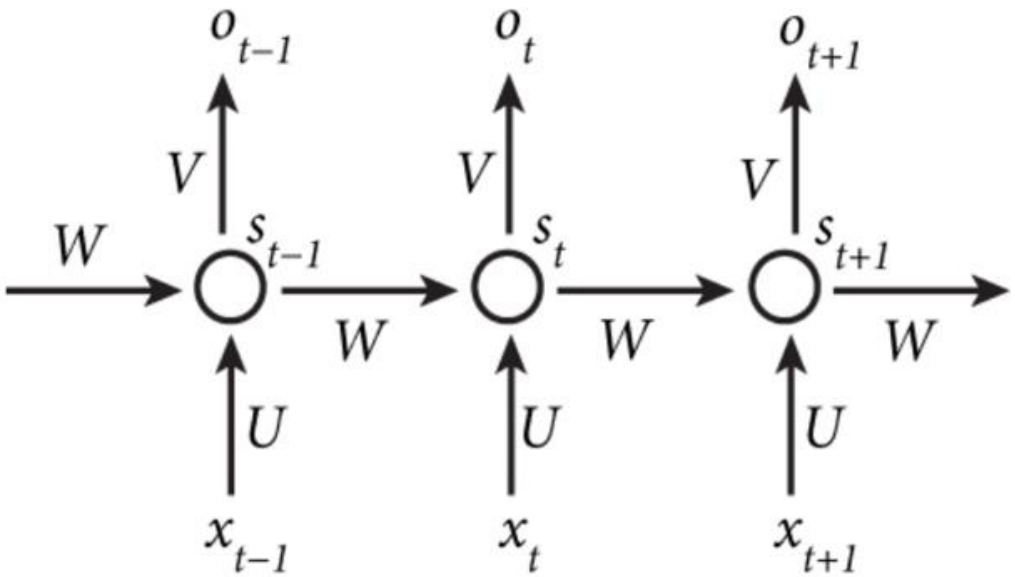

$$\boldsymbol{o}_t = g(V\boldsymbol{s}_t) \qquad (3\text{-}5\text{-}1\text{-}1)$$

$$\boldsymbol{s}_t = f(U\boldsymbol{x}_t + W\boldsymbol{s}_{t-1}) \qquad (3\text{-}5\text{-}1\text{-}2)$$

https://zybuluo.com/hanbingtao/note/541458
零基础入门深度学习(5)—循环神经网络

长短期记忆神经网络

循环神经网络(Recurrent Neural Network, RNN)

将式(3-5-1-2)反复代入式(3-5-1-1)得到:

$$
\begin{aligned}
\boldsymbol{o}_t &= g(V\boldsymbol{s}_t) \\
&= Vf(U\boldsymbol{x}_t + W\boldsymbol{s}_{t-1}) \\
&= Vf(U\boldsymbol{x}_t + Wf(U\boldsymbol{x}_{t-1} + W\boldsymbol{s}_{t-2})) \\
&= Vf(U\boldsymbol{x}_t + Wf(U\boldsymbol{x}_{t-1} + Wf(U\boldsymbol{x}_{t-2} + \cdots)))
\end{aligned}
$$

实际上，由于RNN对前面信息的长期依赖，在训练中很容易发生梯度爆炸和梯度消失，这导致训练时梯度不能在较长的序列中一直传递下去，因此RNN不能很好地处理较长的序列。

https://zybuluo.com/hanbingtao/note/541458
零基础入门深度学习(5)—循环神经网络

长短期记忆神经网络

长短期记忆神经网络(Long Short-term Memory，LSTM)

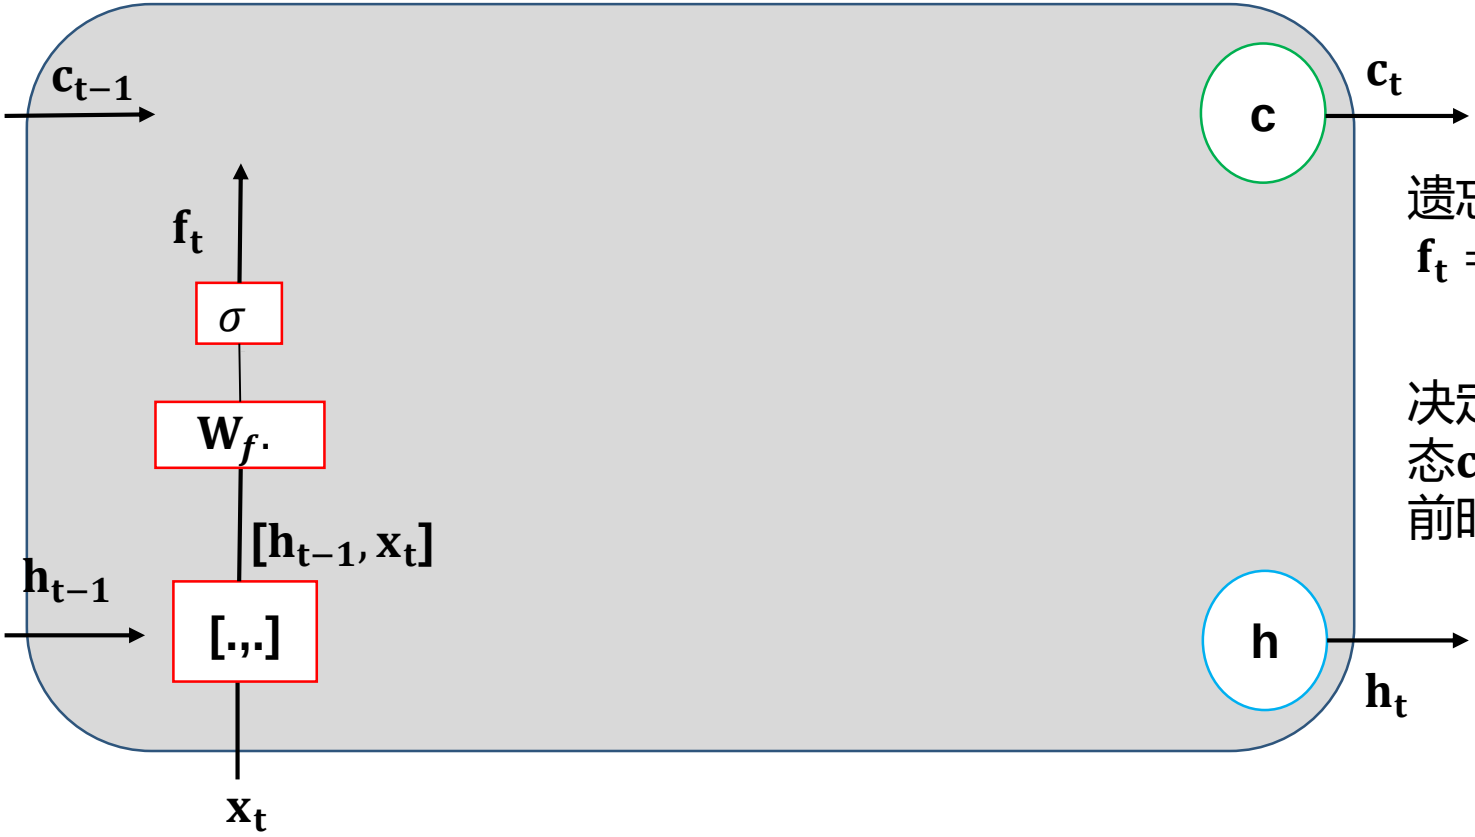

遗忘门:

$$f_t = \sigma(W_{f.}\begin{bmatrix} h_{t-1} \\ x_t \end{bmatrix} + b_f)$$

$$W_f = [W_{fh}, W_{fx}]$$

决定上一时刻单元状态c_{t-1}有多少保留到当前时刻c_t

https://www.jianshu.com/p/6cb6e1736b36
零基础入门深度学习(6)—长短时记忆网络

长短期记忆神经网络

长短期记忆神经网络(Long Short-term Memory，LSTM)

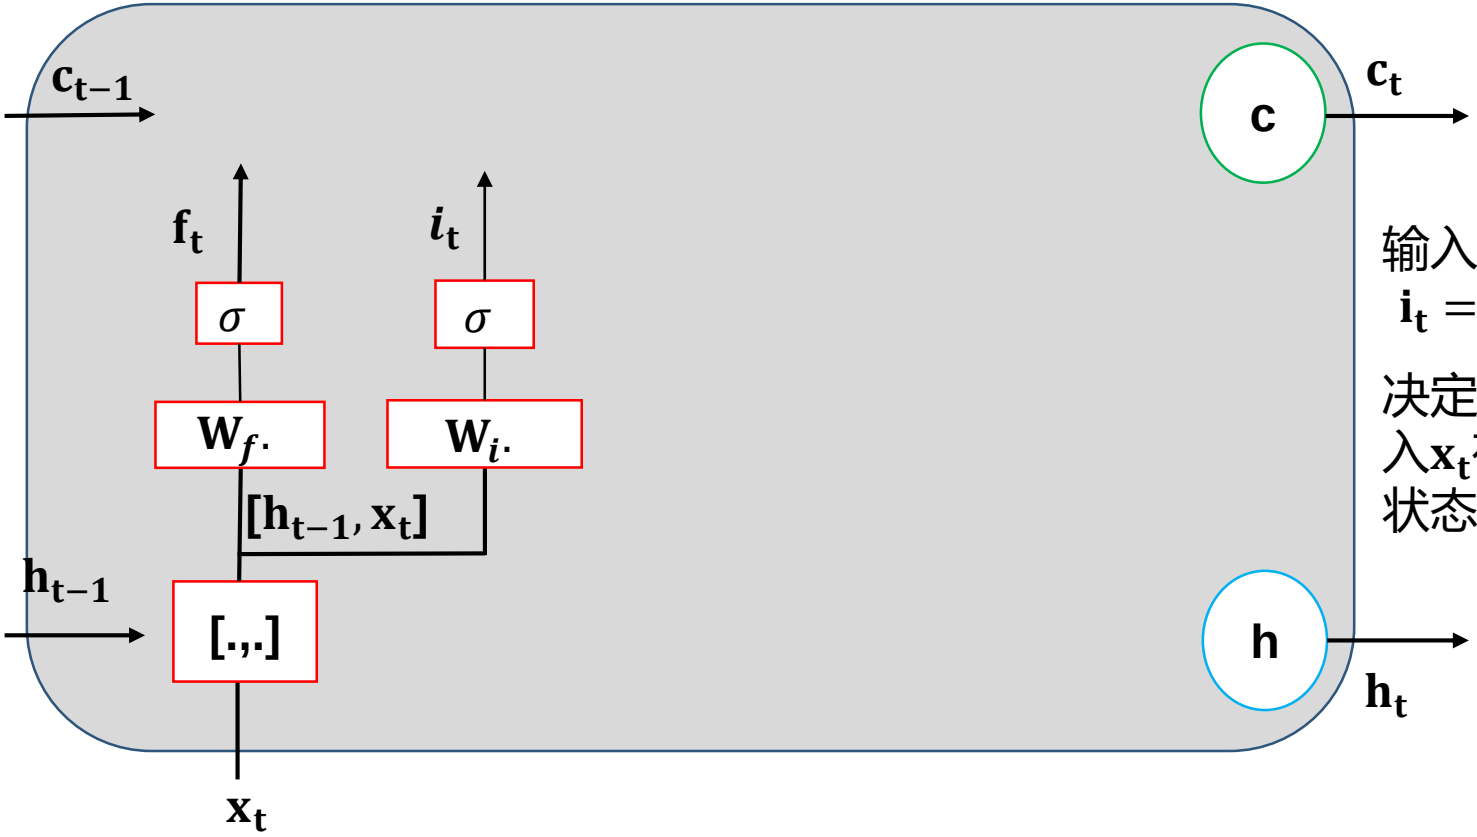

输入门：

$$\mathbf{i_t} = \sigma(W_{i.}\begin{bmatrix}\mathbf{h_{t-1}}\\ \mathbf{x_t}\end{bmatrix} + \mathbf{b_i})$$

决定当前时刻网络的输入$\mathbf{x_t}$有多少保存到单元状态$\mathbf{c_t}$

https://www.jianshu.com/p/6cb6e1736b36
零基础入门深度学习(6)—长短时记忆网络

长短期记忆神经网络

长短期记忆神经网络(Long Short-term Memory，LSTM)

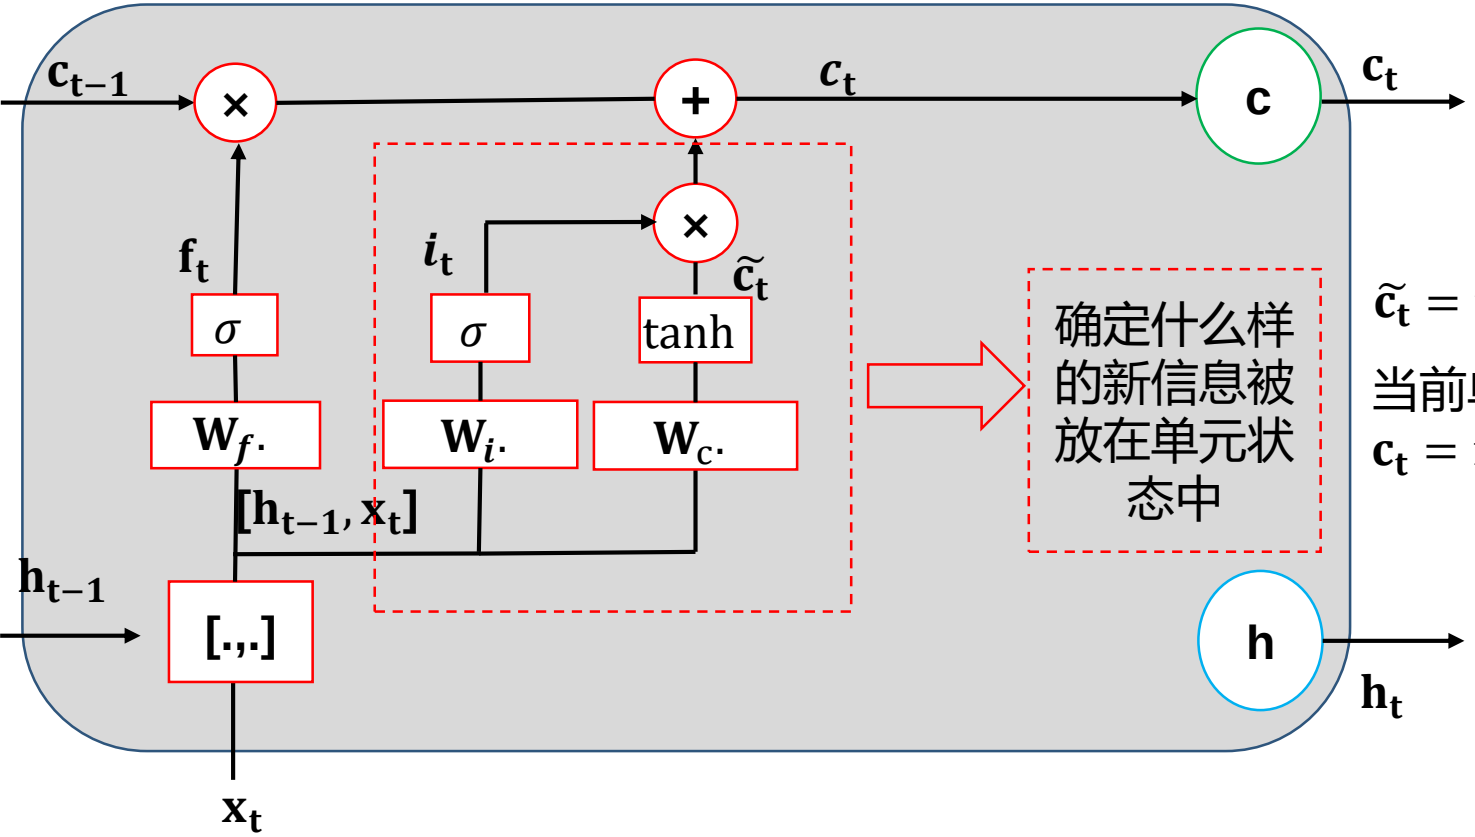

确定什么样的新信息被放在单元状态中

$$\tilde{c}_t = \tanh(W_{c\cdot}\begin{bmatrix} h_{t-1} \\ x_t \end{bmatrix} + b_c)$$

当前单元状态：

$$c_t = f_t \circ c_{t-1} + i_t \circ \tilde{c}_t$$

https://www.jianshu.com/p/6cb6e1736b36
零基础入门深度学习(6)—长短时记忆网络

长短期记忆神经网络

长短期记忆神经网络(Long Short-term Memory，LSTM)

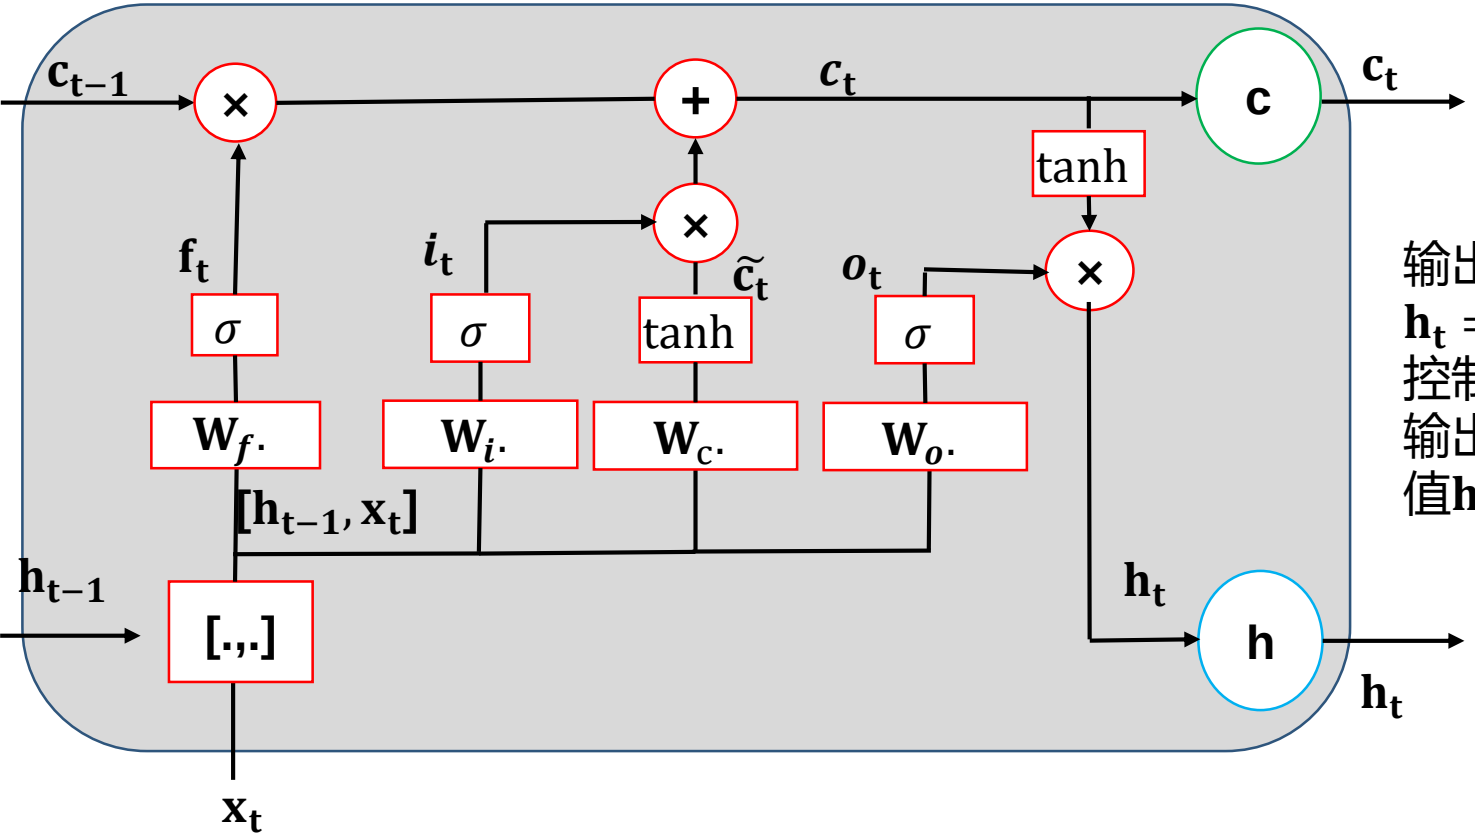

输出门：
$h_t = o_t \circ \tanh c_t$
控制单元状态c_t有多少输出到网络的当前输出值h_t

https://www.jianshu.com/p/6cb6e1736b36
零基础入门深度学习(6)—长短时记忆网络

长短期记忆神经网络

长短期记忆神经网络(Long Short-term Memory，LSTM)

LSTM利用反向传播进行训练：
1.前向计算每个神经元的输出值，即$\mathbf{f_t}$, $\mathbf{i_t}$, $\mathbf{c_t}$, $\mathbf{o_t}$, $\mathbf{h_t}$
2.反向计算每个神经元的误差项δ值，LSTM误差项反向传播包括两个方向：一个是沿时间反向传播，另一个是将误差项向上一层传播。
3.根据相应的误差项，计算每个权重的梯度。

https://www.jianshu.com/p/6cb6e1736b36
零基础入门深度学习(6)—长短时记忆网络

Thanks