认知科学与类脑计算

第五章 听觉信息加工

山东大学 吴强 副教授

本章要点

01 听觉系统的基本结构和功能

02 外围听觉神经系统的响应

03 听觉中枢系统的神经响应

04 听觉感受野的性质

05 鸡尾酒会问题和时频掩蔽

06 可计算听觉场景分析

01 听觉系统的基本结构和功能

听觉系统的基本结构和功能

A. 外耳和中耳

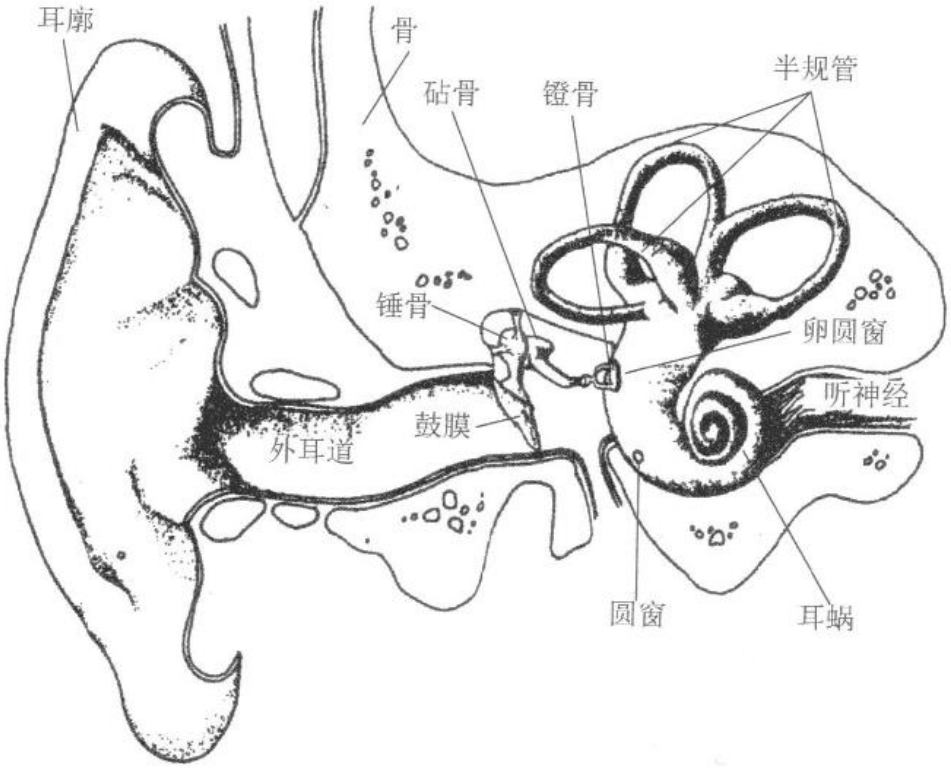

外周听觉系统的结构示意图，图中分别画出了外耳，中耳以及内耳。此图引自《人类的信息加工》（Lindsay&Norman,1972）

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

听觉系统的基本结构和功能

- 外耳包括耳廓和耳道。耳廓能显著改变入射声音，尤其是高频部分，这种改变对我们的声源定位能力非常重要。

- 中耳最重要的功能是保证声音道耳蜗的有效传递。从技术角度理解，中耳的作用类似于一个阻抗匹配器或转换器。在中频段（500~5000Hz），中耳对声音的传递效率达到最大（Puria et al., 1997;Aibara et al., 2001）。

- 听小骨上附着少量肌肉，这些肌肉在人耳暴露于强声时收缩。这种收缩被称为**中耳反射**，可能受脑干中的神经中枢控制。中耳反射会减少声音向中耳的传递，但仅对频率低于1500Hz的声音如此，尽管比该频率更高的声音也可以使之收缩。

- 有研究提出中耳反射还具有其他两个功能。
  一是降低自发声的可听度。二是减弱低频成分对中高频成分的掩蔽作用。

听觉系统的基本结构和功能

B. 内耳与基底膜

- 耳蜗被两个薄膜分隔开，这两个薄膜分别是赖斯纳氏膜和基底膜。
- 声音引起的基底膜运动是我们关注的重点。基底膜的力学特性会强烈影响其对不同频率声音的响应。对于高频声音，蜗底处基底膜的位移最大，其他部分的位移较小。对于低频声音，整个基底膜均会震动，但在蜗顶前振动幅度最大。右图给出了一些基底膜振动模式的空间包络，刺激信号为不同频率的低频正弦波。
- 耳蜗有一个重要特性，即不同频率的声音所对应的基底膜的最大位移的位置不同。耳蜗的作用实际上类似于傅里叶分析器，尽管其频率分析能力不够完美。引起基底膜特定点产生最大响应的频率被称为该位置的特征频率。

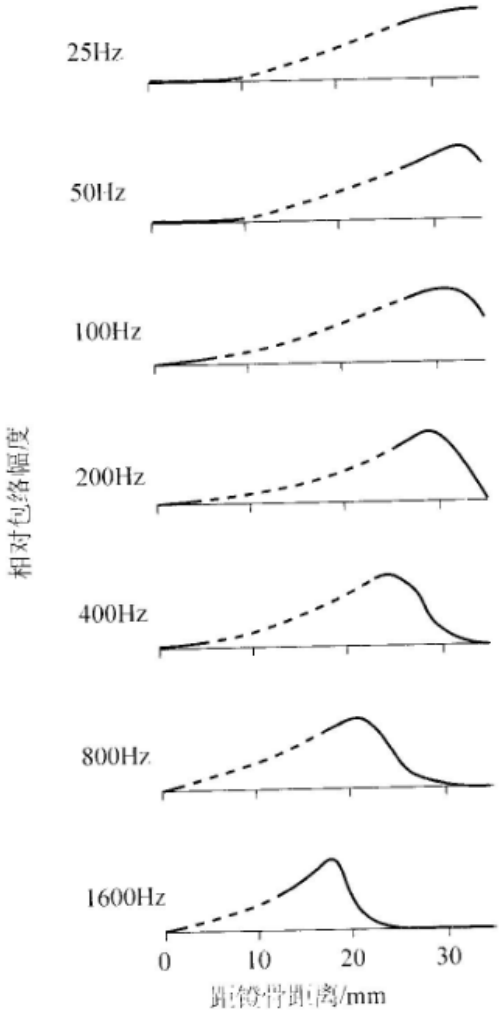

一系列低频正弦波对应的基底膜振动模式的包络。实线表示实际测量的结果，虚线为von Bekesy外推的结果

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

听觉系统的基本结构和功能

- 对响应稳定的正线刺激，基底膜上每点均以近似正弦波的形式振动，其振动频率等于正弦波的频率。

  例：声音刺激为1000Hz正弦波时，基底膜上可被检测到位移变化的点的振动频率也为1000Hz。

- 基底膜振动模式的调谐“锐度”有多种表示方法。相对带宽的倒数可以作为调谐锐度的度量指标，以Q（quality factor，品质因子）表示。通常假设Q由3dB带宽计算得到。但在测量基底膜响应和神经响应时，常使用10dB带宽。在这种情况下，调谐锐度的度量，记作$Q_{10\mathrm{dB}}$带宽。Q为4.35时，对应带宽为1/3倍频程。

- 关于基底膜振动模式的大部分开创性工作均出自 von Bekesy。von Bekesy利用光学显微镜和频闪照明测量了人尸体耳内基底膜上多点的振动幅度。近期有研究使用其他技术在活体动物上测量基底膜的振动，表明相比于von Bekesy的测量结果，新测得的调谐曲线更加锐利。

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

听觉系统的基本结构和功能

许多技术在活体生物上的测量结果表明动物的生理情况对基底膜的调谐锐度来说很关键，生理状况越好，调谐越锐利。下图给出了测量结果的示例。图中曲线表示使基底膜特定点产生恒定速度运动所需的输入声级（dB SPL）与刺激频率之间的函数关系（数据来自Sellick et al., 1982），该曲线通常被称为“恒速调谐曲线”。实验开始时，复合动作电位阈值很低，得到的调谐曲线（空心圆）很尖锐。随着动物的生理状况恶化，调谐曲线变宽，动物死亡后（实心方块）产生标准响应所需的声级在顶端附近显著增加。

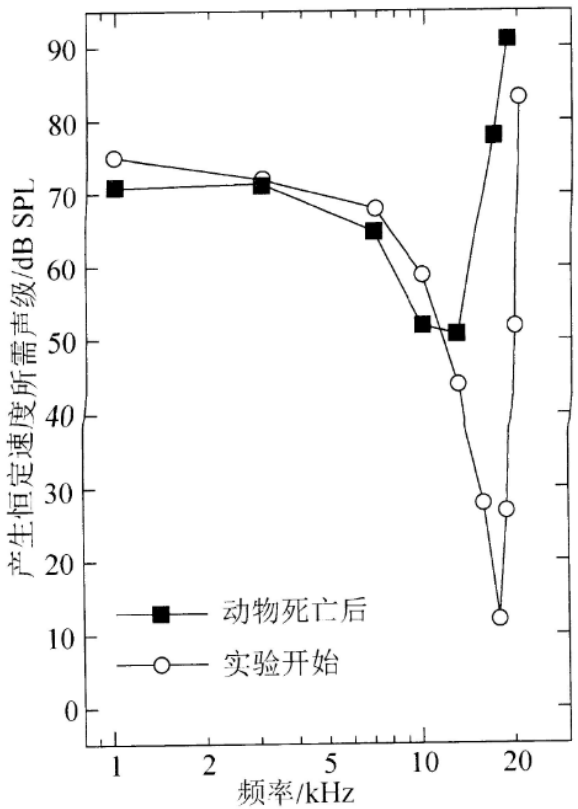

基底膜上单个点测得的调谐曲线。每条曲线表示使基底膜产生恒定速度的运动所需的声级（dB SPL）与频率之间的函数关系。实验刚开始时测量得到的曲线以空心圆标记，此时动物的生理状况良好。动物死后测量得到的曲线以实心正方形标注。数据引自 Sellick 等人 (1982）。

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

听觉系统的基本结构和功能

- 对于正常的健康耳，基底膜上每个点都是锐调谐的，对一定频率范围内的声音具有高敏感度，随着信号频率移出这一频率范围，引起该点响应所需的声级越来越大。$Q_{10\mathrm{dB}}$通常在3~10之间，相应地，带宽在1/2~1/8octave。

- 健康耳的基底膜振动具有非线性特性，其响应幅度不直接正比于输入幅度。

- 对于频率为特征频率的纯音而言，基底膜的响应在信号强度很低时（低于20dB SPL）几乎是线性的，在信号强度较高时（高于90dB SPL）接近线性，在信号强度中等时斜率较小。上述结果表明基底膜具有压缩的非线性，即变化范围较大的声级被压缩成变化范围较小的基底膜响应。

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

听觉系统的基本结构和功能

- 在基底膜的底部，当刺激频率接近基底膜上观测点的特征频率时，非线性占主导。当刺激的频率距特征频率较远时，响应变得更加线性。因此频率为 7kHz 和 9kHz（接近特征频率）的曲线具有较小的斜率，而频率低于 7kHz 和高于9kHz 的曲线具有更大（线性）的斜率。实际上，压缩仅在基底膜响应模式的峰值附近出现。实际上，压缩仅在荃底膜响应模式的峰值附近出现。

- 在基底膜的顶部，响应模式则有些许不同．有些研究中观察到了压缩响应，其中多数使用栗鼠作为实验对象（Cooper & Rhodc , 1995；Rhode & Coopcr ,1996）。但相对于底部，顶部的压缩程度更小且不十分依赖于刺激频率与特征频率间的相对关系，即所有频率的纯音的响应都受到近似同等程度的压缩。但耳蜗项端的基底膜响应仍存在不确定性，特别是蜗顶和蜗底中间的部分，因为这些部位相对难操作，直接观察基底膜的运动十分困难。相关评述可参阅 Ulfendahl (1997) , Robles 和 Rugero (2001），以及 Picklcs (2008）。

听觉系统的基本结构和功能

基底膜对声压突变信号（阶跃函数）或短脉冲的响应与其对正弦波的响应差别很大。上述刺激信号的频谱覆盖了较大的频率范围，因此基底膜上各位置均会响应该信号，这会在基底膜上形成一个沿基底膜移动的“鼓包”。有许多实验研究了基底膜上单个点对冲激信号的响应，该响应被称为“冲激响应”。下页图给出了 Rccio 等人（1998）测量的冲激响应。这些冲激响应看起来像不断衰减的正弦振荡并类似于带通滤波器的响应，尽管其衰减并不严格单调。

听觉系统的基本结构和功能

左图中，以绝对速度表示基底膜的响应，正如预料的那样，响应幅度随冲激强度的增加而增大。右图中，以冲激信号的声压表示基底膜的响应，响应随着冲激强度的降低而大幅增加。这反映了基底膜的输入—输出函数的非线性。冲激响应的振荡频率大致等于基底膜上观测点的特征频率。对高频响应幅度最佳的墓底膜的底端具有较高的振荡频率（如图所示），而对低频响应幅度最佳的顶端则具有较低的振荡频率。因此，冲激响应的波形随观测点在基底膜位置的改变而持续变化。

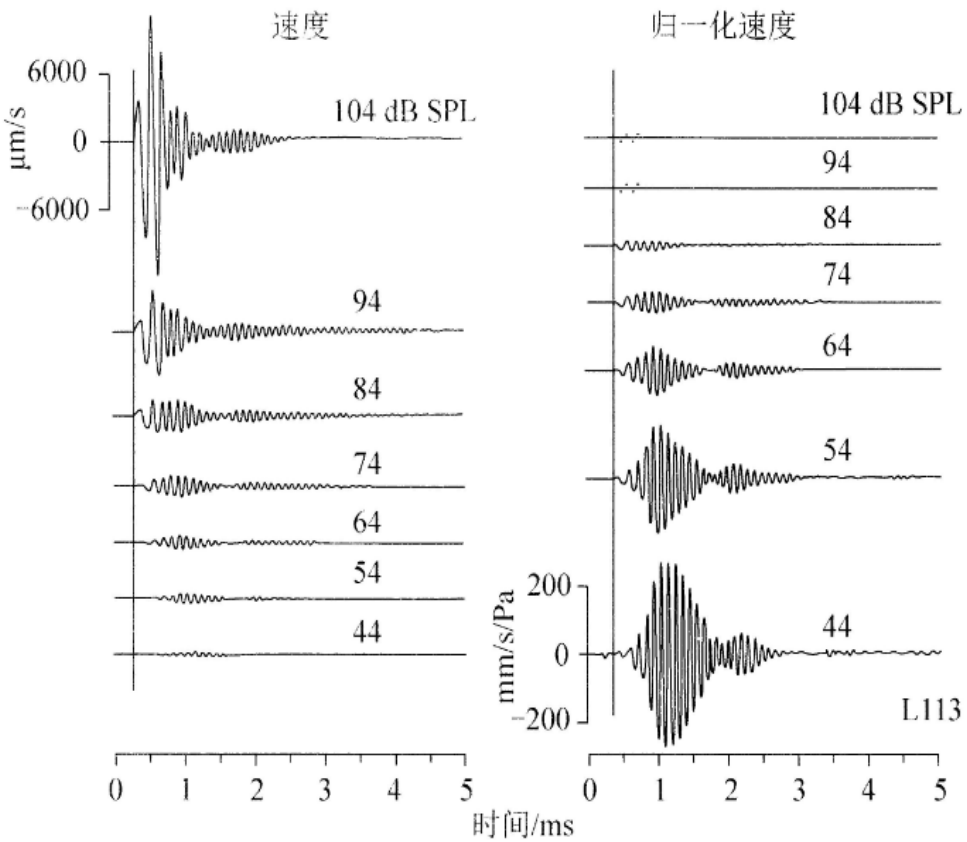

基底膜上一点对不同强度冲激信号的响应，该点特征频率为10kHz。左图中，以绝对速度表示基底膜的响应。右图中，以冲激响应的声压表示基底膜的响应，响应随着冲激信号强度的降低而大幅增加。

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

听觉系统的基本结构和功能

C. 转导过程与毛细胞

毛细胞位于丛底膜与覆膜之间，是柯蒂氏器的组成部分。毛细胞被一个称为柯蒂氏管的拱形通道分为两组，其中靠近耳蜗外部的部分被称为外毛细胞，猫耳的外毛细胞有三排，人耳的外毛细胞多达五排。在柯蒂氏管另一侧的毛细胞形成单独一排，被称为内毛细胞。每个细胞上都有数十根纤毛。

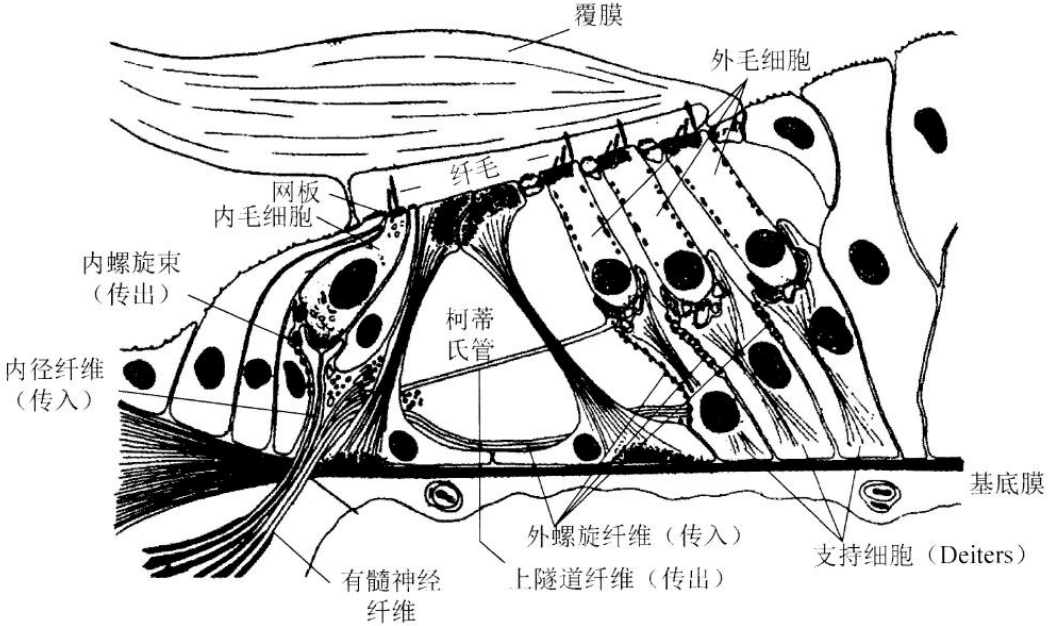

内毛细胞能将机械运动转化为神经活动，其纤毛之间通过细丝彼此连接，该细丝被称为“顶端链接”。大多数将耳蜗的信息传递至听觉高级皮层的传入神经元与内毛细胞相连接，每个内毛细胞大约与 20 个神经元接触。因此，大多数关于声音的信息是经内毛细胞传入听觉系统的。

外毛细胞的主要任务可能是主动地影响耳蜗的机能，以使耳蜗具有高灵敏度和锐调谐特性。

听觉系统的基本结构和功能

D. 耳声发射

有观点认为听觉系统中存在一个影响耳蜗机能的主动生理过程， Kcmp (1978) 首次发表的一个著名现象为该观点提供了证据支撑， Gold (1948）则在更早的时候预测到了该现象。播放低强度的咔嗒声后，利用密封于耳道中的传声器可以记录来自耳朵的声音。声音的开始部分似乎来自中耳的反射，但有些声音相对于咔嗒声的呈现时刻延迟了 5~60ms 。由于延时较大，基本能确定这些声音是由耳蜗自身的活动引起，而不是来自于中耳。这种声音被称为“诱发耳声发射”，有时也被称为“ Kemp声”或“耳蜗回声”。

总的来说，我们尚不清楚耳声发射产生的确切机制，但可以确定的是该声音的产生与耳蜗中的主动过程有关。这些过程中包含很强的非线性成分、具有生物 37 活性、生理脆弱，看来是与基底膜的灵敏度与锐调谐有关。

02

外围听觉神经系统的响应

外围听觉神经系统的响应

每条听神经中包含约30 000个神经元，它们能将耳蜗中的信息传递至中枢神经系统。每一个神经元均以短电脉冲的形式传递信息，这种能沿轴突传导的电脉冲被称为动作电位、神经兴奋或神经发放。神经发放有时也被描述为神经元“放电”。对一个给定的神经元，每次发放的幅度固定，其传递的信息被编码为神经发放的数量和时刻。大多数关于听神经活动的研究会使用末端极细的电极，即微电极，这些电极能够记录单条听神经纤维（通常称作一个单元）中的神经发放。

对于大多数哺乳动物而言，有三个一般性的结论。
第一，无声音刺激时，听神经纤维中存在自发的神经发放．其发放速率的大致范围是每秒0～150 次。
第二，神经纤维对于某些频率的响应更强，即神经纤维具有频率选择性。
第三，神经纤维具有锁相性，听神经倾向 于在刺激信号的相位为一定值时发放，周期信号对应的神经发放模式具有时间规律。下面将分别介绍这些现象。

外围听觉神经系统的响应

A. 神经发放率和阈值

Liberman (1978）的工作表明听神经纤维按其自发放率可被分为三类。大约 61%的神经纤维的自发放率较高（每秒18~250 次）；约 23 %的神经纤维的自发放率居中（每秒0.5~18次）：约 16 %的神经纤维的自发放率较低（少于每秒0.5次）。自发放率与内毛细胞上突触的位置和大小有关。高自发放率对应大的突触，这些突触主要位于内毛细胞朝向外毛细胞的一侧。低自发放率与较小的突触相关，位于毛细胞的另外一侧。能使神经元响应发生可测量变化的最小声强值被称为该神经元的阈值。高自发放率的神经纤维的阈值通常较低，反之亦然。最敏感的神经元的阈值接近0dB SPL，而最不敏感的神经元阈值接近80dB SPL，甚至更高。

外围听觉神经系统的响应

B. 调谐曲线和等速率曲线

单个神经纤维的频率选择性通常由调谐曲线表示，即神经纤维的阈值关于频率的函数。该曲线也被称为频率一阈值曲线（FTC）。测量神经纤维的调谐曲线时，为了使发放率的改变更容易被检测到，通常使用短纯音作为刺激信号，而非连续纯音。使神经纤维阈值最低的信号频率被称为该纤维的特征频率。右图给出了些典型的调谐曲线。在对数尺度下，调谐曲线的高频侧通常比低频侧更陡。通常认为，由于单个神经纤维仅响应基底膜上某个位置的振动，因此其具有频率选择性。对调谐曲线已知的神经元的追踪实验直接证实了这一假设。此外，听神经的特征频率有序分布。特征频率较高的神经纤维被发现位于神经束的外周，特征频率沿神经束的径向方向逐渐减小。这种组织结构被称作拓扑结构，它表明频率在基底膜上的位置表征被保留为听神经上的位置表征。基底膜调谐曲线的锐度本质上与听神经中单个神经元的调谐曲线的锐度相同。

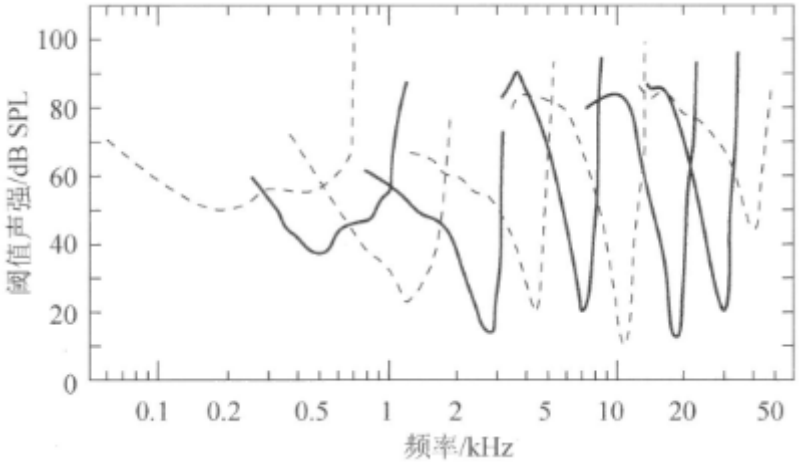

听神经中单个神经元的调谐曲线（也被称为频率一闽值曲线）的测最结果示例，39 测量对象为被麻醉的猫。摊条曲线代表一个神经元的测量结果，曲线表示发放阔值与刺激频率（对数尺度）间的函数关系。

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

外围听觉神经系统的响应

B. 调谐曲线和等速率曲线

等速率曲线可以描述单个神经纤维的阈上特征，该曲线表示使神经纤维的发放速率达到预定值的纯音强度与纯音频率间的函数关系。等速率曲线的形状和调谐曲线相似，尽管在高声强下等速率曲线有时更平缓。另一种描述神经纤维阈上特征的方法是测量相同声强、不同频率的纯音对应的神经纤维的发放速率，由该方法得到的曲线（等声强曲线）的形状通常随所选声强改变且明显不同于调谐曲线（下图）。等声强曲线较难解释，这是因为其形状取决于神经纤维的发放率如何随声强变化，而它通常不是线性函数。

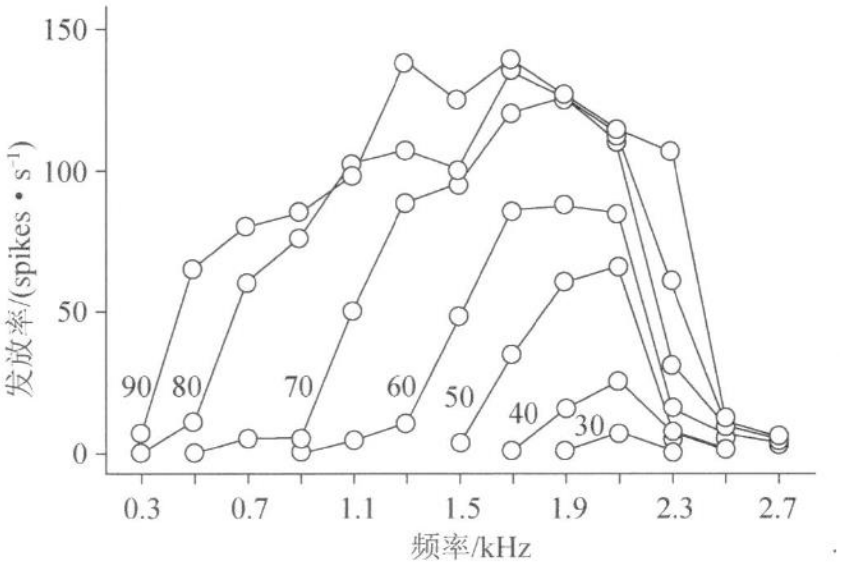

听神经中单个神经元的等声强曲线，测徽对象为麻醉的松鼠猴。曲线附近的数字表示该曲线对应的刺激声强（dB SPL）。需要注意的是，最大发放率对应的刺激频率值随刺激强度变化。

外围听觉神经系统的响应

C. 发放率与声级的函数关系

右图给出了三种听神经纤维的放电速率随着刺激声强变化的模式，这些曲线叫作发放率—声级函数。在每种情况下，刺激均为正弦信号且频率等于神经元的特征频率。对于曲线（a），该曲线典型地反映了高自发放速率神经元的测量结果。高于某一声级时，神经元的发放率不再随声级的增大而增大，即神经元达到饱和状态。阈值和刚出现饱和现象的声级之间的范围被称作动态范围。对于高自发放率神经元，动态范围通常很小，约为15~30dB。曲线（b）典型地反映了中自发放速率神经元的测量结果。相比于（a），曲线（b）对应的阈值更大、动态范围更宽。曲线（c）典型地反映了低自发放速率神经元的测量结果，该曲线对应的闽值高于（b）所对应的阂值。在（c）中，发放速率首先随着刺激声级的增加而快速增大，之后增速变缓。发放速率在很宽的声级范围内随刺激声级的增加而逐渐增加，这被称作“斜率饱和”。

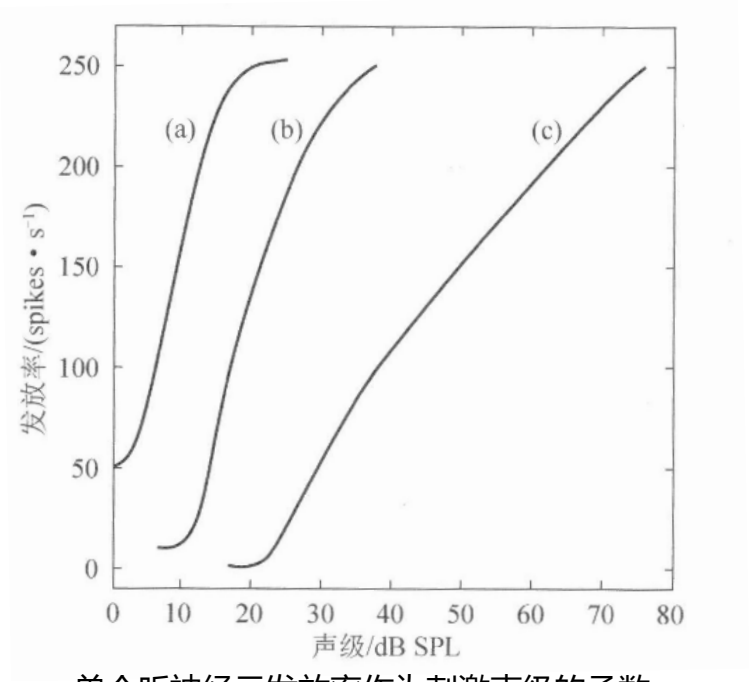

单个听神经元发放率作为刺激声级的函数示意图。图中曲线被称作发放率声级函数。在每种条件下，刺激频率等于神经元特征频率。曲线（a），（b）和（c）分别对应高、中和低自发放速率神经纤维的典型测量结果。

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

外围听觉神经系统的响应

C. 发放率与声级的函数关系

发放率一声级函数形状在三种情况下的差异可通过两个函数进行，如下图。第一个函数是基底膜的输入一输出函数，见右上图。第二个是基底膜的位移或速度与目标神经元的发放率之间的映射函数，见左图。除了较低阈值的神经元具有较高的自发放率外，不同的神经元的第二个函数在形式上相似。对于左图，当基底膜的幅度高出发放阈值对应的幅度一定倍数后，所有三个函数都展现出了饱和特性（事实上，不同神经元的饱和发放率存在些许差别）。

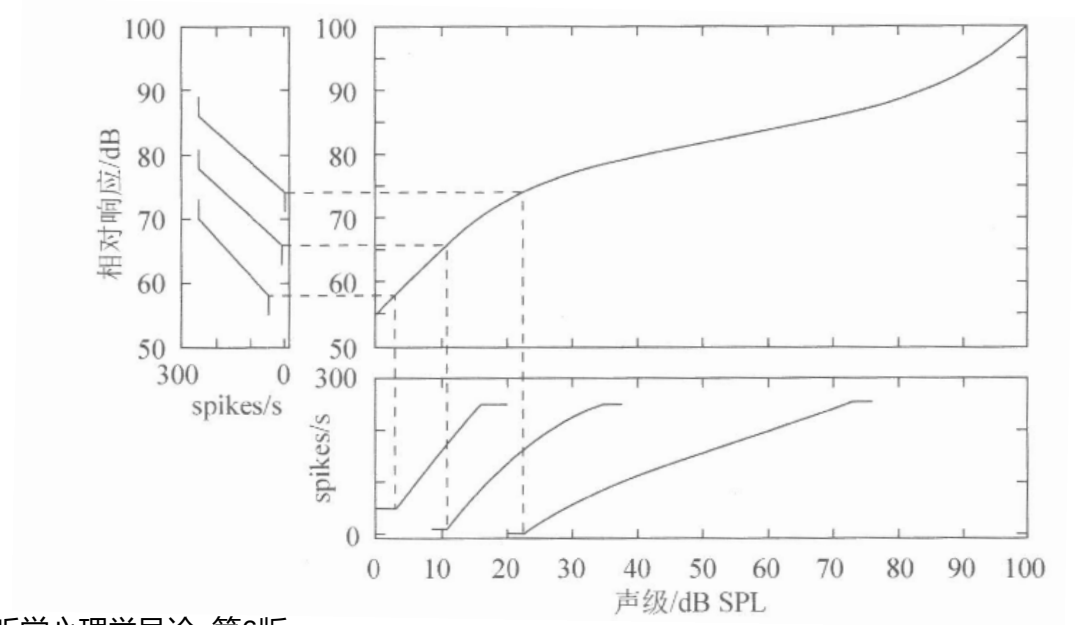

根据基底膜输入一输出函数（右上图）和神经发放率一基底膜振动幅度函数（左图），解释发放率-声级函数形状的示意图，三条曲线分别对应不同敏感度的神经突触。下图给出了由基底膜输入一输出函数、神经发放率一基底膜振动幅度函数得到的三条发放率一声级函数。

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

外围听觉神经系统的响应

C. 发放率与声级的函数关系

不同神经元之间的差异可能主要取决于突触的类型．如之前讨论的那样。较低阈值的神经元具有较强敏感度的神经突触。它们在非常低的声级条件下就开始进行响应，此时基底膜上的输入一输出函数是接近线性的。随着声级的增加，基底膜的位移线性地增加，神经元相对较早地发生了饱和，故动态范围较小，如上页图下子图中最左侧的曲线。阈值较高的神经元具有敏感度较弱的神经突触。它们响应的声级范围正是基底膜输入一输出函数展现出很强的压缩非线性的范围。因此，需要声级较大的增加，才能增加基底膜对于神经元饱和点的位移量。并且神经元的动态范围很宽，如上页图下子图中最右侧的曲线。

外围听觉神经系统的响应

D. 神经兴奋模式

发放率关于特征频率的函数有时被称为“兴奋模式”。然而，表征神经元的发放率较难，这是因为不同神经元的自发频率和最大发放率差异较大，即使其特征频率相同。因此，兴奋模式最多只能描述给定特征频率的神经元的平均响应。使用另一种方式表示兴奋模式可以部分地解决该问题，即对每个特征频率规定一个有效输入声级，称作兴奋声级。假定我们需要确定声音S对特征频率为 CF 的神经元的兴奋声级。为此，首先交替呈现声音 S 和频率为 CF 的纯音，调整纯音的声级直至其与声音 S 诱发神经发放速率相同，此时纯音的声级即为声音 S 在该特征频率下兴奋声级的估计。当刺激强度大于神经元的阈值但不至于使其饱和时，对于灵敏度不同的神经元（特征频率相同），上述方法估计得到的兴奋声级相似。对不同特征频率的神经元重复上述过程，兴奋声级关于特征频率的函数曲线即是兴奋模式。

概括来说，兴奋模式是表示刺激诱发的有效兴奋量与神经元特征频率间的函数关系，即有效声级（以分贝为单位）随特征频率的变化曲线。通常，特征频率轴为对数尺度，这与频率在基底膜上的表示方式基本一致。

外围听觉神经系统的响应

E. 锁相

在对纯音的响应中，神经纤维的发放倾向于锁相或同步于刺激的波形。听神经纤维并不一定在刺激信号的每个周期内均产生神经发放，但是每次发放时均大致出现在刺激波形的同一相位。因此，发放的时间间隔（大约）是刺激周期的整数倍。比如，500Hz正弦波信号的周期是2ms，由此声音诱发的神经发放的时间间隔约等于2,4,6,8 ms 。神经元不会严格按照某种模式发放，因此其发放速率不能精确等于每秒 500、250或 125 次。然而，单个神经元发放的时间模式明确地包含了刺激波形的周期信息。锁相恰好是可由转导过程预测的结果。基底膜朝向覆膜运动会使内毛细胞上的纤毛发生弯曲并最终引起神经兴奋．而基底膜反方向的运动并不会引起神经兴奋。

相邻神经发放的时间间附的统计直方图可以很好地展示单个听神经纤维的锁相特性。下页图给出了特征频率为1.6kHz 的神经元的多个峰间隔（interspike interval，ISI）直方图。

外围听觉神经系统的响应

E. 锁相

对于每个刺激频率（在本例中，为0.408~2.3kHz），相邻神经发放的时间间隔主要分布于纯音周期的整数倍上，这些时间间隔在图中以坐标轴下的点标出。尽管神经元不在刺激的每一个周期内都产生神经发放，但是相邻神经发放的时间间隔的分布与刺激频率密切相关。需要注意到，对于较高的刺激频率，如2kHz，ISI直方图中的第一个峰并没有出现在刺激频率对应的周期处（如0.5ms），这被称为神经不应性。一次神经发放产生之后，一段时间内神经元无法产生下一次神经发放，这段时间被称为绝对不应期，通常持续0.5~0.75ms。在此之后的一段时间内，神经元可以生成下一个神经发放但概率下降，这段时间被称为相对不应期，持续2~3ms

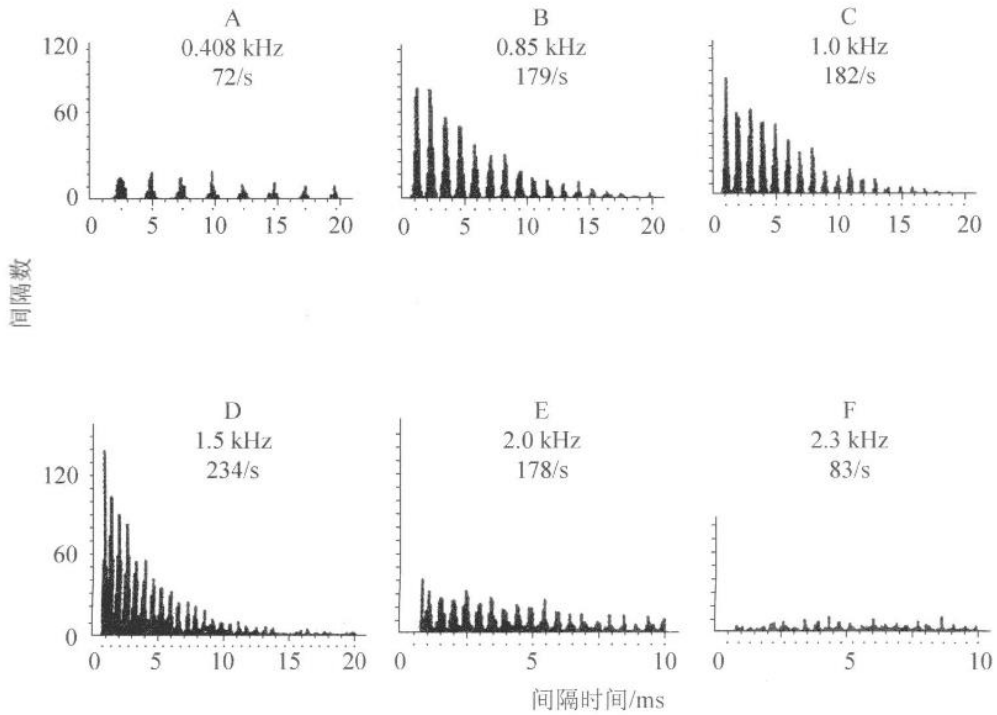

单个听觉神经元（松鼠猴）的峰间隔直方图，神经元的特征频率为1.6kHz。在每个直方图的上方分别标出了刺激纯音的频率和平均响应速率（spikes/s）。所有纯音的声级为80 dB SPL，持续时间为1s。需要注意的是，图E和图F中的时间尺度与A~D中不同。

外围听觉神经系统的响应

F. 双音抑制

许多研究调查了听神经对两个纯音的响应。一个惊人的发现是纯音诱发的单一神经纤维的响应会因第二个纯音的出现而被抑制，这种现象将其称为“双音抑制”（two-tone suppression）。右图对双音抑制进行了说明。典型的研究该现象的方式是，播放频率等于或接近神经元特征频率的纯音，其声强高于神经元阈值 10dB，如右图中的三角形所示。然后播放第二个纯音，改变该纯音的频率和声强并记录其对神经响应的影响。当第二个纯音的频率和声强落入了以调谐曲线为边界的兴奋区域时，神经发放率通常会增加。然而，当其落在该区域之外，第一个纯音引起的响应会下降或者说受到抑制。通常，在两个抑制区域内．当第二个纯音的频率稍微高于或低于兴奋区域时，抑制作用最大。双音抑制的建立和消失都非常快，仅需几毫秒。因此，双音抑制不太可能依赖于神经连接。事实上，有充分的证据表明，抑制发生在基底膜上。

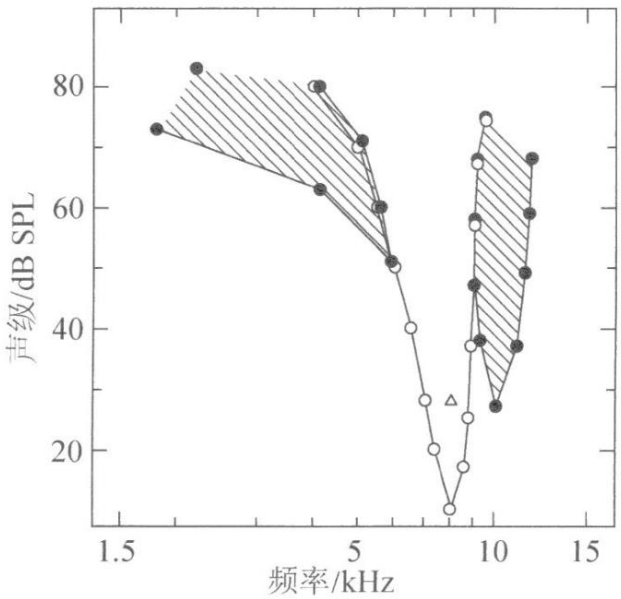

空心圆表示特征频率为8kHz 单一神纤元的调谐曲线（阈值 vs．频率）。神经元的刺激信号为频率等于其特征频率且声强略高于其阈值的纯音。然后呈现第二个纯音并改变其频率和强度。在以实心圆为边界的阴影区域内的纯音会减小特征频率纯音20％或更多的响应，该区域即为抑制区域。数据来自 Anhur 等人（1971）。

外围听觉神经系统的响应

G. 对复杂声音的锁相

Brugge 等人（1969 ）研究了听觉神经对频率具有简单比例关系（即谐波关系）的成对纯音的响应。他们得到了以下结论： ① 当基底膜仅在一个方向上移动时，听神经才会兴奋；② 神经发放时基底膜的位移朝向覆膜； ③ 有效的刺激波形可以通过正弦成分的叠加来近似得到，尽管所需的幅度和相位关系通常不能直接从实际的刺激参数中得到。 Brugge等人的结果表明即使当两个纯音的频率差距很大时（纯音频率比最大为 7：1)，二者之间的相互作用仍然存在。

外围听觉神经系统的响应

H. 自适应

当一个声音开始播放时，对该声音响应的神经发放率首先很高，随后快速衰减。这一效应被称作自适应，下图展示了使用单一神经元的刺激后时间直方图。刺激信号是一段 80ms 的宽带噪声脉冲，信号突然开始和结束，声级为 53dB SPL 。在声音开始之前，神经元具有中等程度的自发放活动。开始播放声音后，发放率快速增加然后速率逐渐下降。声音结束后的很短时间内，发放率降至自发放率值以下，之后恢复正常。使用较长声音刺激的实验表明自适应阶段能够在刺激开始之后持续数秒甚至数分钟。

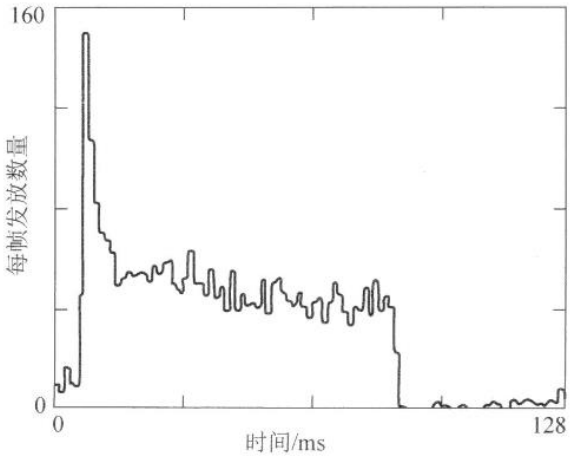

单一神经元对80ms宽带噪声脉冲响应的刺激后时间直方图，声音突然开始和结束，声级为53dB SPL。

听觉心理学导论 第6版
Brian C.J. Moore著 陈婧 吴玺宏 迟惠生译
北京大学出版社，2018.1

03

听觉中枢系统的神经响应

听觉中枢系统的神经响应

众所周知，视觉系统中的神经元会优先对刺激的某些特定做特征出反应，如特定方向的线条、移动或颜色，似乎存在具有层级结构的神经检测器。视神经中的信息在视觉系统中的不同层级被记录和加工，皮层神经元的响应和视神经上的响应相差很大。

听觉系统中的情况大致相同．不同的是在脑干和皮层一级，我们尚不清楚刺激信号的哪些关键特征能够引起给定神经元或神经元组的响应。

相对于简单的频率和强度，皮层似乎参与分析了更加复杂的刺激特性。许多皮层神经元根本就不对稳定的纯音做出响应，而那些对纯音有响应的神经元的调谐特性，又倾向于和初级听觉神经元表现的特征不同。一些神经元展示出了非单音调的发放率 — 声级函数，不同的神经元具有不同的“最适”声级。 Abeles 和 Goldstein (1972）发现三种不同类型的调谐特征：窄、宽和多范围（对若干倾向性频率都有响应）。他们认为这一结果揭示了一种分层结构，即若干窄范围神经元汇聚到某个多范围的神经元。皮层是按照频率拓扑组织的，但是具有多个拓扑“图”，每一个都专门分析除频率之外的特殊刺激特征。

听觉中枢系统的神经响应

Evans（1968）以未被麻醉的猫为研究对象，记录到 20%的皮层神经元仅对复杂刺激做出响应，如咔嗒声、噪声脉冲或“接吻”声。对于能对音调刺激产生响应的神经元，其中的 10%仅在音调频率发生改变的情况下才有这样的现象。 Whitfield 和 Evans（1965）报道了频率调制的纯音对于大多数能对纯音产生响应的神经元是非常有效的刺激。许多神经元的响应展现出了对频率变化特定方向的优先选择性。这些神经元被称为“扫频检测器”。一些神经元优先对特定的调制速率或特定的扫频速率产生响应。对其他神经元，重复速率和音调刺激的持续时间是很重要的参数。在所有被研究的神经元中， 17%仅对音调刺激的起始产生响应，而 10%仅对刺激的终止产生响应， 2%对起始和终止都产生响应。超过 50%的神经元对空间中声源的特定位置是优先选择或特别敏感的。这一普遍性的发现被 Bruggc 和 Merzenich（1973）在被约束的且未被麻醉的猴子身上证实并推广。他们发现许多神经元对双耳时间差或强度差是敏感的。在低频处，发放次数是双耳时差的周期性函数。在一些微电极穿透实验中，临近的细胞对于相同的双耳时差是最敏感的。一些细胞对于声压级约 20dB 以内的小的双耳偏差是敏感的。

04 听觉感受野的性质

听觉感受野的性质

复杂环境下的声音

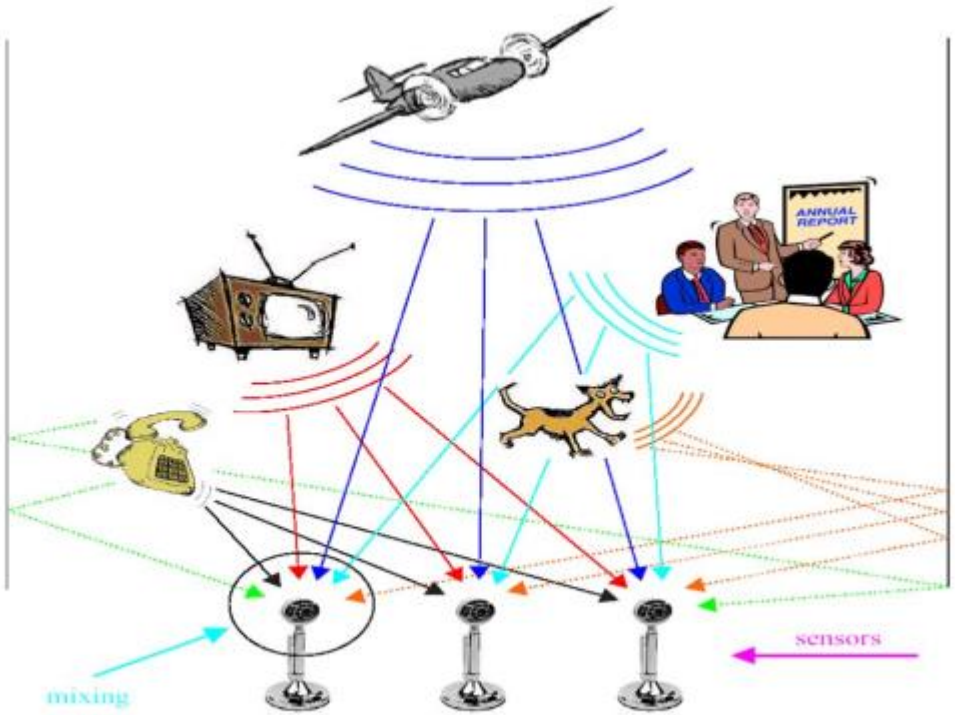

听觉感受野的性质

外界对源信号的干扰

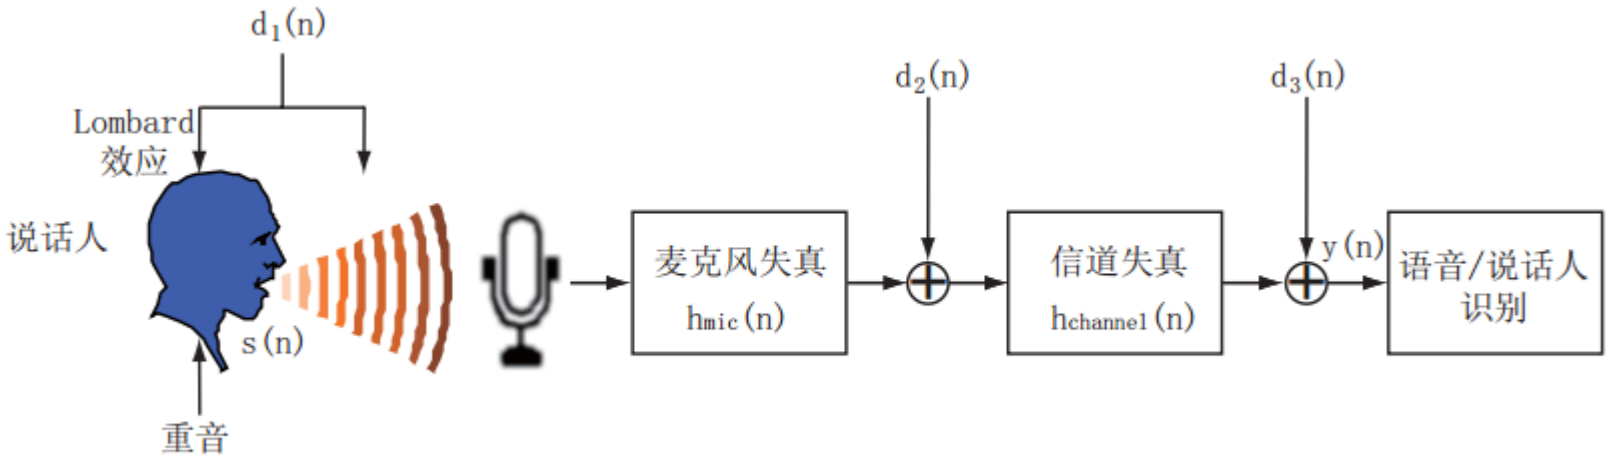

听觉感受野的性质

听觉通路

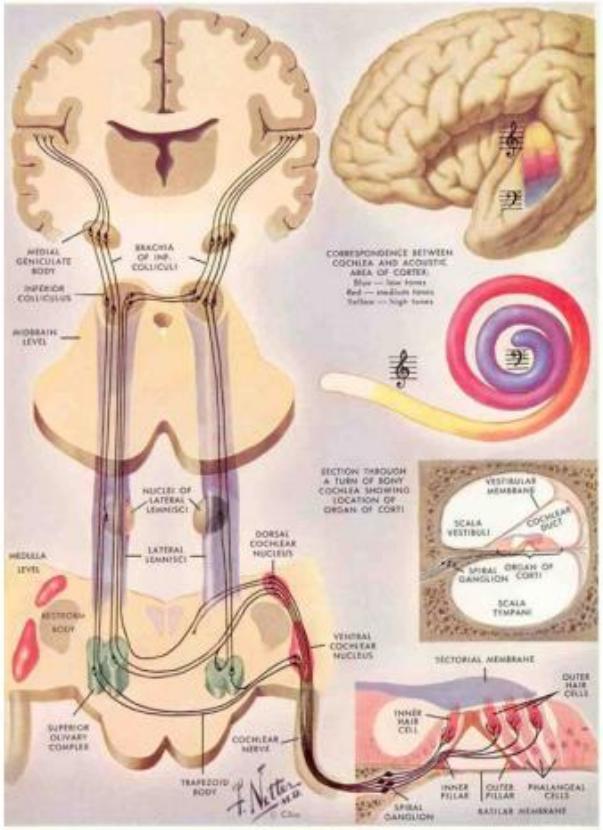

http://emcap.iua.upf.es/BasicsAuditory.html

外围听觉系统：

- 外耳
- 中耳
- 内耳
- 耳蜗

听觉中枢：

- 耳蜗核
- 斜方体
- 橄榄旁核
- 上橄榄
- 外侧丘系
- 下丘和上丘
- 内侧膝状体
- 听觉皮层

听觉感受野的性质

听觉通路

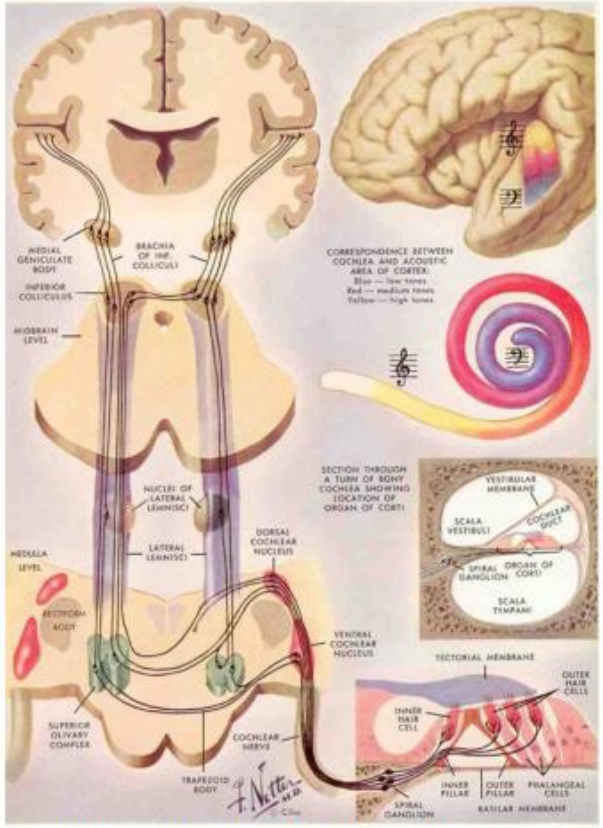

http://emcap.iua.upf.es/BasicsAuditory.html

外围听觉系统：

- 外耳
- 中耳
- 内耳
- 耳蜗

听觉中枢：

- 耳蜗核
- 斜方体
- 橄榄旁核
- 上橄榄
- 外侧丘系
- 下丘和上丘
- 内侧膝状体
- 听觉皮层

听觉感受野的性质

外围听觉系统

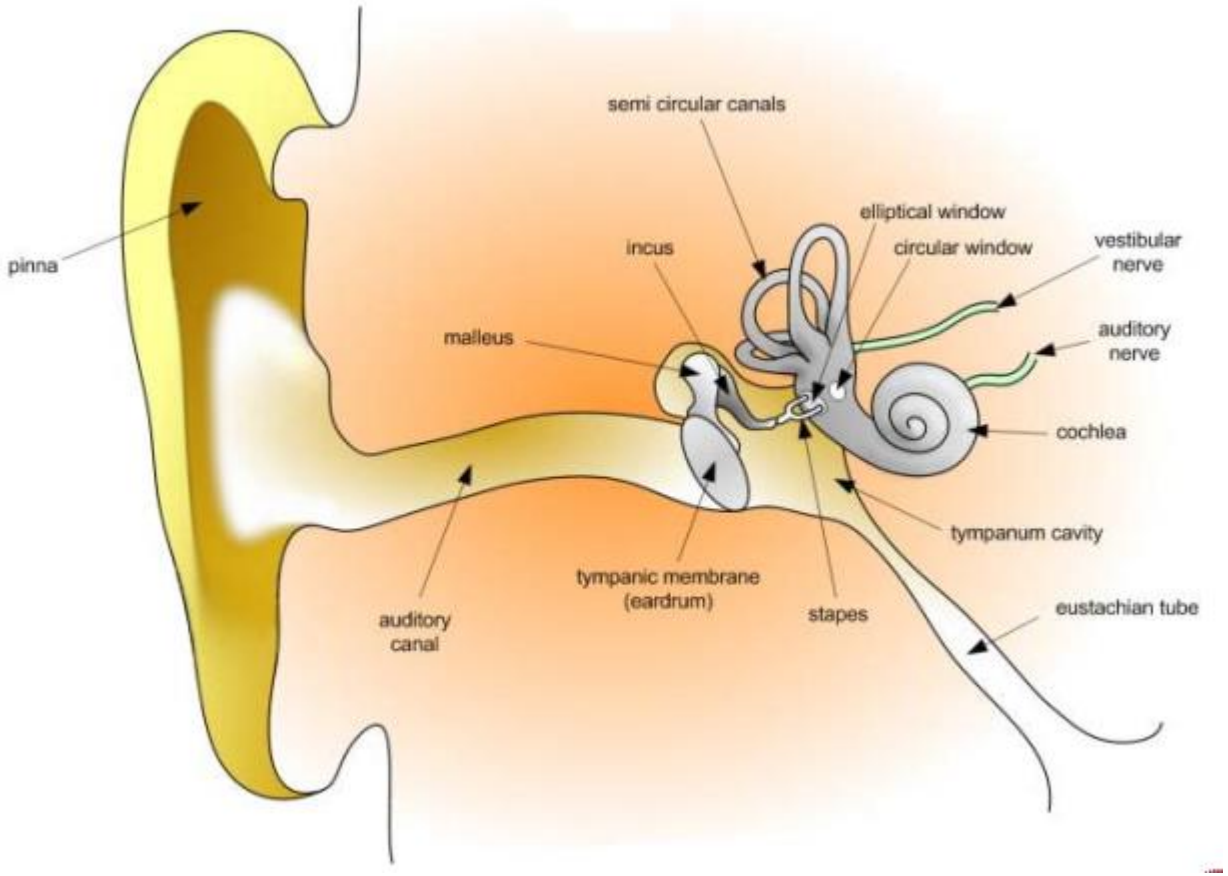

听觉感受野的性质

听觉感受野

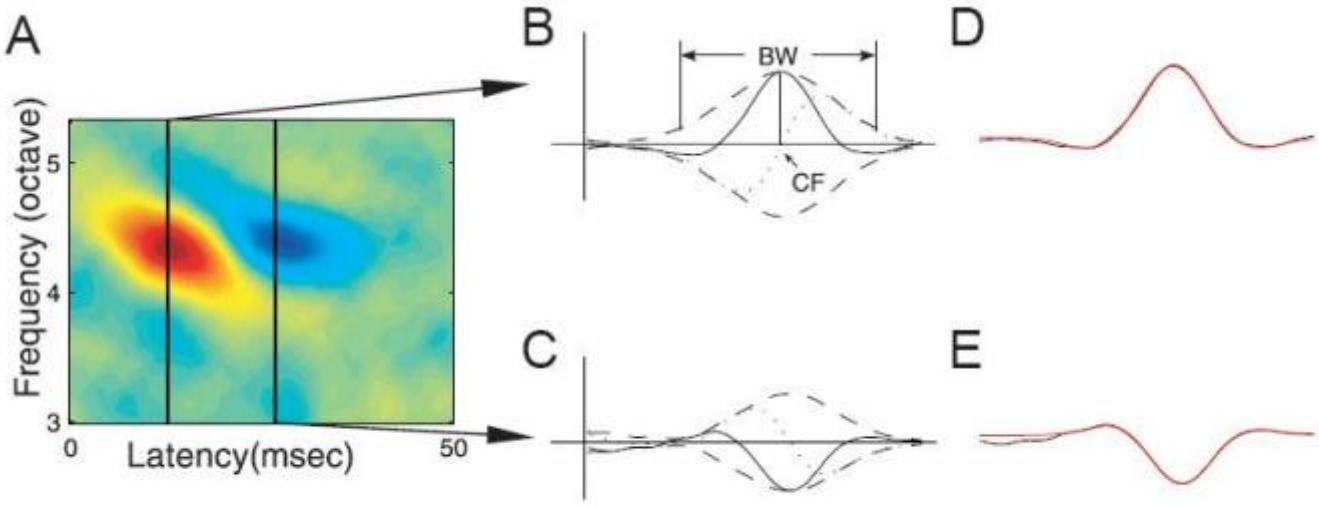

Qiu,J Neurophysiol,2003

听觉感受野的性质

基于皮表特征模型的语音特征提取

Gabor函数

神经心理学研究表明在听觉皮层的神经元反应被调制为局部的时频包络。我们利用2D-Gabor函数对皮层细胞的视频感受野（STRF）进行建模。下面给出2D-Gabor复函数$g_{u,v}(f,t)$的定义：

$$g_{u,v}(f,t) = g_{\bar{k}}(\bar{x}) = \frac{\bar{k}^2}{\sigma^2} \cdot e^{-\frac{\bar{k}^2 \cdot \bar{x}^2}{2\sigma^2}} \cdot \left[e^{i\bar{k}\cdot\bar{x}} - e^{-\frac{\sigma^2}{2}} \right],$$

这里$\bar{x} = (f,t)$表示能量谱样本点，$\bar{k} = k_v e^{i\emptyset}$决定Gabor函数的尺度和方向，其中$k_v = 2^{-\frac{v+2}{2}} \cdot \pi, \emptyset = \mu\frac{\pi}{K}$，$v$ 决定Gabor函数的尺度变化，u 和 v 是相互关联而且由$\bar{k}$控制。我们可以利用Gabor函数获得语音信号的时频包络。下面是Gabor函数的实部示意图。

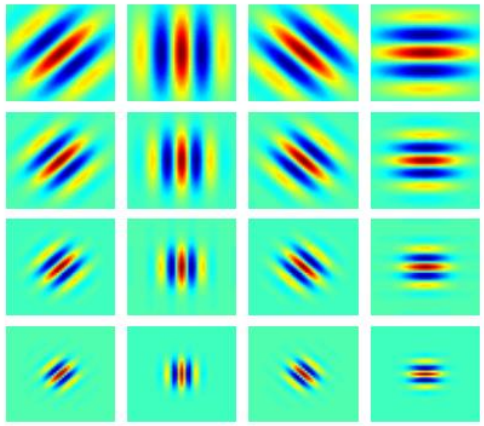

A. Qiu, C.E. Schreiner, and M.A. Escabi. Gabor analysis of auditory midbrain receptive fields: spectro-temporal and binaural composition. *Journal of Neurophysiology*, 90(1):456–476, 2003

听觉感受野的性质

基于皮表特征模型的语音特征提取

初始听觉皮层（A1）中的皮层表征

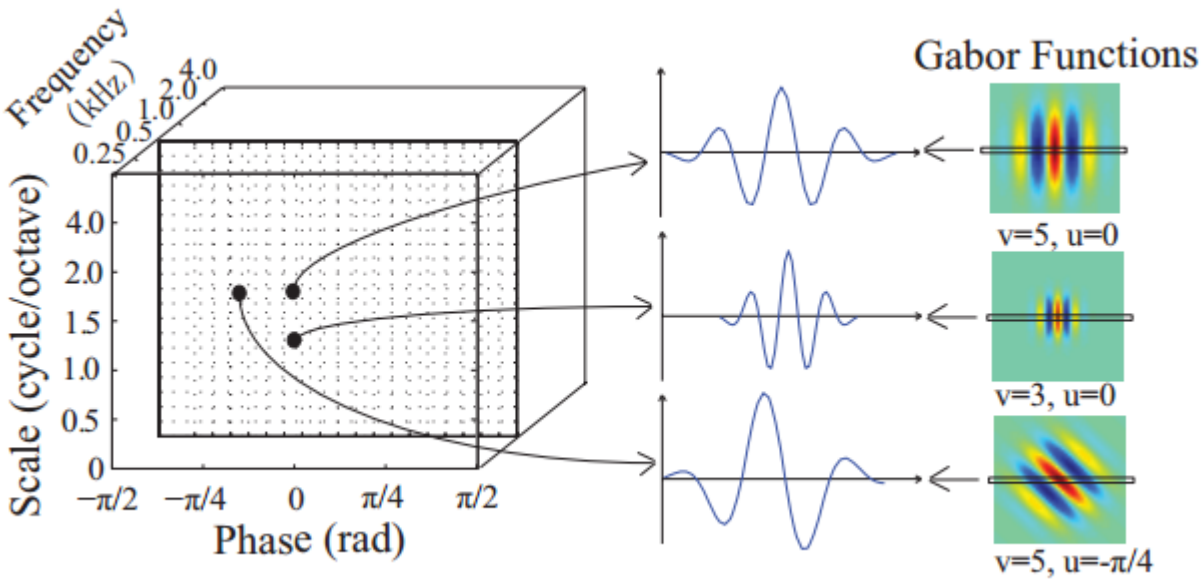

A. Qiu, C.E. Schreiner, and M.A. Escabi. Gabor analysis of auditory midbrain receptive fields: spectro-temporal and binaural composition. *Journal of Neurophysiology*, 90(1):456–476, 2003

听觉感受野的性质

基于皮表特征模型的语音特征提取

皮层表征的张量结构

我们通过将Gabor函数$g_{u,v}(f,t)$与能量谱 $\mathbf{X}(f,t)$ 进行卷积运算得到皮层表征结果，这样可以得到一个4阶张量 $\mathcal{X} \in \mathrm{R}^{N_f \times N_t \times N_v \times N_u}$，其中前两维表示频率和时间坐标，第三维代表尺度，第四维代表方向。对于一个固定尺度和方向参数的Gabor函数，卷积结果可以定义为：

$$\mathbf{G}_{u,v}(f,t) = |\mathbf{X}(f,t) * g_{u,v}(f,t)|.$$

为了保留对于感知有用的频率元素，我们利用Mel尺度滤波器组对卷积结果$\mathbf{G}_{u,v}(f,t)$进行滤波：

$$\mathbf{G}^{m}_{\boldsymbol{u},\boldsymbol{v}}(I,t) = \sum_{f=L_I}^{H_I} |v_I(f)\mathbf{G}_{u,v}(f,t)|$$

这里$v_I(f)|_{I=1}^{N_I}$是一个临界带通三角滤波器。

A. Qiu, C.E. Schreiner, and M.A. Escabi. Gabor analysis of auditory midbrain receptive fields: spectro-temporal and binaural composition. *Journal of Neurophysiology*, 90(1):456–476, 2003

听觉感受野的性质

基于皮表特征模型的语音特征提取

Gabor张量特征

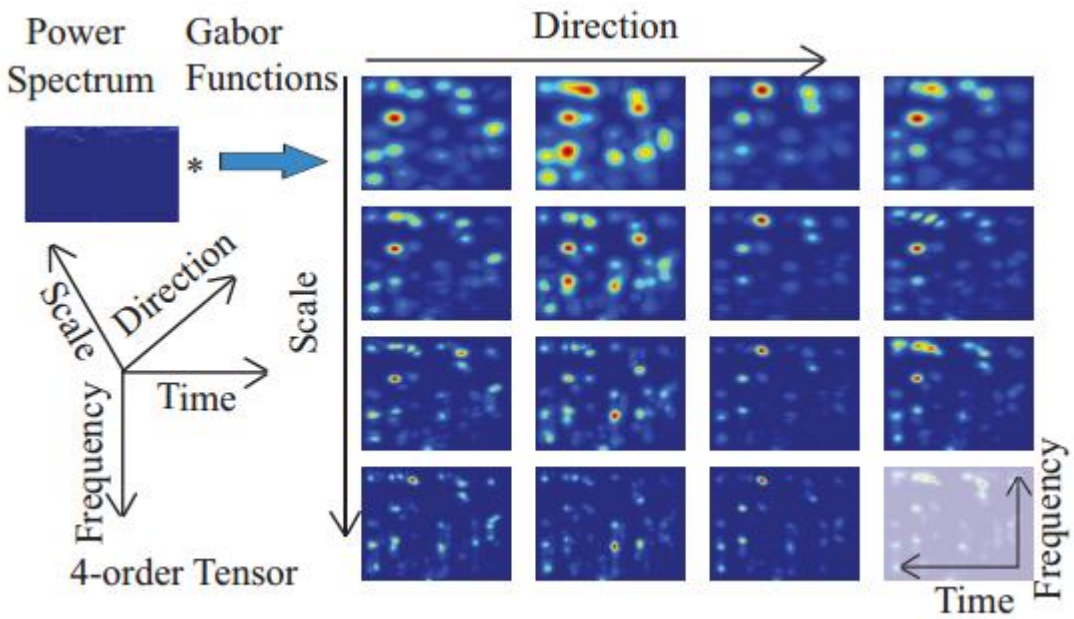

A. Qiu, C.E. Schreiner, and M.A. Escabi. Gabor analysis of auditory midbrain receptive fields: spectro-temporal and binaural composition. *Journal of Neurophysiology*, 90(1):456–476, 2003

听觉感受野的性质

基于皮表特征模型的语音特征提取

稀疏投影与特征

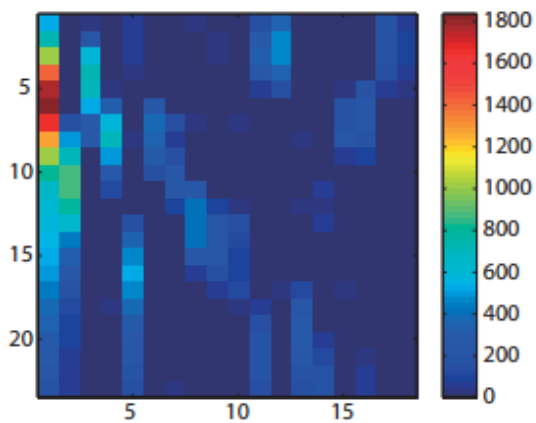

NTPCA 基函数

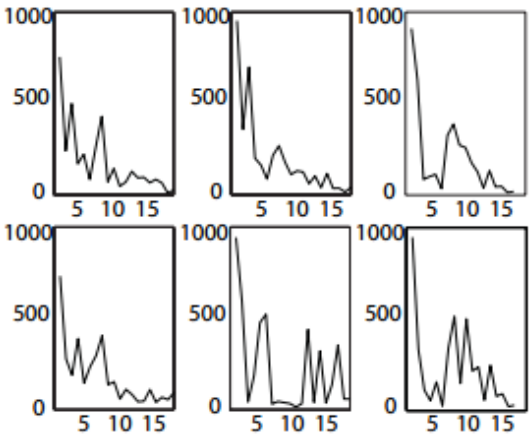

稀疏特征向量

为了提取适于识别的鲁棒性特征，我们首先将语音样本变换为皮层表征 $\mathcal{S} \in \mathrm{R}^{N_f^* \times N_t \times N_v^* \times N_u^*}$，我们可以得到稀疏张量特征 $\mathcal{S} \in R^{N_f^* \times N_t \times N_v^* \times N_u^*}$：

$$\mathcal{S} = \mathcal{G}^m \times_1 \mathbf{U}_f^T \times_3 \mathbf{U}_V^T \times_4 \mathbf{U}_u^T$$

听觉感受野的性质

基于皮表特征模型的语音特征提取

GTCC特征提取框架

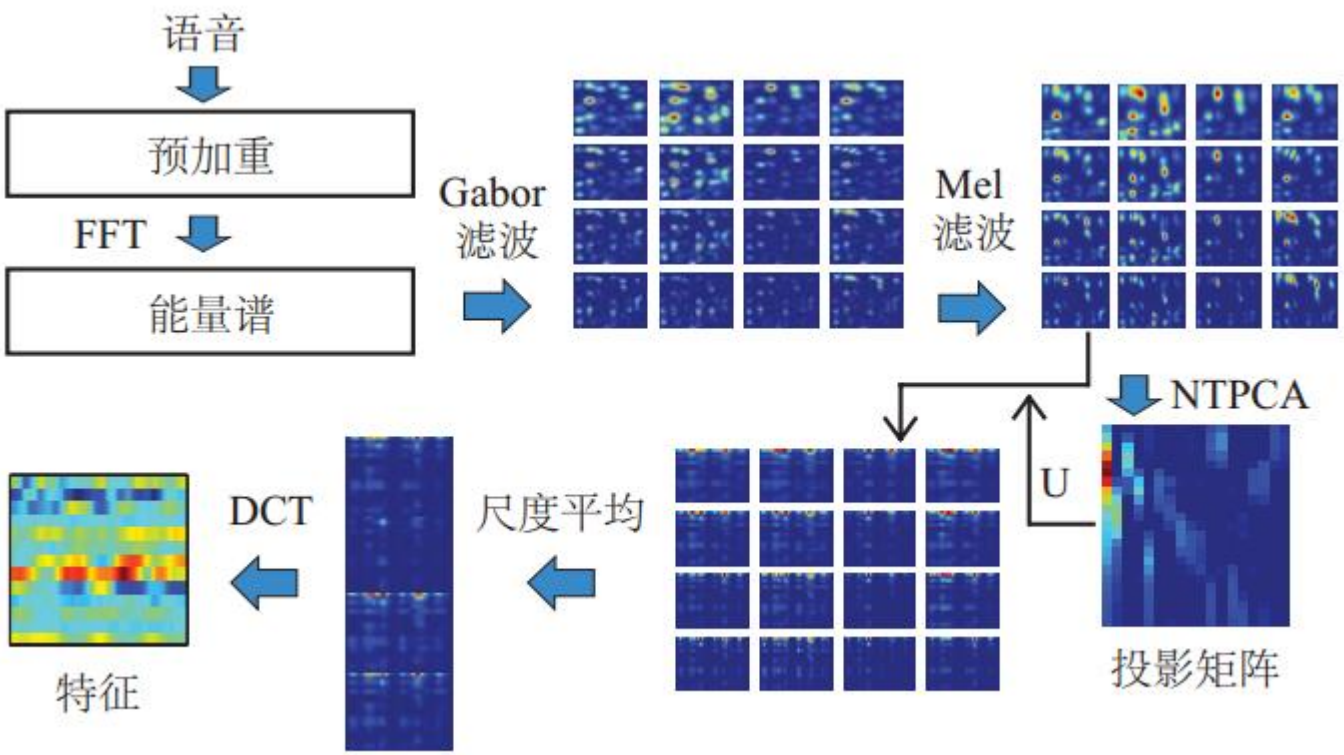

听觉感受野的性质

基于皮表特征模型的语音特征提取

特征提取

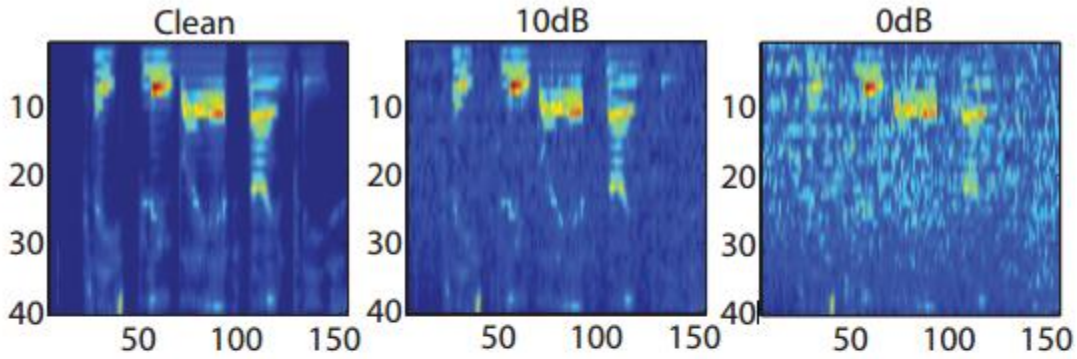

MFCC 特征

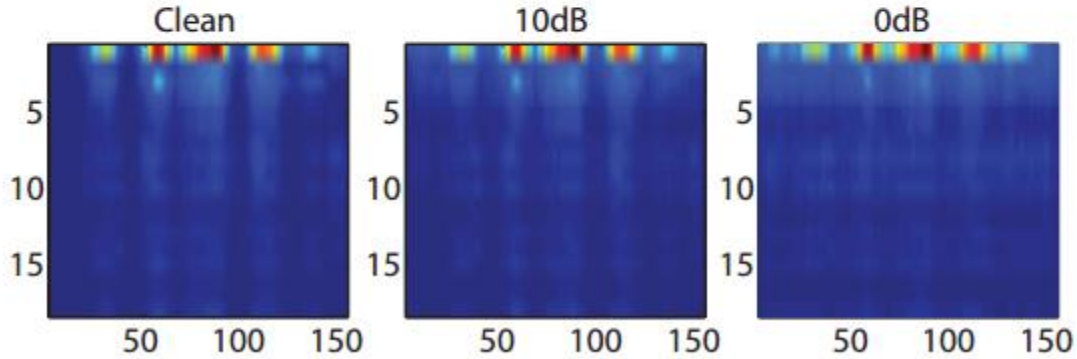

GTCC 特征

听觉感受野的性质

基于皮表特征模型的语音特征提取

特征系数分布

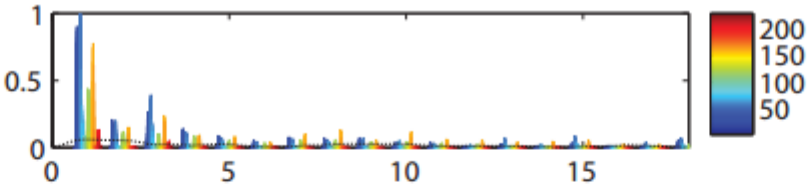

纯净语音的特征系数分布

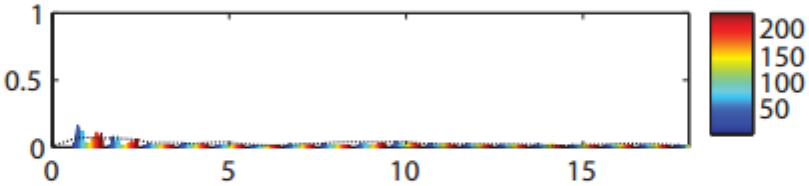

factory 噪声经过变换之后的特征系数分布

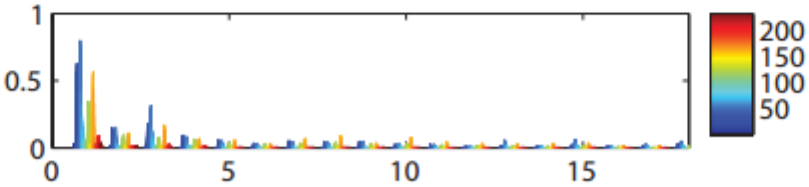

在 SNR=10dB 的 factory 噪声情况下语音的特征系数分布

A. Hyvarinen. Sparse code shrinkage: Denoising of nongaussian data by maximum likelihood estimation. *Neural Computation*, 11(7):1739–1768, 1999.

05 鸡尾酒会问题和时频掩蔽

鸡尾酒会问题和时频掩蔽

鸡尾酒会问题

麦克风能够录入目标语音，同时也录入了干扰噪音

语音识别性能显著降低

鸡尾酒会问题和时频掩蔽

鸡尾酒会问题

目标：实现高质量的免提语音接口系统

方法一：麦克风阵列

可以增强目标语音或者减少干扰

处理问题
（1）声源到达方向
（2）滤波器适配的目标语音的中断

鸡尾酒会问题和时频掩蔽

鸡尾酒会问题

方法二：盲源分离

可以增强目标语音或者减少干扰

(1)不需要任何关于声源方向和声学条件的信息。
(2)主要使用ICA

鸡尾酒会问题和时频掩蔽

基本原理

混合模型

$$x_i(k) = a_{i1}s_1 + a_{i2}s_2 + \cdots + a_{in}s_n + v_i(k)$$

$$x(k) = As(k) + v(k)$$

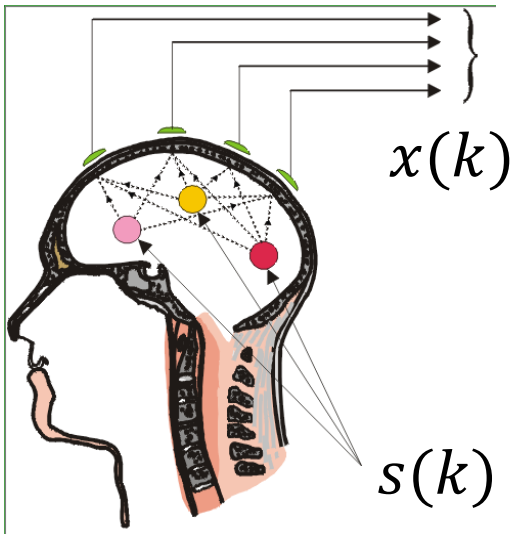

- $\boldsymbol{s}(\mathrm{k}) = (s_1(k), \ldots, s_n(k))^T$: the vector of n-source signals;
- $\boldsymbol{x}(\mathrm{k}) = (x_1(k), \ldots, x_m(k))^{\mathrm{T}}$: the vector of m-sensor signals;
- $\boldsymbol{v}(\mathrm{k})$: the vector of sensor noises.
- $\boldsymbol{A}$: the mixing matrix.

鸡尾酒会问题和时频掩蔽

基本原理

非混合模型：利用传感器信号估计源信号 $\mathrm{y}(k) = Wx(k)$

- $\boldsymbol{y}(\mathrm{k}) = (y_1(k), \ldots, y_m(k))^T$: **the vector of recovered signals**
- **W:** **the demixing matrix**

假定

$$x(k) = As(k) + v(k)$$
$$\mathrm{y}(k) = Wx(k)$$

1. 统计独立
2. 非高斯(最多一个分量是高斯分量)
3. 平稳性
4. A是列满秩

鸡尾酒会问题和时频掩蔽

基本原理

分量振幅

$$x(k) = As(k) = AD^{-1}Ds(k) = \hat{A} \cdot \hat{s}(k)$$

D:对角矩阵

例:

$$\mathbf{Ds} = \begin{bmatrix} d_1 & & & \\ & d_2 & & \\ & & \ddots & \\ & & & d_n \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ \vdots \\ s_n \end{bmatrix} = \begin{bmatrix} d_1 s_1 \\ d_2 s_2 \\ \vdots \\ d_n s_n \end{bmatrix}$$

鸡尾酒会问题和时频掩蔽

基本原理

分量顺序

$$x(k) = As(k) = AP^{-1}Ps(k) = \check{A} \cdot \tilde{s}\,(k)$$

D:置换矩阵

例:

$$\mathbf{Ps} = \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ s_3 \\ s_4 \end{bmatrix} = \begin{bmatrix} s_3 \\ s_2 \\ s_4 \\ s_1 \end{bmatrix}$$

鸡尾酒会问题和时频掩蔽

基本原理

预处理

$$x(k) = x' - E\{x'\}$$

$$z(k) = Vx(k)$$

$$E\{z(k)z(k)^T\} = I$$

鸡尾酒会问题和时频掩蔽

算法概述

ICA算法=目标函数+优化算法

常见目标函数:

Maximum Negentropy
Minimum Mutual Information
Joint Diagonalization of Cross-corrlations
Linear Predictability
Sparseness Maximization

常见优化算法:

Ordinary Gradient
e.g. Infomax (Bell, *et al*. 1996)
Natural Gradient
e.g. Self-Adaptive ICA Method (Zhang, *et al*. 2004)
Relative Gradient
e.g. EASI (Cardoso, *et al*. 1995)
Newton Method
e.g. FastICA (Hyvarinen, *et al*. 1999)
Genetic Algorithm

鸡尾酒会问题和时频掩蔽

DUET算法

使用短时傅立叶变换窗将每个传感器的观测值变换到时频域，并且根据相应的时间频率点的比率计算两个观测值之间的相对衰减和延迟值。

其主要假设是，由于时频域中的语音稀疏性，几乎所有具有显著幅度的混合时频点仅归因于一个原始信号源。

在下页图可以看到一个衰减延迟直方图，它指示存在六个信号源及其相关的衰减和延迟参数。

鸡尾酒会问题和时频掩蔽

DUET算法

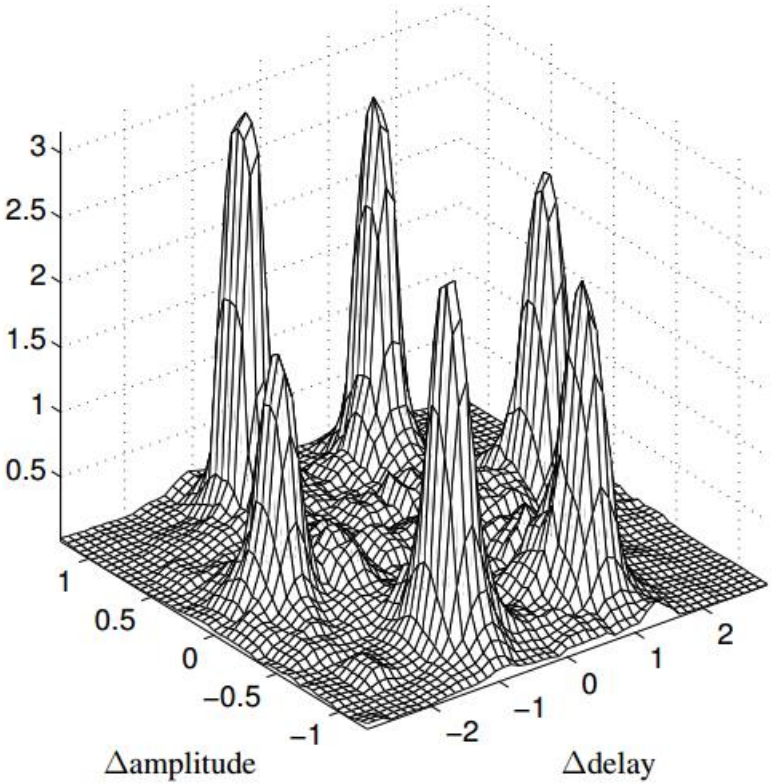

DUET平滑了六个语音源混合的功率加权直方图。 每个峰值对应一个源，峰值位置对应于相关源的混合参数。

05

可计算听觉场景分析

可计算听觉场景分析

听觉场景分析（ASA）是指通过对人的听觉系统在生理和心理层面的研究，来学习出人类对语音接收和感知的机理。而计算听觉场景分析（CASA ）就是将物理和生物学上的研究应用到数学模型的构建，使得计算机也能够仿真这种听觉特性，进而实现机器智能。

听觉场景分析概念最早由 Cherry 在1953年提出，在这之后借鉴心理学方面的一些研究的丰富，一些听觉场景分析的基本理论也越来越多。包括人耳分离视合声音问题也定义了一系列准则。其中Bregman在其书中认为：人耳在同一时刻不可能同时感受到来自不同信息流的声音，而只会感知某个声源的信息。但是人的大脑可以连续地进行感知，并把感知过程中属于同一信息流的信息片段整合起来。这就是人耳和大脑能够在混杂的环境中分离出信号、感知不同信号的一个解释。听觉场景分析提供了有效的理论基础，出现了许多的计算听觉场景模型和算法。

基于听觉计算模型和深度神经网络的双耳语音分离 ,范娜娜，2017

可计算听觉场景分析

基于Bregman的理论，近年来计算场景分析也有了长足的发展。研究者对人耳感知过程构建一系列校型，使得计算机能够逼近甚至在某些特定场景下达到人耳语音分离的优越性能。综合各个 CASA 的模型和方法，可以把计算机的语音处理过程按顺序分为三部分：

第一部分：先将语音信号进行时域频域二维表达形式，短时傅里叶变换就是一种方式，这样原来的声波信号就可以被分成一个个时频单元（T-F units）。因为未处理观测信号在时域上和频域上是混合的，因此 CASA 方法借鉴人耳的耳蜗频选特性，用中心频率分布相类似的非线性滤波器组进行滤波，使得混合信号转换到可以被分辨开的变换域中。

第二部分：将这些时频单元分到各自归属的信号流中，这是一个分类或者聚类的过程。

第三部分：将属于各个信息流的时频单元整合起来，进行语音的恢复，至此，混合语音的各个分量就被分离出来了。

基于听觉计算模型和深度神经网络的双耳语音分离 ,范娜娜，2017

可计算听觉场景分析

近年来， CASA 方法在语音分离方面有不少的应用，利用人耳心理生理学特征对语音进行相应的特性研究也不断地取得成果。基于人耳的声音掩蔽现象，文献中提到， ASA 的主要任务是将接收到的声音信息分成属于不同场景的声音流，使得分离出来的每个声音流能代表混合声音场景中的一个声源。而 CASA 的研究则是从计算的角度将声音信号分离成不同的语音流。而从计算的角度来看，Wang认为 CASA 的最终目标是估计出一个理想的时频掩蔽矩阵，即将声音表达成时频表达形式后，一个理想的T-F mask 则就是一个二维的0-1矩阵，当该 T-F unit 所在位置的 target 语音强于背景干扰时，mask 上的 T-F unit 值为1，否则为 0 。

可计算听觉场景分析

单通道语音分离的传统方法，例如 BSS，麦克风阵列等，需要多个麦克风或者接收器，传统的 HMM 语音建模则是对语言和干扰做了相应的假设条件，在干扰和语音多样化环境下，不一定能够进行好的建模和分离。针对麦克风阵列的beamforming方法能够建立一个 special-dependent 的滤波模型，来对target语音进行增强，但如果干扰和target语音距离太近或语音的空间特征不明显，这种方法可能没办法进行有效地增强。而 CASA 将语合分成分成T-F units，无论是单通道还是双通道，它的计算目标都是对这些 units 进行分离聚类，并不需要太多的假设条件，因此有更好的通用性。

可计算听觉场景分析

计算听觉场景分析系统基本上可以被数据驱动型和图式驱动型两类方法。前者是符合以往对信息处理过程的经验，认为信息由下到上单向流动。后者则包含双向的流动。即由下到上和由上到下同时存在，研究表明这种方式才应该是人耳听觉感知的实际机制。

可计算听觉场景分析

数据驱动型CASA系统

（1）仿人耳听觉机制，把接收到的混合声音信号划分到一组基本感知单元。一般来说，混合声音信号被转换到能够辨别每个声源分量的变换域。这种转换通常借助仿耳蜗频响的听觉滤波器组来完成。进行这种转换的原因是原始混合信号在时间轴与频率轴上具有严重的重叠，不能使用经典的频域滤波方法有效地辨别声源。可以推断，如果转换后的单个感知单元有合适的大小，那么它将不太可能同时被多个源影响。

（2）假设基本感知单元之间存在连续性，将时频空间划分成多个区域，这一阶段可视为将上阶段得到的感知单元进行类内聚合。实验表明，同一声源会占据某些特定的局部区域，那么可以假设，在时频空间越接近的感知单元，属于同一声源的可能性越高。

基于听觉场景分析的多人语音分离方法，王凯龙，2018

可计算听觉场景分析

数据驱动型CASA系统

结构如下图所示，一般包括四个阶段

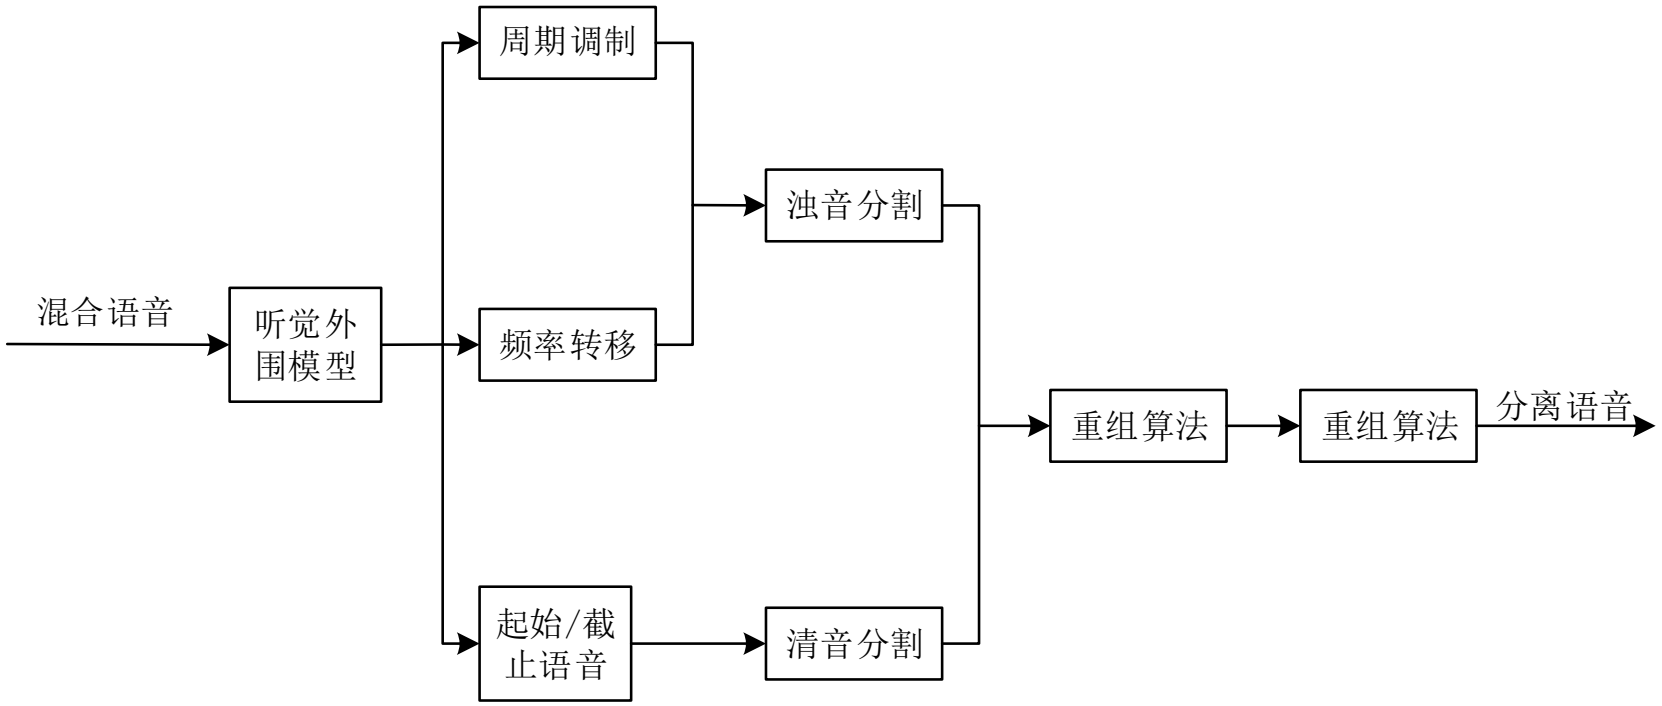

基于听觉场景分析的多人语音分离方法，王凯龙，2018

可计算听觉场景分析

数据驱动型CASA系统

（3）将上阶段得到的分块区域按声派感知差异进行分组，从而将认定为同一声派的成分归于同一感知流，此阶段可再分为“同时组合”（simultancous grouping）和“时序组合”（sequential grouping）。如下图所示， B与C的组合属于“同时组合”，指将相同时间段内属于同一声源不同频段的声音分量组合在一起， A与 B 的组合属于“时序组合”，是指将不同时间段产生的来自同一个声源的听觉片段按时间的先后顺序组合到一个声音流中。

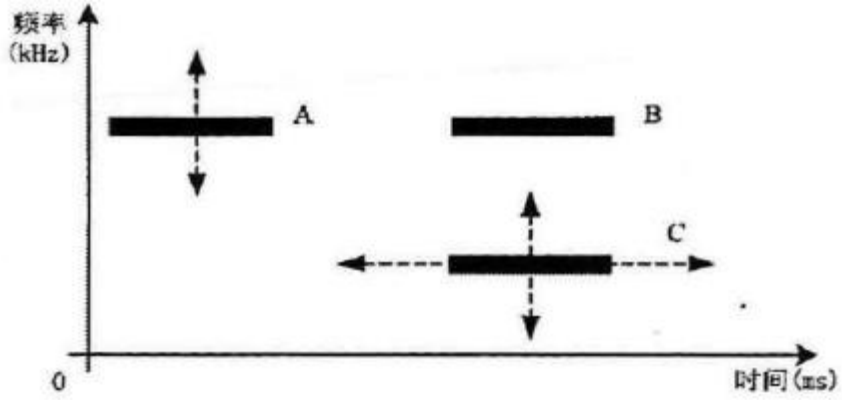

基于听觉场景分析的多人语音分离方法，王凯龙，2018

可计算听觉场景分析

数据驱动型CASA系统

（4）最后阶段在上述各步骤得到的感知流基础上进行语音重建，还原声音信号。整个 CASA 系统的难点在于分离和组合的过程，首先要找出较为合适的分离依据，包括同时起始与结束、谐波关系、连续性与平滑性、节奏与空间位置等，然后要有一组合适的规则将分块区域进行拼合。

基于听觉场景分析的多人语音分离方法，王凯龙，2018

可计算听觉场景分析

图式驱动型CASA系统

图式驱动型 CASA 系统结构如下图所示，因为信息分布在不同的层次中，要实现不同层信息交互存在一定困难。此类系统多基于黑板结构，将不同层次的信息公布于黑板上，让不同层之间的信息相互关联，从而提高了信息处理的灵活性。理论上图式驱动型 CASA 系统更加符合人类听觉系统对信息的处理过程，但受限于系统构造的复杂性，实际效果往往不及数据驱动型系统。

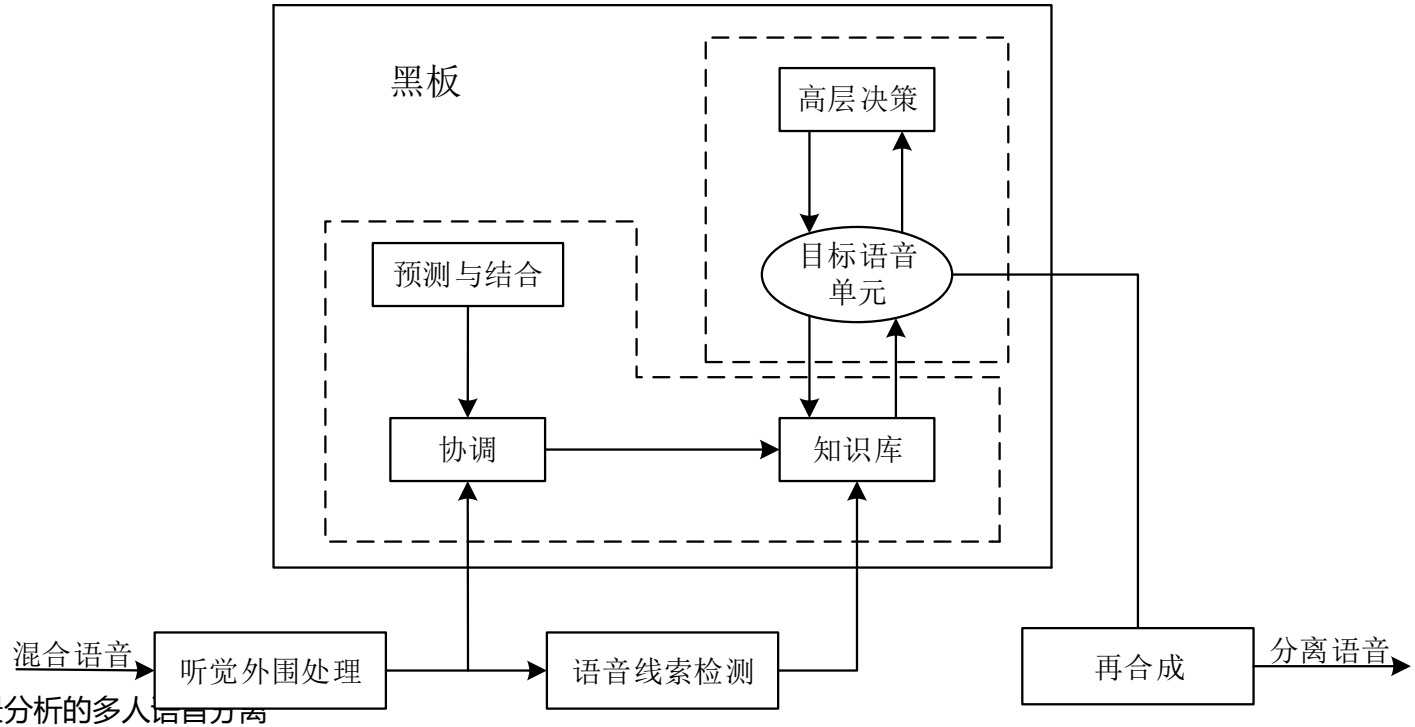

基于听觉场景分析的多人语音分离方法，王凯龙，2018

可计算听觉场景分析

图式驱动型CASA系统

CASA 提出之后出现了 Brown-Cooke 系统、 Hu-Wang 系统、Jin算法等一系列语音分离算法。在这些算法中，基音周期都被作为分离和组合的重要依据，因而待分离的目标语音基音周期的精确性对分离效果具有决定性影响。然而，目标语音的基音周期常常受到噪声的影响，尤其是在低信噪比条件下，因此，如何得到鲁棒性的基音周期估计是一大难点。同时，多数基于 CASA 的语音分离方法目标在于从噪声中提取语音以及应用于音乐分离，对多说话人的语音分离研究涉及较少。

基于听觉场景分析的多人语音分离方法，王凯龙，2018

可计算听觉场景分析

目前已有许多计算听觉现象分析模型（CASA）提出，各种各样的CASA计算模型的目的在于解决混合输入声音信号的智能感知处理问题。不同的CASA系统按其所处理的声音形式和从这些声音中提取的不同信息有不同的结构。

基于盲信号处理和听觉现象分析的语音增强与分离方法 ,1999

可计算听觉场景分析

G.J.Brown在其博士论文和相关文献中提出了一种CASA 计算模型， 大致框图如下，其可以分为四个阶段：

首先: 利用一个滤波器组模拟人耳的外围处理模型并用神经传输机理模拟内耳毛细胞的的传输作用;
第二阶段: 利用第一阶段的神经输出， 提取输入语音信号的周期性、频率传输、开始时刻与结束时刻等特征， 并用一系列的映射图(map)表示;
第三阶段: 利用各种映射图表征的语音信息组建听觉感知成分分段的符号表示;
第四阶段: 按照各语音成分的基音频率、 开始时间、 结束时间的相似性以及各种映射图， 建立一种基于符号的搜索策略算法 。

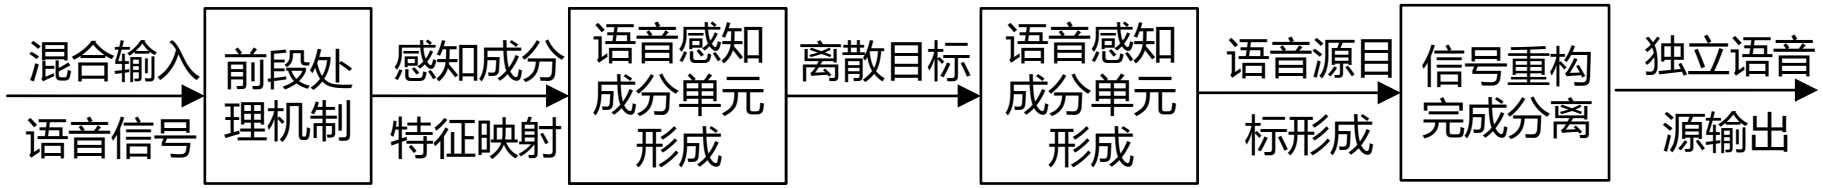

基于盲信号处理和听觉现象分析的语音增强与分离方法 ,1999

可计算听觉场景分析

基于IPUS黑板结构的CASA模型

IPUS：信号综合处理与理解系统(Integrated Processing and Understanding of Signal)， 主要应用于复杂环境中如不间断变化的输入信噪比、 不可预测信号源变化以及相互影响的不同语音源的共同发生情况下的处理系统。

一个IPUS系统大致可以由3部分组成:

1. 一系列的前端信号处理算法(SPAs)，并且具有各种不同的可调节算法参数;
2. 一系列基于不同期望(Expectation)的假设、 判断;
3. 控制面板(Control Planner)。

基于盲信号处理和听觉现象分析的语音增强与分离方法 ,1999

可计算听觉场景分析

基于IPUS黑板结构的CASA模型

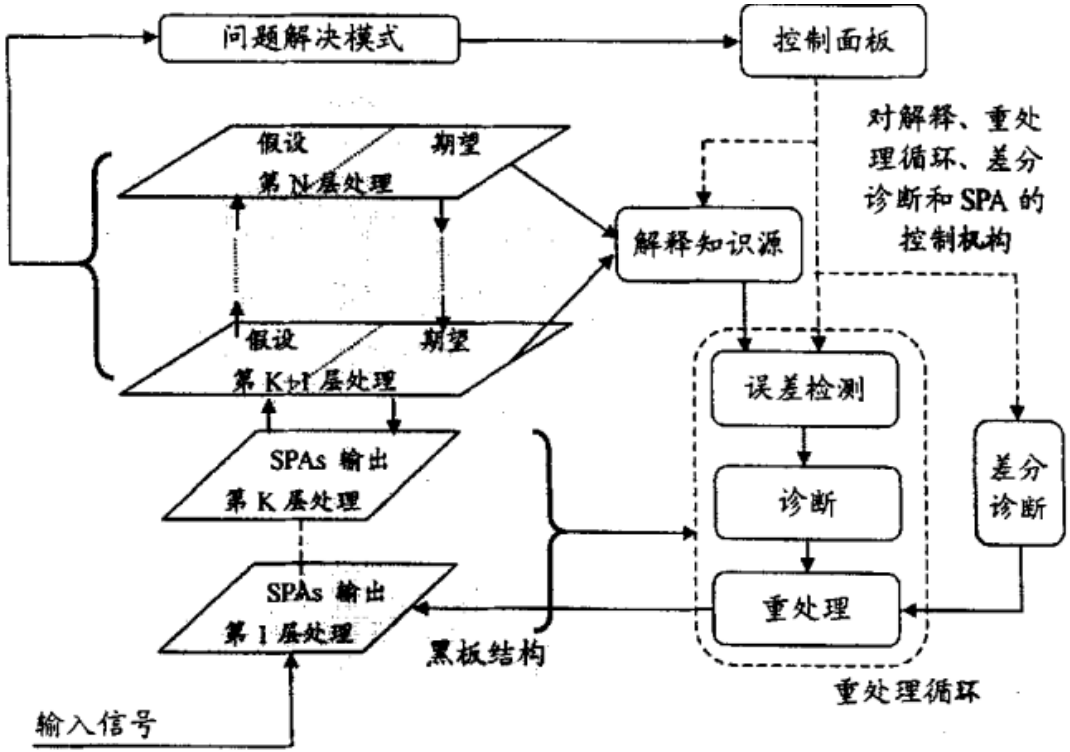

基于盲信号处理和听觉现象分析的语音增强与分离方法 ,1999

可计算听觉场景分析

基于预测驱动（Prediction-driven）的CASA模型

与大多数基于数据驱动的CASA模型不同，美国麻省理工学院的D.P.W.Ellis在其博士论文中提出一种基于预测驱动的CASA模型。在他的CASA模型中同样采用了类似黑板结构的工作机理，并且采用更切近于人听觉系统的结构。

基于预测驱动的C人SA 模型可以大致分为如下四个部分：

一、 前端处理部分；

二、 核心表达部分(The core world-model)；

三、 预测驱动引擎(Predictive-Reconciliation Engine)；

四、 高层次的抽象(Higher-level abstraction) 。

基于盲信号处理和听觉现象分析的语音增强与分离方法 ,1999

可计算听觉场景分析

基于预测驱动（Prediction-driven）的CASA模型

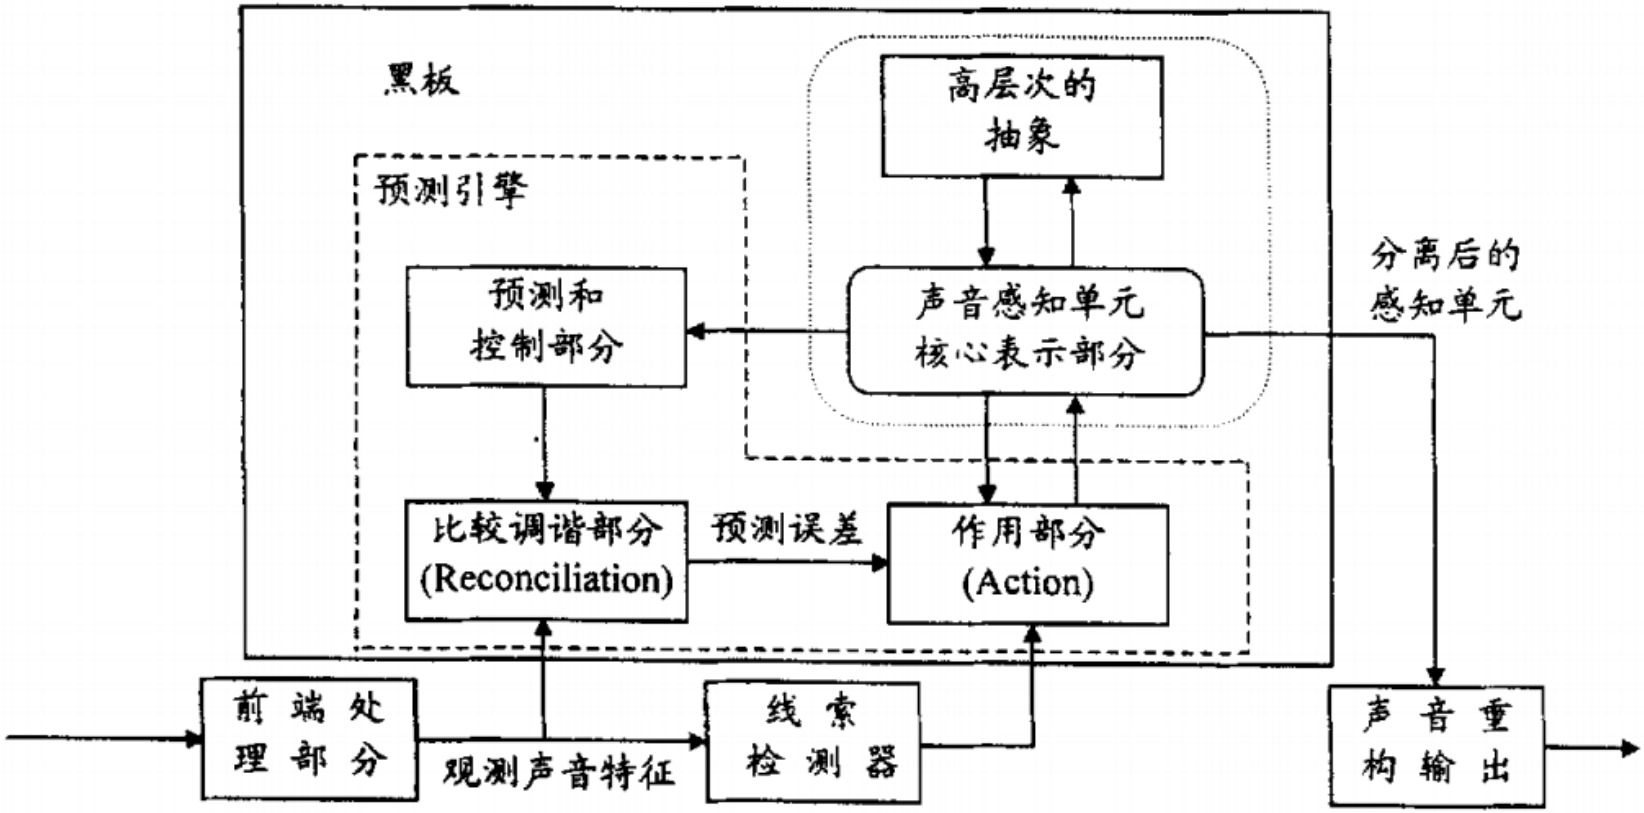

基于盲信号处理和听觉现象分析
的语音增强与分离方法 ,1999

Thanks